



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

پایان نامه کارشناسی

رشته مهندسی کامپیوتر، گرایش هوش مصنوعی

عنوان پایان نامه:

چتبات فارسی مبتنی بر یکپارچه سازی تشخیص گفتار، مدل زبانی بزرگ و
تبدیل متن به گفتار

استاد راهنما:

دکتر حمیدرضا برادران کاشانی

پژوهشگر:

علی اکبر احراری

شهریور ۱۴۰۵



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

گروه هوش مصنوعی

پایان نامه کارشناسی

رشته مهندسی کامپیوتر، گرایش هوش مصنوعی

عنوان پایان نامه:

چت بات فارسی مبتنی بر یکپارچه سازی تشخیص گفتار، مدل زبانی بزرگ و تبدیل متن به گفتار

پژوهشگر: علی اکبر احراری

در تاریخ _____ / _____ / ۱۴_____ توسط هیأت داوران زیر بررسی و با نمره _____ به تصویب
نهایی رسید.

۱- استاد راهنمای پروژه:

دکتر حمیدرضا برادران کاشانی

امضا _____

۲- استاد داور:

دکتر _____

امضا _____

امضای مدیر گروه _____

تشکر و قدردانی

از استاد راهنمای محترم، جناب آقای دکتر حمیدرضا برادران کاشانی، که با راهنمایی‌های علمی، دقت نظر و حمایت خود مسیر انجام این پروژه را روشن کردند، صمیمانه سپاسگزاری می‌کنم. دیدگاه‌ها و پیشنهادهای ایشان نقش مهمی در شکل‌گیری روش ارزیابی و تکمیل سامانه داشت.

همچنین از خانواده‌ام که با حمایت و تشویق خود انگیزه لازم را در طول انجام این پژوهش فراهم کردند، سپاسگزارم. در پایان، از دوستانم که با همراهی و حمایت معنوی خود موجب دلگرمی من شدند، تشکر می‌کنم.

تقديم به

خانواده‌ام،

که همراهی و پشتیبانی‌شان انگیزه ادامه این مسیر بود.

چکیده

در این پروژه یک دستیار صوتی فارسی محلی طراحی، پیاده‌سازی و ارزیابی شده است. خط لوله نهایی از مدل سیلرو برای تعیین شروع و پایان گفتار، مدل فارسی واسک نسخه ۴۲۰۰ برای تشخیص گفتار، نسخه چهاربیتی گما ۲ با ۹ میلیارد پارامتر برای تولید پاسخ و پایپر برای تولید و پخش جریانی گفتار استفاده می‌کند. افزون بر اتصال مدل‌ها، کنترل ابهام مبتنی بر اطمینان واژه و فرضیه‌های چندگانه، حافظه اصلاح محدود به زمینه، تاریخچه چندنوبتی، تقویت انتخابی صوت کم‌دامنه و ثبت زمان‌های مرحله‌ای پیاده‌سازی شده‌اند.

برای انتخاب اجزای سامانه، چند مدل تشخیص گفتار، مدل زبانی و تبدیل متن به گفتار بر پایه معیارهای کیفیت، سرعت و مصرف منابع مقایسه شدند. همچنین اثر خطاهای تشخیص گفتار بر پاسخ مدل زبانی به‌صورت پایین‌دستی بررسی شد. نتایج نشان دادند که رتبه مدل‌های تشخیص گفتار به دامنه داده وابسته است و کم‌بودن خطای کلی واژه به‌تنهایی حفظ اطلاعات ضروری برای پاسخ‌گویی را تضمین نمی‌کند. ازاین‌رو، در طراحی نهایی علاوه بر انتخاب مدل مناسب، به اختلاف‌های مرتبط با وظیفه مانند نام‌ها، اعداد و نفی توجه شده است.

آزمایش‌های انجام‌شده نشان دادند که پیش‌پردازش محدود صوت‌های ضعیف و استفاده محتاطانه از فرضیه‌های جایگزین با تکیه بر اصلاح صریح کاربر می‌توانند پایداری مسیر تشخیص گفتار تا تولید پاسخ را افزایش دهند. در مقابل، انتخاب خودکار فرضیه صرفاً بر پایه امتیاز رمزگشا می‌تواند خطا را بیشتر کند. معماری جریانی نیز با هم‌پوشانی تولید متن، تولید صوت و پخش، زمان انتظار ادراکی کاربر را کاهش می‌دهد. در مجموع، این پروژه یک چارچوب ماژولار و قابل بازتولید برای توسعه و تحلیل دستیارهای صوتی فارسی محلی فراهم می‌کند و نشان می‌دهد کیفیت نهایی حاصل تعامل مدل‌ها، کنترل خطا، مدیریت زمینه و نحوه اجرای خط لوله است.

کلمات کلیدی: چت‌بات صوتی فارسی، تشخیص گفتار، مدل زبانی بزرگ، تبدیل متن به گفتار، انتشار خطا، رفع ابهام، پردازش جریانی

فهرست مطالب

د	فهرست مخفف‌ها
۱	۱ مقدمه
۱	۱-۱- بیان مسئله و هدف پروژه
۴	۲-۱- کاربردها و اهمیت عملی
۵	پرسش‌های پژوهش
۶	۳-۱- ساختار گزارش
۷	۲ مفاهیم
۷	۱-۲- مقدمه
۷	۲-۲- قرارداد خط لوله صوتی
۷	۱-۲-۲- بازنمایی دیجیتال گفتار
۸	۲-۲-۲- رابط داده میان مؤلفه‌ها
۹	۳-۲- تشخیص گفتار و معیارهای آن
۹	۱-۳-۲- خانواده مدل‌های بررسی شده
۹	۲-۳-۲- پیش‌آموزش و ریزتنظیم مدل‌های ارزیابی شده
۱۰	۳-۳-۲- معماری ویو ۲ و ۲ و ایکس ال اس آر
۱۱	۴-۳-۲- معماری ویسپر
۱۲	۵-۳-۲- معماری کانفورمر و فست کانفورمر
۱۲	۶-۳-۲- ساختار اجرایی واسک
۱۲	۷-۳-۲- هم‌ترازی، رمزگشایی و اطمینان
۱۳	۸-۳-۲- نرخ خطای واژه و نویسه

۱۴	۹-۳-۲- نرمال سازی فارسی و سطح ارزیابی
۱۴	۱۰-۳-۲- سرعت و تأخیر
۱۴	۴-۲- مدل زبانی در یک دستیار محلی
۱۵	۱-۴-۲- توکن سازی و معماری رمزگشای ترنسفورمر
۱۷	۲-۴-۲- خانواده مدل های بررسی شده
۱۷	۳-۴-۲- ساخت زمینه و شیوه تولید پاسخ
۱۸	۴-۴-۲- کوانتیزه سازی و معیارهای استنتاج
۱۹	۵-۴-۲- معیارهای کیفیت پاسخ
۲۰	۵-۲- تبدیل متن به گفتار و معیارهای آن
۲۰	۱-۵-۲- مدل های مورد استفاده
۲۰	۲-۵-۲- معماری ویتس
۲۱	۳-۵-۲- تفاوت مدل های مورد ارزیابی
۲۲	۴-۵-۲- بازنمایی متن و تولید موج صوتی
۲۲	۵-۵-۲- کیفیت ادراکی و بازشناسی پذیری
۲۳	۶-۵-۲- کارایی زمانی
۲۳	۶-۲- تشخیص فعالیت صوتی و کنترل نوبت
۲۴	۷-۲- انتشار خطا، رفع ابهام و حافظه
۲۵	۱-۷-۲- معیارهای ارزیابی انتشار خطا و عدم قطعیت
۲۶	۸-۲- مرور پژوهش ها و کارهای مرتبط
۲۶	۹-۲- تشخیص گفتار فارسی
۲۶	۱-۹-۲- داده ها و معیارهای فارسی
۲۷	۲-۹-۲- مدل های چندزبانه و معماری های کارآمد
۲۸	۳-۹-۲- نتیجه برای پروژه
۲۸	۱۰-۲- مدل های زبانی فارسی و اجرای محلی
۲۸	۱-۱۰-۲- ارزیابی زبان فارسی
۲۸	۲-۱۰-۲- محدودیت اجرای محلی
۲۹	۳-۱۰-۲- نتیجه برای پروژه
۲۹	۱۱-۲- تبدیل متن به گفتار فارسی

۲۹	۱-۱۱-۲-داده و مدل
۲۹	۲-۱۱-۲-ارزیابی چندبعدی
۳۰	۳-۱۱-۲-نتیجه برای پروژه
۳۰	۱۲-۲-سامانه‌های گفت‌وگوی صوتی یکپارچه
۳۰	۱-۱۲-۲-ارزیابی وظیفه‌محور تشخیص گفتار در کاربردهای مبتنی بر مدل زبانی
۳۲	۱۳-۲-مقایسه کارهای مرتبط
۳۲	۱۴-۲-شکاف پژوهشی و جایگاه پروژه حاضر
۳۳	۱۵-۲-جمع‌بندی

۳ شرح پروژه

۳۴	۱-۳-مقدمه
۳۴	۲-۳-نیازمندی‌های سامانه
۳۴	۱-۲-۳-نیازمندی‌های عملکردی
۳۵	۲-۲-۳-نیازمندی‌های غیرعملکردی
۳۵	۳-۳-معماری ماژولار
۳۶	۴-۳-دریافت صوت و تشخیص انتهای گفتار
۳۷	۵-۳-آماده‌سازی صوت و تشخیص گفتار
۳۷	۶-۳-کنترل ریسک و رفع ابهام
۳۸	۷-۳-تاریخچه و حافظه نشست
۳۸	۸-۳-تولید پاسخ و گفتار جریانی
۳۸	۹-۳-جریان یک نوبت مکالمه
۳۹	۱۰-۳-ثبت معیارها و حریم خصوصی
۳۹	۱۱-۳-پیاده‌سازی سامانه
۳۹	۱-۱۱-۳-نمای کلی پیاده‌سازی
۴۰	۱۲-۳-تنظیمات و قابلیت بازپیکربندی
۴۱	۱۳-۳-پیاده‌سازی دریافت صوت و تشخیص فعالیت صوتی
۴۱	۱۴-۳-پیاده‌سازی آماده‌سازی و تشخیص گفتار
۴۲	۱۵-۳-نرمال‌سازی محافظه‌کارانه فارسی
۴۲	۱۶-۳-پیاده‌سازی ارزیابی ریسک تشخیص گفتار

۴۲	۱۷-۳-بازرتبه‌بندی محدود با حافظه اصلاح
۴۳	۱۸-۳-پیاده‌سازی نشست و کنترل مکالمه
۴۳	۱۹-۳-پیاده‌سازی مدل زبانی
۴۴	۲۰-۳-پیاده‌سازی تبدیل متن به گفتار جریانی
۴۴	۲۱-۳-هماهنگ‌سازی، معیارها و مدیریت خطا
۴۴	۲۲-۳-آزمون‌پذیری و جداسازی پژوهش از اجرا
۴۵	۲۳-۳-جمع‌بندی

۴ نتایج

۴۶	۱-۴-مقدمه
۴۶	۲-۴-کنترل نشت داده میان آموزش و آزمون
۴۷	۱-۲-۴-مدل‌های تشخیص گفتار
۴۷	۲-۲-۴-مدل‌های تبدیل متن به گفتار
۴۸	۳-۴-ارزیابی مستقل تشخیص گفتار
۴۸	۱-۳-۴-مجموعه کامن‌ویس نسخه ۲۵
۴۸	۲-۳-۴-مجموعه بخش فارسی مجموعه فلورز
۴۹	۴-۴-ارزیابی مستقل مدل‌های زبانی
۴۹	۱-۴-۴-پرسش‌های چندگزینه‌ای پارسی‌ان‌ال‌یو
۵۰	۲-۴-۴-درک مطلب فارسی
۵۰	۵-۴-ارزیابی مستقل تبدیل متن به گفتار
۵۳	۶-۴-انتشار خطا از تشخیص گفتار به مدل زبانی
۵۵	۱-۶-۴-نرخ خطای واژه در برابر حفظ عبارت پاسخ
۵۶	۷-۴-آزمایش تقویت صوت‌های کم‌دامنه
۵۶	۸-۴-شواهد فرضیه‌های چندگانه و بازیابی زمینه‌ای
۵۷	۱-۸-۴-بازیابی با اصلاح صریح
۵۸	۹-۴-انتخاب پارامتر بدون نشت داده
۵۹	۱۰-۴-ارزیابی چندنوبتی کنترل مکالمه
۵۹	۱۱-۴-بحث و تحلیل نتایج
۵۹	۱-۱۱-۴-مقدمه تحلیل

۶۰	۱۲-۴-وابستگی انتخاب تشخیص گفتار به دامنه
۶۰	۱۳-۴-کیفیت مدل زبانی و هزینه استقرار
۶۱	۱۴-۴-معنای نتایج انتشار خطا
۶۱	۱۵-۴-تفسیر پیش پردازش صوت
۶۲	۱۶-۴-چرا فرضیه‌های چندگانه نباید کورکورانه انتخاب شوند
۶۲	۱۷-۴-توازن رفع ابهام و تجربه کاربر
۶۲	۱۸-۴-کاهش تأخیر ادراکی با جریان سازی
۶۳	۱۹-۴-انتخاب ترکیب نهایی
۶۳	۲۰-۴-جمع بندی

۵ نتیجه گیری و پیشنهادات ۶۴

۶۴	۱-۵- نتیجه گیری
۶۵	۲-۵- پیشنهادات برای توسعه آینده

منابع ۶۷

۱ فهرست برنامه‌ها و جزئیات بازتولید ۷۳

۷۳	۱-۱- مشخصات محیط توسعه و اجرای نهایی
۷۴	۲-۱- محیط نرم افزاری ثبت شده
۷۵	۳-۱- مدل های عملیاتی
۷۵	۴-۱- تنظیمات ارزیابی ASR
۷۵	۵-۱- تنظیمات انتشار خطا
۷۶	۶-۱- تنظیمات آزمایش پیش پردازش صوت
۷۶	۷-۱- تنظیمات N-best و عدم قطعیت
۷۶	۸-۱- تنظیمات ارزیابی مدل زبانی و TTS
۷۷	۹-۱- فرمان های اصلی بازتولید
۷۸	۱۰-۱- جریان اجرا و شبه کد سامانه
۷۸	۱۱-۱- جریان اصلی برنامه
۷۹	۱۲-۱- شبه کد یک نوبت کامل

۸۰	 ۱-۱۳-شبه کد کنترل ابهام
۸۰	 ۱-۱۴-نمونه مکالمه رفع ابهام
۸۲	 ۱-۱۵-ساختار خروجی و معیارها

فهرست تصاویر

۲-۱	معماری پیش‌آموزش ویو ۲ و ۲؛ برگرفته از [۱]	۱۱
۲-۲	معماری مرجع ترنسفورمر و شاخه رمزگشای آن؛ برگرفته از [۲]	۱۶
۲-۳	مسیرهای آموزش و استنتاج معماری ویتس؛ برگرفته از [۳]	۲۱
۲-۴	چارچوب ارزیابی وظیفه‌محور تشخیص گفتار در کاربردهای مبتنی بر مدل زبانی؛ بازطراحی شده بر اساس [۴]	۳۱
۳-۱	گردش کار و جریان تصمیم یک نوبت در چت‌بات فارسی	۳۶
۴-۱	روش ارزیابی کیفیت، بازشناسی‌پذیری و کارایی زمانی مدل‌های تبدیل متن به گفتار	۵۱
۴-۲	خلاصه مقایسه مدل‌های تبدیل متن به گفتار از نظر کیفیت، بازشناسی مجدد و سرعت . . .	۵۳
۴-۳	ساختار ارزیابی انتشار خطا از تشخیص گفتار به پاسخ مدل زبانی	۵۴
۱-۱	نمایه مصرف منابع و تأخیر مسیر انتهابه‌انتهای چت‌بات فارسی	۷۴

فهرست جداول

۲-۱	وضعیت پیش‌آموزش و ریزتنظیم مدل‌های تشخیص گفتار ارزیابی شده	۱۰
۲-۲	ارتباط گروه‌های پژوهشی با تصمیم‌های پروژه حاضر	۳۲
۳-۱	تنظیمات پیش‌فرض خط لوله اجرایی	۴۰
۴-۱	نتایج تشخیص گفتار روی مجموعه فارسی کامن‌ویس نسخه ۲۵	۴۸
۴-۲	نتایج تشخیص گفتار روی بخش فارسی مجموعه فلورز	۴۹
۴-۳	دقت مدل‌های زبانی در وظیفه چندگزینه‌ای پارسی‌ان‌ال‌یو	۴۹
۴-۴	نتایج درک مطلب فارسی	۵۰
۴-۵	نتایج کیفیت ادراکی مدل‌های تبدیل متن به گفتار	۵۱
۴-۶	بازشناسی مجدد و زمان نمونه‌ای مدل‌های تبدیل متن به گفتار	۵۲
۴-۷	کارایی زمانی تجمیعی مدل‌های تبدیل متن به گفتار	۵۲
۴-۸	اثر کیفیت تشخیص گفتار بر پاسخ گما ۲ با ۹ میلیارد پارامتر	۵۵
۴-۹	مقایسه پیش‌بینی‌کننده‌های شکست پایین‌دستی	۵۵
۴-۱۰	آزمایش زوجی تقویت صوت کم‌دامنه	۵۶
۴-۱۱	ظرفیت و خطر انتخاب فرضیه‌های چندگانه	۵۷
۴-۱۲	نتایج بازیابی زمینه‌ای فرضیه‌های چندگانه	۵۷
۴-۱۳	اثر پایین‌دستی بازیابی زمینه‌ای	۵۸
۴-۱۴	نتیجه انتخاب پارامتر تقویت صوت	۵۸
۴-۱۵	انتخاب آستانه اطمینان و شکاف فرضیه	۵۹
۱-۱	مشخصات محیط توسعه و اجرای محلی	۷۳
۱-۲	نسخه کتابخانه‌های محیط اجرای محلی	۷۴
۱-۳	مدل‌های خط لوله نهایی	۷۵

فهرست مخفف‌ها

اختصار	عبارت انگلیسی	معادل یا توضیح فارسی
ASR	Automatic Speech Recognition	تشخیص خودکار گفتار
CER	Character Error Rate	نرخ خطای نویسه
CPU	Central Processing Unit	واحد پردازش مرکزی
CTC	Connectionist Temporal Classification	طبقه‌بندی زمانی پیوندگرا
GPU	Graphics Processing Unit	واحد پردازش گرافیکی
LLM	Large Language Model	مدل زبانی بزرگ
MFCC	Mel-Frequency Cepstral Coefficients	ضرایب کپسترال فرکانس مل
MOS	Mean Opinion Score	میانگین امتیاز ارزیابی ادراکی
NISQA	Non-Intrusive Speech Quality Assessment	ارزیابی بدون مرجع کیفیت گفتار
NLP	Natural Language Processing	پردازش زبان طبیعی
ONNX	Open Neural Network Exchange	قالب تبادل مدل شبکه عصبی
PCM	Pulse-Code Modulation	مدولاسیون کد پالس
RMS	Root Mean Square	ریشه میانگین مربعات
RNN-T	Recurrent Neural Network Transducer	ترنسدیوسر شبکه عصبی بازگشتی
RTF	Real-Time Factor	ضریب زمان واقعی
SNR	Signal-to-Noise Ratio	نسبت سیگنال به نویز

اختصار	عبارت انگلیسی	معادل یا توضیح فارسی
STFT	Short-Time Fourier Transform	تبدیل فوریه کوتاه‌زمان
TTS	Text-to-Speech	تبدیل متن به گفتار
VAD	Voice Activity Detection	تشخیص فعالیت صوتی
WER	Word Error Rate	نرخ خطای واژه

فصل ۱

مقدمه

۱-۱- بیان مسئله و هدف پروژه

پیشرفت سریع روش‌های هوش مصنوعی در حوزه‌های پردازش گفتار و پردازش زبان طبیعی، امکان توسعه سامانه‌هایی را فراهم کرده است که تعامل انسان و رایانه را از رابط‌های متنی متداول به سمت تعامل طبیعی‌تر مبتنی بر گفتار هدایت می‌کنند. در یک سامانه گفت‌وگوی صوتی، کاربر می‌تواند درخواست خود را مستقیماً از طریق گفتار بیان کند و پاسخ سامانه را نیز به صورت صوتی دریافت نماید. پیاده‌سازی چنین سامانه‌ای نیازمند همکاری چند مؤلفه مستقل در زمینه پردازش صوت، تشخیص گفتار، درک و تولید زبان و تولید گفتار است.

هدف اصلی این پروژه، طراحی و پیاده‌سازی یک چت‌بات صوتی فارسی است که بتواند چرخه کامل دریافت گفتار کاربر، تبدیل آن به متن، تولید پاسخ متنی و تبدیل پاسخ به گفتار را به صورت یکپارچه اجرا کند. معماری پایه سامانه از سه مؤلفه اصلی تشکیل شده است: سامانه تشخیص خودکار گفتار^۱ برای تبدیل صوت ورودی به متن، یک مدل زبانی بزرگ^۲ برای پردازش درخواست و تولید پاسخ، و سامانه تبدیل متن به گفتار^۳ برای تبدیل پاسخ متنی تولیدشده به گفتار فارسی.

یکی از اهداف اصلی پروژه، امکان اجرای این چرخه به صورت محلی بر روی یک رایانه شخصی است. اجرای محلی سامانه موجب کاهش وابستگی به سرویس‌های پردازشی خارجی شده و امکان کنترل بیشتر بر نحوه پردازش داده‌ها، مصرف منابع محاسباتی و تأخیر سامانه را فراهم می‌کند. در نتیجه، انتخاب مدل‌ها در این پروژه صرفاً بر اساس کیفیت خروجی انجام نمی‌شود و معیارهایی نظیر دقت، سرعت استنتاج، مصرف حافظه و امکان اجرا بر روی سخت‌افزار شخصی نیز مورد توجه قرار می‌گیرند.

برای انتخاب مؤلفه مناسب در هر مرحله، چندین مدل به صورت مستقل مورد ارزیابی قرار گرفته‌اند. در بخش

^۱Automatic Speech Recognition (ASR)

^۲Large Language Model (LLM)

^۳Text-to-Speech (TTS)

تشخیص خودکار گفتار، مدل‌هایی بر پایه ویو ۲ و یکس‌ال‌اس‌آر، ویسپر، واسک و فست‌کانفورمر نمو مورد آزمایش قرار گرفته‌اند. معماری ویو ۲ و یکس‌ال‌اس‌آر بر یادگیری خودنظارتی بازنمایی‌های گفتاری استوار است [۱] و نسخه چندزبانه یکس‌ال‌اس‌آر این رویکرد را به یادگیری بازنمایی میان‌زبانی گسترش می‌دهد [۵]. مدل ویسپر نیز بر اساس آموزش گسترده چندزبانه و چندوظیفه‌ای توسعه یافته است [۶]. همچنین معماری کانفورمر با ترکیب سازوکار توجه و کانولوشن، یکی از معماری‌های مهم مورد استفاده در سامانه‌های جدید تشخیص گفتار محسوب می‌شود [۷].

در بخش مدل زبانی، چند مدل قابل اجرای محلی شامل گما ۲، کوئن ۵.۲ و درنا ۲ بر پایه لاما ۱.۳ از نظر کیفیت پاسخ، زمان تولید، نرخ تولید توکن و مصرف حافظه مورد مقایسه قرار گرفته‌اند. شرط اولیه انتخاب این مدل‌ها آن بود که نسخه چهاربیتی آن‌ها بتواند به‌طور کامل در حافظه یک پردازنده گرافیکی محلی بارگذاری و بدون وابستگی به سرویس ابری اجرا شود. در بخش تبدیل متن به گفتار نیز چند سامانه فارسی از جمله کامترا مبتنی بر ویتس، ام‌ام‌اس و پایپر از نظر کیفیت ادراکی، قابل فهم بودن گفتار و سرعت تولید صوت ارزیابی شده‌اند. روش دقیق ارزیابی و نتایج عددی این مقایسه‌ها در فصل آزمایش‌ها و نتایج ارائه خواهد شد.

با توجه به ماهیت زنجیره‌ای این معماری، کیفیت سامانه نهایی صرفاً تابعی از عملکرد مستقل هر مؤلفه نیست. خطای ایجادشده در یک مرحله می‌تواند به مراحل بعدی منتقل شود. برای مثال، تشخیص نادرست یک یا چند واژه در مؤلفه تشخیص گفتار ممکن است مفهوم جمله ورودی را تغییر دهد و در نتیجه بر پاسخ مدل زبانی اثر بگذارد. به همین ترتیب، حتی در صورت تولید پاسخ متنی مناسب، کیفیت پایین خروجی تبدیل متن به گفتار می‌تواند فهم پاسخ توسط کاربر را دشوار سازد. از این‌رو، علاوه بر ارزیابی مستقل اجزا، ارزیابی عملکرد انتهابه‌انتهای سامانه نیز یکی از اهداف اصلی پروژه محسوب می‌شود.

یکی دیگر از مسائل مهم در یک سامانه گفت‌وگوی صوتی، تأخیر پاسخ‌گویی است. فاصله زمانی زیاد میان پایان گفتار کاربر و شروع پاسخ صوتی می‌تواند طبیعی بودن مکالمه را کاهش دهد. بنابراین، در کنار معیارهای کیفیت، معیارهایی مانند ضریب زمان واقعی^۴ و زمان تأخیر استنتاج برای مقایسه مدل‌ها مورد استفاده قرار گرفته‌اند. در نسخه نهایی، علاوه بر زمان کل مراحل، زمان نخستین توکن، نخستین عبارت و نخستین صوت نیز ثبت می‌شود تا تأخیر ادراکی معماری جریانی قابل بررسی باشد. گردآوری توزیع این زمان‌ها روی مجموعه بزرگ‌تری از مکالمات طبیعی به‌عنوان ارزیابی نهایی باقی مانده است.

معماری سامانه به‌صورت ماژولار در نظر گرفته شده است؛ به این معنا که مؤلفه‌های اصلی تا حد امکان وابستگی مستقیم کمی به پیاده‌سازی داخلی یکدیگر داشته باشند. این طراحی امکان جایگزینی یک مدل تشخیص گفتار، مدل زبانی یا سامانه تبدیل متن به گفتار را بدون بازنویسی کامل خط لوله فراهم می‌کند. چنین ساختاری علاوه بر تسهیل آزمایش مدل‌های مختلف، امکان توسعه و نگهداری ساده‌تر سامانه در آینده را نیز فراهم می‌سازد.

^۴Real-Time Factor (RTF)

علاوه بر سه مؤلفه اصلی، یک سامانه گفت‌وگوی صوتی کاربردی به قابلیت‌های تکمیلی دیگری نیز نیاز دارد. از جمله این موارد می‌توان به تشخیص فعالیت صوتی^۵ برای تعیین شروع و پایان گفتار، پردازش نویز محیط، پس‌پردازش متن و علائم نگارشی، و حفظ تاریخچه مکالمه برای پشتیبانی از گفت‌وگوی چندمرحله‌ای اشاره کرد. در نسخه نهایی، مدل سیلرو، تقویت انتخابی صوت‌های کم‌دامنه، نرمال‌سازی محافظه‌کارانه متن، تاریخچه شش‌نوبتی و حافظه اصلاح زمینه‌ای پیاده‌سازی شده‌اند. افزون بر آن، اختلاف‌های مهم فرضیه‌های چند فرضیه‌بازشناسی پیش از فراخوانی مدل زبانی به رفع ابهام هدفمند هدایت می‌شوند.

برای تحقق هدف اصلی پروژه، اهداف اجرایی زیر تعریف شده‌اند:

- طراحی و پیاده‌سازی یک خط لوله انتهابه‌انتهای برای تبدیل گفتار فارسی کاربر به پاسخ صوتی فارسی.
- ارزیابی و مقایسه چند مدل تشخیص گفتار فارسی از نظر دقت، سرعت استنتاج و مصرف منابع محاسباتی.
- ارزیابی چند مدل زبانی قابل اجرای محلی از نظر کیفیت پاسخ، سرعت تولید و مصرف حافظه.
- ارزیابی چند سامانه تبدیل متن به گفتار فارسی از نظر کیفیت ادراکی، قابل‌فهم‌بودن گفتار و سرعت تولید.
- انتخاب ترکیب مناسب مدل‌های تشخیص گفتار، مدل زبانی بزرگ و تبدیل متن به گفتار با در نظر گرفتن هم‌زمان کیفیت و هزینه محاسباتی.
- طراحی معماری ماژولار به‌منظور فراهم‌کردن امکان جایگزینی مستقل مؤلفه‌های اصلی سامانه.
- توسعه قابلیت حفظ بافت و تاریخچه مکالمه برای پشتیبانی از گفت‌وگوهای چندمرحله‌ای.
- بررسی و افزودن پردازش‌هایی مانند تشخیص فعالیت صوتی، مدیریت نویز و پس‌پردازش متن برای افزایش پایداری سامانه.
- اندازه‌گیری تأخیر هر یک از مؤلفه‌ها و تأخیر انتهابه‌انتهای سامانه.
- فراهم‌کردن امکان اجرای سامانه بر روی یک رایانه شخصی بدون وابستگی دائمی به سرویس‌های پردازشی خارجی.

دامنه این پروژه بر تعامل صوتی به زبان فارسی متمرکز است. هدف پروژه، آموزش یک مدل پایه تشخیص گفتار، مدل زبانی بزرگ یا مدل تبدیل متن به گفتار از ابتدا نیست؛ بلکه تمرکز اصلی بر ارزیابی، انتخاب و یکپارچه‌سازی مدل‌های موجود و ایجاد یک سامانه عملیاتی بر پایه آن‌ها قرار دارد.

^۵Voice Activity Detection (VAD)

همچنین هدف این پروژه توسعه یک دستیار صوتی تجاری در مقیاس بزرگ یا سامانه‌ای برای پاسخ‌گویی هم‌زمان به تعداد زیادی کاربر نیست. موضوعاتی مانند زیرساخت ابری گسترده، احراز هویت گوینده، مقیاس‌پذیری سازمانی و طراحی یک رابط گرافیکی کامل خارج از دامنه اصلی پروژه قرار دارند. تمرکز اصلی بر توسعه یک نمونه عملیاتی محلی، ارزیابی علمی اجزای آن و بررسی قابلیت استفاده از ترکیب مدل‌های انتخاب‌شده در یک سامانه مکالمه صوتی فارسی است.

۲-۱- کاربردها و اهمیت عملی

تعامل صوتی یکی از طبیعی‌ترین شیوه‌های ارتباط انسان است و استفاده از آن به‌عنوان رابط میان کاربر و سامانه‌های هوشمند می‌تواند نیاز به تعامل مستقیم با صفحه‌کلید یا رابط‌های گرافیکی را کاهش دهد. این ویژگی به‌ویژه در شرایطی که کاربر امکان تایپ کردن ندارد یا استفاده از دست برای تعامل با سامانه دشوار است، اهمیت بیشتری پیدا می‌کند.

یکی از کاربردهای مستقیم سامانه پیشنهادی، راهنماهای صوتی هوشمند است. در چنین کاربردی، کاربر می‌تواند پرسش خود را به زبان فارسی و به‌صورت طبیعی بیان کرده و بدون نیاز به مشاهده نمایشگر، پاسخ صوتی دریافت کند. این قابلیت می‌تواند در سامانه‌های راهنما، کیوسک‌های اطلاع‌رسانی، راهنمای خدمات و دستیارهای شخصی مورد استفاده قرار گیرد.

حوزه دیگر، پشتیبانی مشتری است. بخش قابل توجهی از پرسش‌های کاربران در سامانه‌های پشتیبانی شامل درخواست‌های تکرارشونده و قابل پاسخ‌گویی از طریق یک سامانه خودکار است. ترکیب تشخیص گفتار، مدل زبانی و تولید گفتار می‌تواند امکان ایجاد یک رابط مکالمه‌ای را فراهم کند که پرسش کاربر را دریافت کرده، پاسخ متنی مناسب را تولید کند و نتیجه را به‌شکل صوتی ارائه دهد. در صورت اتصال چنین سامانه‌ای به منابع اطلاعاتی اختصاصی، دامنه کاربرد آن می‌تواند به دستیارهای پشتیبانی تخصصی نیز گسترش یابد.

کاربرد دیگر سامانه در آموزش است. یک رابط مکالمه‌ای فارسی می‌تواند به‌عنوان دستیار آموزشی مورد استفاده قرار گیرد تا فراگیر بتواند پرسش‌های خود را به‌صورت صوتی مطرح کند و پاسخ متناسب دریافت نماید. ماهیت گفت‌وگومحور چنین سامانه‌ای همچنین امکان توسعه تعاملات چندمرحله‌ای، پرسش و پاسخ و توضیح تدریجی مفاهیم را فراهم می‌کند.

اهمیت عملی این پروژه تنها به کیفیت خروجی مدل‌ها محدود نمی‌شود. یکی از محورهای اصلی، بررسی امکان اجرای یک سامانه کامل زنجیره تشخیص گفتار، مدل زبانی و تبدیل متن به گفتار بر روی سخت‌افزار شخصی است. مدل‌هایی که کیفیت بالایی دارند ممکن است از نظر حافظه یا زمان استنتاج برای اجرای محلی مناسب نباشند. بنابراین، بررسی هم‌زمان کیفیت، سرعت و مصرف منابع می‌تواند به انتخاب معماری واقع‌بینانه‌تری برای کاربردهای

عملی منجر شود.

اجرای محلی همچنین می‌تواند در کاربردهایی که اتصال پایدار به اینترنت در دسترس نیست یا استفاده دائمی از سرویس‌های ابری مطلوب نیست، مفید باشد. از این‌رو، دستیابی به یک ترکیب مناسب از مدل‌های نسبتاً سبک، دقیق و سریع یکی از جنبه‌های کاربردی مهم این پروژه محسوب می‌شود.

پرسش‌های پژوهش

با توجه به اهداف پروژه و ماهیت چندمرحله‌ای سامانه، پرسش‌های پژوهش به‌گونه‌ای تعریف شده‌اند که هم عملکرد مستقل مؤلفه‌ها و هم عملکرد سامانه یکپارچه را مورد بررسی قرار دهند.

انتخاب مدل تشخیص گفتار

• پرسش پژوهش ۱: کدام مدل تشخیص خودکار گفتار، مناسب‌ترین توازن میان دقت تشخیص، سرعت استنتاج و مصرف منابع محاسباتی را برای یک چت‌بات صوتی فارسی محلی فراهم می‌کند؟

برای پاسخ به این پرسش، مدل‌های مختلف تشخیص گفتار بر اساس معیارهایی نظیر نرخ خطای واژه^۶، نرخ خطای نویسه^۷، ضریب زمان واقعی، تأخیر متوسط و مصرف حافظه گرافیکی مورد مقایسه قرار می‌گیرند.

انتخاب مدل زبانی

• پرسش پژوهش ۲: کدام مدل زبانی قابل اجرای محلی، مناسب‌ترین توازن میان کیفیت معنایی پاسخ، زمان پاسخ‌گویی و مصرف حافظه را برای استفاده در سامانه فراهم می‌کند؟

در این بخش، مدل‌ها از نظر معیارهای کیفیت متنی و همچنین ویژگی‌های اجرایی مانند زمان پاسخ، نرخ تولید توکن و مصرف حافظه مقایسه می‌شوند.

انتخاب مدل تبدیل متن به گفتار

• پرسش پژوهش ۳: کدام سامانه تبدیل متن به گفتار فارسی، مناسب‌ترین توازن میان کیفیت ادراکی صوت، قابل‌فهم‌بودن گفتار و سرعت تولید را ارائه می‌دهد؟

برای پاسخ به این پرسش، کیفیت ادراکی مدل‌های تبدیل متن به گفتار به همراه معیارهای مرتبط با قابل‌فهم‌بودن خروجی و زمان اجرای مدل بررسی می‌شود.

^۶Word Error Rate (WER)

^۷Character Error Rate (CER)

عملکرد انتهابه‌انتهای سامانه

- پرسش پژوهش ۴: ترکیب مؤلفه‌های منتخب در یک خط لوله زنجیره تشخیص گفتار، مدل زبانی و تبدیل متن به گفتار چه تأخیر انتهابه‌انتهایی ایجاد می‌کند و آیا این تأخیر برای یک تعامل مکالمه‌ای قابل قبول است؟

این پرسش علاوه بر زمان پردازش مستقل هر مؤلفه، کل فاصله زمانی میان دریافت گفتار کاربر و تولید پاسخ صوتی سامانه را مورد توجه قرار می‌دهد.

پایداری تعامل و بافت مکالمه

- پرسش پژوهش ۵: افزودن مؤلفه‌هایی مانند تشخیص فعالیت صوتی، پردازش نویز و مدیریت بافت مکالمه چه تأثیری بر پایداری و کیفیت تعامل با سامانه دارد؟

این پرسش با آزمون زوجی پیش‌پردازش صوت، مجموعه رگرسیون چندنوبتی و آزمایش بازیابی زمینه‌ای بررسی شده است. تعمیم نتیجه به جمعیت کاربران به مجموعه مهر و موم شده‌ای از مکالمات صوتی طبیعی نیاز دارد.

۳-۱- ساختار گزارش

این گزارش در پنج فصل تنظیم شده است.

فصل اول به معرفی مسئله، اهداف و دامنه پروژه، کاربردها و اهمیت عملی، پرسش‌های پژوهش و ساختار کلی گزارش اختصاص دارد.

فصل دوم مفاهیم لازم برای درک پروژه و پژوهش‌های مرتبط را پوشش می‌دهد. در این فصل مبانی پردازش گفتار، تشخیص خودکار گفتار، مدل‌های زبانی بزرگ، تبدیل متن به گفتار، کنترل نوبت مکالمه و معیارهای ارزیابی تعریف و سپس رویکردهای پیشین مقایسه می‌شوند.

فصل سوم شرح پروژه است و طراحی و پیاده‌سازی سامانه را یکجا ارائه می‌کند. معماری ماژولار، گردش کار یک نوبت، آماده‌سازی صوت، کنترل ابهام، حافظه مکالمه، تولید پاسخ و تولید گفتار جریانی در این فصل تشریح می‌شوند.

فصل چهارم روش آزمایش، نتایج و تحلیل آن‌ها را در بر می‌گیرد. ارزیابی مستقل مدل‌های تشخیص گفتار، مدل‌های زبانی و تبدیل متن به گفتار، آزمون انتشار خطا و آزمایش‌های تکمیلی سامانه در این فصل گزارش می‌شوند. فصل پنجم نتیجه‌گیری نهایی و پیشنهادهای توسعه آینده را ارائه می‌کند. پس از آن، منابع و پیوست فهرست برنامه‌ها و جزئیات بازتولید آورده شده‌اند.

فصل ۲

مفاهیم

۲-۱- مقدمه

در بستر سامانه‌های مکالمه صوتی و با تأکید بر پردازش زبان فارسی، این فصل به مبانی نظری مورد نیاز برای درک توسعه یک دستیار صوتی محلی مبتنی بر ادغام بازشناسی خودکار گفتار، مدل زبانی بزرگ و تبدیل متن به گفتار می‌پردازد. ابتدا قرارداد خط لوله صوتی و خروجی ساخت‌یافته مدل تشخیص گفتار معرفی می‌شوند؛ از جمله متن اصلی، اطمینان واژه‌ها و فرضیه‌های چندگانه. سپس خانواده مدل‌های بازشناسی گفتار و معیارهای نرخ خطای واژه، نرخ خطای نویسه، ضریب زمان واقعی و تأخیر مرور خواهند شد. در ادامه، نقش مدل زبانی در تولید پاسخ، مدیریت پنجره بافت، کوانتیزه‌سازی و معیارهای سنجش کیفیت پاسخ بررسی می‌شود. پس از آن، مدل‌ها و معیارهای کیفیت، بازشناسی‌پذیری و کارایی زمانی تبدیل متن به گفتار توضیح داده می‌شوند. در پایان نیز تشخیص فعالیت صوتی، انتشار خطا میان اجزای زنجیره، رفع ابهام و حافظه مکالمه مطرح خواهند شد تا مبنای لازم برای درک معماری و آزمایش‌های فصل‌های بعد فراهم شود.

۲-۲- قرارداد خط لوله صوتی

۲-۲-۱- بازنمایی دیجیتال گفتار

ورودی سامانه، جریان صوت تک‌کاناله با نرخ نمونه‌برداری ۱۶ kHz است. این مشخصات برای مدل‌های گفتاری پروژه یک قرارداد عملیاتی محسوب می‌شود، نه موضوعی برای تحلیل نظری سیگنال. صوت میکروفن ابتدا به قطعه‌های کوتاه تقسیم می‌شود تا تشخیص فعالیت صوتی بتواند شروع و پایان نوبت را تعیین کند. قطعه نهایی سپس به قالب مورد انتظار مدل تشخیص گفتار تبدیل می‌شود.

سیگنال گفتار در رایانه به صورت دنباله‌ای از نمونه‌های دامنه نمایش داده می‌شود. نرخ نمونه‌برداری تعداد این اندازه‌گیری‌ها در هر ثانیه را مشخص می‌کند و باید با نرخ مورد انتظار مدل سازگار باشد. اگر فایل یا میکروفن نرخ

دیگری داشته باشد، پیش از ورود به مدل باز نمونه برداری می‌شود. انجام این تبدیل در یک نقطه ثابت از خط لوله مانع از آن است که هر مدل نسخه‌ای متفاوت از صوت را دریافت کند و مقایسه نتایج تحت تأثیر پیش‌پردازش قرار گیرد.

تک‌کاناله کردن نیز برای یکسان‌سازی ورودی ضروری است. در صوت چندکاناله، هر کانال ممکن است دامنه یا نویز متفاوتی داشته باشد و انتخاب یا ترکیب نامناسب کانال‌ها بخشی از گفتار را تضعیف کند. پس از تبدیل کانال و نرخ نمونه برداری، نمونه‌ها در قالب عددی مورد انتظار مدل ذخیره می‌شوند. دامنه این اعداد باید کنترل شود تا از برش قله‌های موج یا بسیار کم‌دامنه شدن سیگنال جلوگیری شود.

مدل‌های گفتاری ورودی یکسان را الزاماً به شکل یکسان مصرف نمی‌کنند. برخی مدل‌ها ابتدا قاب‌های کوتاه را به ویژگی‌های زمانی و فرکانسی تبدیل می‌کنند تا انرژی موجود در نوارهای فرکانسی مختلف آشکار شود. طیف‌نگاشت مل فرکانس‌ها را با تفکیکی نزدیک‌تر به ادراک انسان نمایش می‌دهد و ورودی مدل‌هایی مانند ویسپر است. در مقابل، خانواده ویو ۲ و ۲ک ویژگی‌های اولیه را با لایه‌های کانولوشنی مستقیماً از شکل موج می‌آموزد. بنابراین آماده‌سازی مشترک صوت باید تا پیش از پیش‌پردازش اختصاصی هر مدل یکسان باشد، نه آنکه همه مدل‌ها مجبور به استفاده از یک نوع ویژگی داخلی شوند.

برای پردازش برخط، کل نوبت از ابتدا در دسترس نیست. جریان صوت به قاب‌های کوتاه تقسیم می‌شود و هر قاب برای تشخیص وجود گفتار بررسی می‌گردد. در عین حال، چند قاب اخیر در یک بافر نگه داشته می‌شوند تا پس از تشخیص شروع گفتار، بخش ابتدایی واژه از دست نرود. بنابراین قطعه‌بندی فقط یک عملیات فنی روی فایل نیست و مستقیماً مرز متن ورودی به بازشناسی گفتار را تعیین می‌کند.

۲-۲-۲- رابط داده میان مؤلفه‌ها

خروجی بازشناسی گفتار در این پروژه فقط یک رشته متنی نیست و سه نوع شاهد را شامل می‌شود:

- متن اصلی که رمزگشا آن را بهترین خروجی دانسته است؛
 - اطمینان واژه‌ها که برای یافتن بخش‌های نامطمئن به کار می‌رود؛
 - و چند فرضیه جایگزین یا فرضیه‌های چندگانه که امکان مقایسه انتخاب‌های نزدیک رمزگشا را فراهم می‌کند.
- این تمایز برای کنترل مکالمه ضروری است. اطمینان پایین به تنهایی مشخص نمی‌کند کدام واژه درست است و اطمینان بالا نیز تضمین نمی‌کند که نام، عدد یا نفی به درستی تشخیص داده شده باشد. سامانه با ترکیب اطمینان، اختلاف فرضیه‌ها و زمینه مکالمه یکی از سه عمل پاسخ‌گویی، رفع ابهام یا درخواست تکرار را انتخاب می‌کند. تنها در مسیر پاسخ‌گویی، متن به مدل زبانی فرستاده می‌شود.

این قرارداد ساخت‌یافته باعث می‌شود مدل بازشناسی و منطق مکالمه به یکدیگر وابستگی مستقیم نداشته باشند. هر پیاده‌سازی تشخیص گفتار تا زمانی قابل جایگزینی است که متن، اطلاعات اطمینان و فرضیه‌ها را در قالب مشترک تحویل دهد. به همین ترتیب، مدل زبانی فقط متن تأییدشده و زمینه لازم را دریافت می‌کند و لازم نیست از قالب داخلی رمزگشای صوت آگاه باشد. این جداسازی امکان آزمون مستقل هر مؤلفه و ردیابی محل ایجاد خطا را فراهم می‌سازد.

۲-۳- تشخیص گفتار و معیارهای آن

۲-۳-۱- خانواده مدل‌های بررسی‌شده

مدل‌های تشخیص گفتار آزمایش‌شده در پروژه از چند خانواده متفاوت‌اند. ویو۲وک ۲ بازنمایی گفتار را با پیش‌آموزش خودنظارتی روی شکل موج می‌آموزد و ایکس‌ال‌اس آر همین ایده را برای انتقال میان زبان‌ها گسترش می‌دهد [۵، ۱]. مدل ویسپر با آموزش نظارت‌شده چندزبانه و رمزگشایی دنباله‌ای، یک رابط عمومی برای بازشناسی و چند وظیفه گفتاری فراهم می‌کند [۶]. معماری کانفورمر وابستگی‌های دوربرد را با مدل‌سازی محلی صوت ترکیب می‌کند و فست کانفورمر با کاهش هزینه محاسباتی برای استنتاج سریع‌تر طراحی شده است [۷، ۸]. در مقابل، واسک یک رابط اجرای آفلاین بر پایه ابزارهای کلدی است [۹]. اهمیت آن برای این پروژه فقط دقت متن نیست؛ اجرای کامل روی پردازنده مرکزی، ارائه اطمینان واژه و دسترسی به فرضیه‌های جایگزین، آن را برای کنترل ابهام مناسب می‌کند. بنابراین انتخاب مدل عملیاتی الزاماً برابر با انتخاب کمترین خطا در یک مجموعه آزمون نیست.

۲-۳-۲- پیش‌آموزش و ریزتنظیم مدل‌های ارزیابی‌شده

برای تفسیر منصفانه نتایج باید میان پیش‌آموزش عمومی، ریزتنظیم برای فارسی و مجموعه‌ای که فقط برای ارزیابی به کار رفته است تمایز گذاشت. جدول ۱-۲ این وضعیت را برای نقطه‌وارسی‌های دقیق استفاده‌شده در پروژه خلاصه می‌کند. هیچ‌یک از این مدل‌ها در این پروژه دوباره آموزش یا ریزتنظیم نشده‌اند و همان وزن‌های منتشرشده ارزیابی شده‌اند.

جدول ۲-۱ وضعیت پیش‌آموزش و ریزتنظیم مدل‌های تشخیص گفتار ارزیابی شده

مدل دقیق	وضعیت سازگارسازی با فارسی	داده فارسی اعلام شده
STT Fa FastConformer Hybrid Transducer-CTC Large	آغاز از نقطه‌وارسی انگلیسی و سپس ریزتنظیم برای فارسی	بخش فارسی Mozilla Common Voice 15.0 با تقسیم‌بندی سفارشی [۱۰]
Wav2Vec2 Large XLSR Persian v3	ریزتنظیم فارسی مدل پایه چندزبانه XLSR-53	بخش فارسی Common Voice 6.1 [۱۱]
Whisper large-v3	مدل ازپیش‌آموزش دیده چندزبانه، بدون ریزتنظیم اختصاصی فارسی	داده چندزبانه گسترده؛ زیرمجموعه فارسی به صورت مستقل اعلام نشده است [۱۲]
Vosk fa-0.42	نقطه‌وارسی اختصاصی فارسی؛ سابقه مدل پایه و نوع ریزتنظیم در مستند رسمی مشخص نشده است	مجموعه آموزش در فهرست رسمی مدل‌ها اعلام نشده است [۱۳]


نام کامل مدل نمو در جدول ۲-۱ آمده است. این مدل از یک نقطه‌وارسی انگلیسی مقداردهی اولیه و سپس با بخش فارسی کامن‌ویس نسخه ۱۵ ریزتنظیم شده است [۱۰]. دو ردیف طبقه‌بندی زمانی پیوندگرا و ترنس‌دیوسر در نتایج فصل چهارم دو مدل آموزش دیده مستقل نیستند، بلکه دو سر رمزگشایی همین نقطه‌وارسی مشترک‌اند. مدل ویو۲وک ۲ فارسی نیز نسخه‌ای از ایکس‌ال‌اس‌آر با پیش‌آموزش روی ۵۳ زبان است که با بخش فارسی کامن‌ویس نسخه ۱۰۶ ریزتنظیم شده است [۱۱]. در مقابل، ویسپر بزرگ نسخه ۳ بدون ریزتنظیم فارسی استفاده شد. درباره مدل فارسی واسک نسخه ۴۲۰، صفحه رسمی تنها آن را مدل فارسی معرفی می‌کند و مجموعه‌های کامن‌ویس نسخه ۱۷ و فلورز را برای گزارش نتیجه می‌آورد؛ ازاین‌رو این دو مجموعه نباید داده آموزش آن تلقی شوند [۱۳].

این پیشینه بر تفسیر بنچمارک اثر دارد: آزمون کامن‌ویس نسخه ۲۵ برای دو مدل نخست آزمونی از همان خانواده پیکره‌های ریزتنظیم است، هرچند نسخه و تقسیم داده متفاوت است؛ اما فلورز تغییر دامنه روشن‌تری ایجاد می‌کند. بنابراین جابه‌جایی رتبه مدل‌ها میان این دو آزمون فقط یک اختلاف عددی نیست و بخشی از آن می‌تواند از میزان سازگاری داده آموزش و آزمون ناشی شود.

۲-۳-۳ معماری ویو۲وک ۲ و ایکس‌ال‌اس‌آر

در ویو۲وک ۲، شکل موج خام ابتدا از یک رمزگذار کانولوشنی عبور می‌کند تا دنباله‌ای کوتاه‌تر از بردارهای نهفته ساخته شود. یک شبکه ترنسفورمر سپس ارتباط هر بردار با بخش‌های دورتر گفتار را مدل‌سازی می‌کند. در مرحله پیش‌آموزش، بخشی از بردارها پوشانده می‌شوند و مدل باید نمایش درست آن‌ها را از میان گزینه‌های کوانتیزه‌شده تشخیص دهد؛ به این ترتیب، بدون نیاز به متن برچسب‌خورده برای همه صوت‌ها، ساختار آکوستیکی گفتار آموخته می‌شود [۱].

این مسیر در شکل ۲-۱ نمایش داده شده است: رمزگذار کانولوشنی شکل موج را به نمایش‌های نهفته تبدیل می‌کند، بخشی از این نمایش‌ها برای یادگیری خودنظارتی پوشانده می‌شوند و شبکه ترنسفورمر با استفاده از هدف تقابلی، بازنمایی زمینه‌ای را می‌آموزد.



شکل ۲-۱ معماری پیش‌آموزش ویو ۲ و ۲؛ برگرفته از [۱]

برای بازشناسی، یک سر خروجی به رمزگذار افزوده و مدل با داده دارای متن مرجع تنظیم می‌شود. نسخه‌های ایکس‌ال‌اس آر پیش‌آموزش را روی چند زبان انجام می‌دهند تا بخشی از الگوهای آکوستیکی میان زبان‌ها مشترک شود [۵]. مزیت این رویکرد برای فارسی، استفاده از دانش آموخته‌شده از حجم بزرگ داده چندزبانه است؛ با این حال، کیفیت نهایی همچنان به میزان شباهت داده تنظیم و آزمون، شیوه نرمال‌سازی متن و پوشش واژگان فارسی وابسته می‌ماند.

۲-۳-۴- معماری ویسپر

ورودی ویسپر به جای شکل موج مستقیم، به طیف‌نگاشت لگاریتمی مل تبدیل می‌شود. رمزگذار صوتی این نمایش زمانی و فرکانسی را به بردارهای زمینه‌ای تبدیل می‌کند و رمزگشای متنی، با توجه به خروجی رمزگذار و توکن‌های قبلی، توکن بعدی را به صورت خودبازگشتی پیش‌بینی می‌کند. توکن‌های کنترلی نیز زبان، نوع وظیفه و در برخی حالت‌ها اطلاعات زمانی را مشخص می‌کنند [۶].

وجود رمزگشای زبانی قوی می‌تواند در صوت دشوار به ساخت جمله‌ای روان کمک کند، اما روان بودن متن تضمین نمی‌کند که همه نام‌ها و اعداد موجود در صوت حفظ شده باشند. علاوه بر این، تولید خودبازگشتی به تصمیم‌های قبلی وابسته است و معمولاً نسبت به یک سر ساده طبقه‌بندی زمانی پیوندگرا محاسبه بیشتری نیاز

دارد. این ویژگی‌ها علت سنجش هم‌زمان دقت، تأخیر و خطاهای معنایی در بنچمارک پروژه هستند.

۲-۳-۵- معماری کانفورمر و فست کانفورمر

گفتار هم الگوهای محلی، مانند گذار کوتاه میان واج‌ها، و هم وابستگی‌های دورتر، مانند زمینه یک واژه در جمله، دارد. بلوک کانفورمر برای پوشش هر دو نوع وابستگی، توجه چندسری را با یک پیمانه کانولوشنی ترکیب می‌کند. شبکه‌های پیش‌خور، اتصال‌های باقی‌مانده و نرمال‌سازی نیز جریان اطلاعات و آموزش شبکه عمیق را پایدار می‌کنند [۷].

فست کانفورمر با زیرنمونه‌برداری شدیدتر و توجه کارآمدتر، طول دنباله میانی و در نتیجه هزینه محاسبات را کاهش می‌دهد [۸]. مدل دقیق بررسی‌شده، مدل بزرگ فست کانفورمر ترکیبی نمو، یک رمزگذار مشترک را با دو مسیر خروجی طبقه‌بندی زمانی پیوندگرا و ترنس‌دیوسر شبکه عصبی بازگشتی عرضه می‌کند [۱۰]. مسیر طبقه‌بندی زمانی پیوندگرا برای رمزگشایی سریع و مقایسه مستقیم مناسب است؛ مسیر ترنس‌دیوسر شبکه عصبی بازگشتی با واردکردن سابقه خروجی در پیش‌بینی، ظرفیت زبانی بیشتری دارد و برای حالت جریانی طراحی شده است. وجود دو سر خروجی به معنی یکسان بودن متن یا هزینه استنتاج آن‌ها نیست و هر مسیر باید جداگانه سنجیده شود.

۲-۳-۶- ساختار اجرایی واسک

واسک رابطی سبک برای اجرای مدل‌های ساخته‌شده با ابزارهای کلدی فراهم می‌کند. در این خانواده، احتمال‌های آکوستیکی با واژه‌نامه تلفظ و مدل زبان در یک گراف جست‌وجو ترکیب می‌شوند. رمزگشا در هر مرحله چند مسیر محتمل را نگه می‌دارد و مسیرهای ضعیف‌تر را برای محدود کردن هزینه محاسبات کنار می‌گذارد [۹]. نتیجه این جست‌وجو می‌تواند علاوه بر متن برتر، امتیاز واژه‌ها و چند مسیر جایگزین باشد.

این ساختار برای پروژه اهمیت عملی دارد، زیرا کنترل ابهام به اطلاعاتی بیش از متن نهایی نیازمند است. مدل واسک انتخاب‌شده روی پردازنده مرکزی اجرا می‌شود و رمزگشا امکان دریافت فرضیه‌های چندگانه را فراهم می‌کند. در مقابل، برخی مدل‌های عمیق‌تر ممکن است نرخ خطای واژه کمتری داشته باشند، اما رابط آماده آن‌ها اطلاعات لازم برای تصمیم‌گیری تعاملی را با همان جزئیات ارائه نکند.

۲-۳-۷- هم‌ترازی، رمزگشایی و اطمینان

مدل بازشناسی باید دنباله‌ای بلند از قاب‌های صوتی را به دنباله‌ای کوتاه‌تر از نویسه‌ها یا واژه‌ها تبدیل کند. تفاوت اصلی خانواده‌های ارزیابی‌شده در شیوه انجام این هم‌ترازی و استفاده از سابقه متنی است. در خروجی طبقه‌بندی زمانی پیوندگرا، نماد خالی و تکرار برجسب‌ها امکان نگاشت قاب‌های متعدد به یک متن کوتاه را فراهم می‌کنند و رمزگشایی را نسبتاً ساده نگه می‌دارند. در ترنس‌دیوسر شبکه عصبی بازگشتی، یک شبکه پیش‌بینی،

برچسب‌های قبلی را نیز در تصمیم بعدی دخالت می‌دهد؛ در نتیجه معماری برای پردازش جریانی مناسب است، اما مسیر رمزگشایی و محاسبه امتیاز پیچیده‌تر می‌شود [۱۴].

مدل‌های دنباله‌به‌دنباله مانند ویسپر متن را به‌صورت خودبازگشتی تولید می‌کنند و می‌توانند از بافت زبانی قوی‌تری بهره ببرند [۶]. در مقابل، سامانه‌های مبتنی بر گلدی مانند مدل اجرایی واسک از ترکیب مدل آکوستیکی، واژه‌نامه و گراف رمزگشایی استفاده می‌کنند [۹]. این تفاوت توضیح می‌دهد که چرا دو مدل با نرخ خطای واژه نزدیک، از نظر سرعت، امکان پردازش جریانی و دسترسی به فرضیه‌های جایگزین رفتار یکسانی ندارند.

امتیاز اطمینان نیز نباید احتمال قطعی درست‌بودن واژه تلقی شود. این امتیاز به معماری، رمزگشا و مقیاس داخلی مدل وابسته است و معمولاً برای مقایسه واژه‌ها و فرضیه‌های همان مدل مناسب‌تر از مقایسه مستقیم میان دو مدل است. در این پروژه، اطمینان پایین یک نشانه خطر است و همراه با شکاف امتیاز فرضیه‌ها و حساسیت معنایی واژه تفسیر می‌شود؛ بنابراین تصمیم رفع ابهام فقط با یک آستانه منفرد گرفته نمی‌شود.

۲-۳-۸- نرخ خطای واژه و نویسه

برای متن مرجع با N واژه، نرخ خطای واژه از تعداد جایگزینی‌ها (S)، حذف‌ها (D) و درج‌ها (I) محاسبه می‌شود:

$$\text{WER}(\%) = \frac{S + D + I}{N} \times 100. \quad (1.2)$$

نرخ خطای نویسه همین محاسبه را در سطح نویسه انجام می‌دهد:

$$\text{CER}(\%) = \frac{S_c + D_c + I_c}{N_c} \times 100. \quad (2.2)$$

در تمام فصل‌های نتایج، نرخ خطای واژه و نرخ خطای نویسه روی مقیاس صفر تا صد درصد گزارش می‌شوند و مقدار کمتر بهتر است. نرخ خطای واژه تفسیر مستقیم‌تری در سطح واژه دارد، اما نرخ خطای نویسه برای فارسی به تفاوت‌های املائی و خطاهای کوچک درون واژه حساس است. پیش از محاسبه، یکسان‌سازی نویسه‌های عربی و فارسی، فاصله‌ها و نشانه‌گذاری ضروری است؛ وگرنه تفاوت ظاهری می‌تواند به‌عنوان خطای مدل شمرده شود. این دو معیار همه خطاها را هم‌ارزش در نظر می‌گیرند. برای یک دستیار صوتی، حذف نام مکان، عدد یا واژه نفی ممکن است با وجود نرخ خطای واژه پایین، پاسخ را کاملاً تغییر دهد. به همین دلیل، پروژه علاوه بر خطای کلی، حفظ عبارت پاسخ و موفقیت مدل زبانی در مرحله پایین‌دستی را نیز بررسی می‌کند.

۲-۳-۹- نرمال سازی فارسی و سطح ارزیابی

پیش از محاسبه خطا باید متن مرجع و پیش بینی به یک قرارداد نوشتاری مشترک تبدیل شوند. برای نمونه، شکل عربی حروف «ی» و «ک» به شکل استاندارد فارسی همین حروف نگاشت می شود. تفاوت فاصله و نیم فاصله، اعراب و نشانه گذاری نیز می تواند دو متن هم معنا را از نظر مقایسه رشته ای متفاوت نشان دهد. نرمال سازی برای حذف این تفاوت های صوری لازم است، اما نباید آن قدر تهاجمی باشد که خطاهای واقعی مدل را پنهان کند. برای مثال، حذف یا جایگزینی عدد، نام خاص یا واژه نفی باید پس از نرمال سازی نیز قابل مشاهده بماند. سطح ارزیابی نیز بر نتیجه اثر دارد. نرخ خطای واژه جابه جایی مرز واژه ها را به عنوان خطا محاسبه می کند، در حالی که نرخ خطای نویسه در برابر برخی تفاوت های فاصله گذاری مقاوم تر است و شدت خطاهای درون واژه را بهتر نشان می دهد. به همین دلیل، این دو معیار در گزارش کنار یکدیگر آمده اند. برای سنجش اثر کاربردی نیز متن بازنمایی شده بدون اصلاح دستی وارد مدل زبانی می شود تا مشخص شود خطای نوشتاری تا چه اندازه پاسخ نهایی را تغییر می دهد.

۲-۳-۱۰- سرعت و تأخیر

ضریب زمان واقعی نسبت زمان پردازش به مدت صوت است:

$$RTF = \frac{T_{\text{processing}}}{T_{\text{audio}}}. \quad (3.2)$$

مقدار کمتر از یک یعنی پردازش سریع تر از زمان واقعی انجام شده است. ضریب افزایش سرعت را می توان به صورت $1/RTF$ بیان کرد. باین حال، ضریب زمان واقعی و تأخیر مترادف نیستند: یک مدل ممکن است در مجموع سریع باشد اما به دلیل بارگذاری، بافرکردن یا انتظار برای پایان ورودی، شروع پاسخ را به تأخیر اندازد. بنابراین در این گزارش زمان کل و نقاطی مانند نخستین توکن یا نخستین صوت جداگانه ثبت می شوند.

۲-۴- مدل زبانی در یک دستیار محلی

مدل های زبانی بررسی شده از نوع دستور محور و عمدتاً «فقط رمزگشا» هستند. متن تشخیص داده شده همراه با دستور سامانه و بخشی از تاریخچه به مدل داده می شود و پاسخ به صورت توکن به توکن تولید می شود. جزئیات عمومی توجه و آموزش ترنسفورمر در منابع پایه آمده است [۲]؛ برای این پروژه چهار ویژگی عملی مهم ترند: توانایی فارسی، پیروی از دستور، اندازه پنجره بافت و هزینه اجرای محلی.

۲-۴-۱- توکن‌سازی و معماری رمزگشای ترنسفورمر

مدل زبانی مستقیماً با واژه کامل کار نمی‌کند. متن ابتدا به توکن‌هایی شامل واژه، بخش واژه، عدد یا نشانه شکسته می‌شود و هر توکن به یک بردار عددی نگاشت می‌گردد. کیفیت توکن‌سازی برای فارسی مهم است؛ زیرا یک عبارت فارسی ممکن است به تعداد متفاوتی توکن در مدل‌های مختلف تقسیم شود. تعداد توکن بیشتر، بخشی از پنجره بافت را مصرف می‌کند و زمان تولید را نیز افزایش می‌دهد. بنابراین مقایسه سرعت فقط بر اساس تعداد واژه خروجی دقیق نیست و نرخ توکن در ثانیه نیز گزارش می‌شود.

در هر لایه رمزگشا، سازوکار توجه از سه نمایش پرس‌وجو، کلید و مقدار استفاده می‌کند. صورت ساده توجه به شکل زیر است [۲]:


$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V. \quad (۴.۲)$$

این محاسبه تعیین می‌کند هر توکن برای ساخت نمایش جدید خود به کدام توکن‌های قبلی توجه بیشتری داشته باشد. در مدل فقط رمزگشا یک پوشش علی مانع مشاهده توکن‌های آینده می‌شود؛ از این رو مدل پاسخ را از چپ به راست و توکن به توکن می‌سازد. خروجی توجه از شبکه پیش‌خور، اتصال باقی‌مانده و نرمال‌سازی عبور می‌کند و تکرار این بلوک‌ها نمایش زبانی غنی‌تری ایجاد می‌کند.

شکل ۲-۲ معماری اصلی ترنسفورمر را نشان می‌دهد. شاخه سمت چپ رمزگذار و شاخه سمت راست رمزگشا است. مدل‌های زبانی این پروژه از ساختار فقط رمزگشا استفاده می‌کنند؛ یعنی بلوک‌های رمزگشای علی را نگه می‌دارند، اما توجه میان رمزگذار و رمزگشا و شاخه مستقل رمزگذار در آن‌ها وجود ندارد.

هنگام تولید، کلیدها و مقدارهای توکن‌های قبلی در حافظه نهان حافظه نهان کلید و مقدار نگهداری می‌شوند تا برای هر توکن جدید دوباره محاسبه نشوند. این حافظه با طول متن و تعداد لایه‌ها رشد می‌کند. در نتیجه، پنجره بافت بزرگ فقط یک قابلیت زبانی نیست و هزینه حافظه اجرایی نیز دارد. محدود کردن تاریخچه در سامانه محلی هم اطلاعات نامرتب را کاهش می‌دهد و هم مصرف حافظه و زمان پردازش ورودی را کنترل می‌کند.

پنجره بافت ظرفیت محدودی دارد. نگهداری نامحدود تاریخچه هم حافظه را افزایش می‌دهد و هم اطلاعات نامرتب را وارد پاسخ می‌کند. در سامانه نهایی، تاریخچه عمومی به چند نوبت اخیر محدود می‌شود و اصلاحات صریح کاربر در حافظه ساخت‌یافته جداگانه نگهداری می‌شوند. این تفکیک باعث می‌شود یک اصلاح مفید پس از حذف نوبت قدیمی باقی بماند، بدون آنکه کل مکالمه برای همیشه در ورودی مدل تکرار شود.



شکل ۲-۲ معماری مرجع ترنسفورمر و شاخه رمزگشای آن؛ برگرفته از [۲]

۲-۴-۲- خانواده مدل‌های بررسی شده

مدل‌های پروژه شامل خانواده‌های گما ۲، کوئن ۵.۲ و درنا ۲ هستند که قابلیت‌ها و اندازه‌های متفاوتی دارند [۱۵، ۱۶، ۱۷]. چون هدف اجرا روی سخت‌افزار شخصی است، تعداد پارامتر به‌تنهایی معیار مناسبی نیست. کیفیت پاسخ فارسی باید همراه با حافظه مصرفی، زمان نخستین توکن و سرعت تولید سنجیده شود. گما ۲ خانواده‌ای از مدل‌های باز و دستورمحور در اندازه‌های مختلف است که نسخه‌های کوچک‌تر و بزرگ‌تر آن امکان بررسی اثر ظرفیت مدل را فراهم می‌کنند [۱۵]. کوئن ۵.۲ نیز در چند اندازه عرضه شده و برای وظایف عمومی و چندزبانه به کار می‌رود [۱۶]. حضور دو اندازه از یک خانواده در بنچمارک کمک می‌کند روشن شود افزایش تعداد پارامتر تا چه حد بهبود کیفیت را در برابر افزایش حافظه و زمان توجیه می‌کند. درنا ۲ بر پایه یک مدل دستورمحور عمومی و با تمرکز بیشتر بر زبان فارسی ارائه شده است [۱۷]. سازگاری فارسی می‌تواند در واژگان و سبک پاسخ مفید باشد، اما به‌تنهایی برتری در همه وظایف را تضمین نمی‌کند. از این رو، معماری پایه یا ادعای پشتیبانی از فارسی معیار انتخاب نهایی نبوده و همه مدل‌ها روی مجموعه پرسش و قالب یکسان ارزیابی شده‌اند.

۲-۴-۳- ساخت زمینه و شیوه تولید پاسخ

ورودی مدل زبانی از چند بخش با نقش‌های متفاوت تشکیل می‌شود: دستور سامانه رفتار کلی دستیار را تعیین می‌کند، تاریخچه کوتاه برای فهم ارجاع‌ها به کار می‌رود، حافظه اصلاحات اطلاعات تأییدشده کاربر را نگه می‌دارد و متن نوبت جاری پرسش اصلی را در اختیار مدل قرار می‌دهد. ترتیب و مرزبندی این بخش‌ها اهمیت دارد؛ زیرا مخلوط‌شدن دستور، حافظه و متن کاربر می‌تواند باعث شود مدل یک داده موقت را به‌عنوان قاعده دائمی یا بخشی از دستور تفسیر کند.

دو حالت استفاده از مدل باید از هم جدا شوند. در بنچمارک، هدف مقایسه قابل‌بازتولید مدل‌ها است؛ بنابراین قالب پرسش، محدودیت طول پاسخ و تنظیمات تولید برای همه مدل‌ها ثابت نگه داشته می‌شوند. در اجرای تعاملی، روانی پاسخ و زمان انتظار نیز اهمیت دارند و خروجی می‌تواند به‌تدریج دریافت شود. ثابت‌بودن شرایط ارزیابی مانع از آن می‌شود که تفاوت قالب درخواست یا طول پاسخ به اشتباه به برتری خود مدل نسبت داده شود.

در هر گام، لایه خروجی برای توکن‌های واژگان امتیاز تولید می‌کند و تابع نرمال‌سازی نمایی این امتیازها را به یک توزیع احتمال تبدیل می‌کند. در رمزگشایی حریصانه، توکن دارای بیشترین احتمال انتخاب می‌شود؛ در نمونه‌گیری، پارامترهایی مانند دما و آستانه احتمال تجمعی میزان تنوع را کنترل می‌کنند. نمونه‌گیری برای گفت‌وگوی خلاقانه مفید است، اما ممکن است اجرای تکراری یک پرسش را به پاسخ‌های متفاوت برساند.

در این پروژه تولید برای بنچمارک و مسیر اصلی به‌صورت قطعی انجام می‌شود تا تغییر خروجی ناشی از تصادف

با تفاوت مدل یا ورودی اشتباه گرفته نشود. همچنین سقف طول ورودی و خروجی از توقف‌ناپذیری تولید و رشد کنترل نشده تأخیر جلوگیری می‌کند. این محدودیت می‌تواند پاسخ بسیار بلند را قطع کند؛ بنابراین مقدار آن باید متناسب با کوتاه‌بودن پاسخ‌های مورد انتظار دستیار انتخاب شود.

مدل زبانی خطای ورودی را الزاماً تشخیص نمی‌دهد. اگر نام، عدد یا نفی در متن تشخیص گفتار تغییر کرده باشد، یک پاسخ روان ممکن است همچنان بر مبنای همان ورودی نادرست ساخته شود. از این رو، کنترل ابهام پیش از فراخوانی مدل انجام می‌شود و مدل زبانی جایگزین سازوکار اعتبارسنجی ورودی نیست. این تفکیک، مسئولیت هر جزء را روشن می‌کند: لایه کنترل درباره قابل‌اعتمادبودن پرسش تصمیم می‌گیرد و مدل زبانی پاسخ آن پرسش را تولید می‌کند.

۲-۴-۴- کوانتیزه‌سازی و معیارهای استنتاج

کوانتیزه‌سازی وزن‌ها را با دقت عددی کمتر ذخیره و محاسبه می‌کند. نسخه چهاربیتی می‌تواند حافظه مورد نیاز را به‌طور محسوسی کاهش دهد، اما اثر آن بر کیفیت به مدل و روش کوانتیزه‌سازی وابسته است. پروژه از نسخه‌ای استفاده می‌کند که روی سخت‌افزار موجود جا می‌شود؛ بنابراین نتایج گزارش شده متعلق به همان نسخه اجرایی هستند، نه الزاماً وزن‌های کامل مدل.

در نمایش ممیز شناور، هر وزن با تعداد بیت بیشتری ذخیره می‌شود. در کوانتیزه‌سازی، بازه‌ای از وزن‌ها با یک مقیاس به مجموعه کوچک‌تری از مقادیر صحیح نگاشت می‌شود و هنگام محاسبه مقدار تقریبی آن‌ها بازسازی می‌گردد. کوانتیزه‌سازی چهاربیتی اندازه حافظه وزن‌ها را در مقایسه با نمایش شانزده‌بیتی به‌طور نظری تا حدود یک‌چهارم کاهش می‌دهد، هرچند مقیاس‌ها، سربار قالب و حافظه فعال‌سازی مانع رسیدن کل مصرف سامانه به دقیقاً همین نسبت می‌شوند [۱۸].

مزیت اصلی برای این پروژه، امکان قرار گرفتن مدل بزرگ‌تر در حافظه پردازنده گرافیکی است. با این حال، کاهش دقت وزن ممکن است احتمال توکن‌ها و در نتیجه پاسخ را تغییر دهد و سرعت نیز به پشتیبانی سخت‌افزار و هسته محاسباتی از قالب کوانتیزه وابسته است. به همین دلیل، نام مدل بدون ذکر قالب وزن برای بازتولید بنچمارک کافی نیست و ارزیابی روی همان نسخه چهاربیتی مورد استفاده در خط لوله انجام می‌شود.

سه معیار برای تجربه تعاملی اهمیت دارند:

- زمان نخستین توکن، فاصله شروع فراخوانی تا نخستین خروجی مدل؛

- سرعت تولید بر حسب توکن در ثانیه؛

- و زمان کل تولید پاسخ.

زمان نخستین توکن بر احساس شروع پاسخ و سرعت توکن بر ادامه روان آن اثر می‌گذارد. در خط لوله جریانی، لازم نیست پایان کل پاسخ منتظر بماند؛ یک عبارت کامل می‌تواند هم‌زمان با ادامه تولید متن به تبدیل متن به گفتار فرستاده شود.

۲-۴-۵- معیارهای کیفیت پاسخ

برای پرسش‌های دارای پاسخ کوتاه، تطابق دقیق سخت‌گیرانه‌ترین معیار است. امتیاز افیک توکنی هم‌پوشانی واژه‌های پاسخ و مرجع را می‌سنجد و شباهت معنایی برای پاسخ‌های هم‌معنا با صورت متفاوت مفید است. هیچ‌یک به‌تنهایی کافی نیستند: تطابق دقیق بازنویسی صحیح را جریمه می‌کند و شباهت معنایی ممکن است خطای یک موجودیت یا عدد را کم‌اهمیت نشان دهد. به همین علت، رتبه‌بندی مدل زبانی در پروژه بر چند وظیفه و چند معیار انجام شده است.

در تطابق دقیق، پس از نرمال‌سازی، کل پاسخ پیش‌بینی‌شده باید با پاسخ مرجع برابر باشد؛ بنابراین این معیار برای پرسش‌های کوتاه و دارای جواب مشخص مناسب است. برای امتیاز افیک توکنی، ابتدا دقت و بازخوانی بر اساس توکن‌های مشترک محاسبه و سپس میانگین هارمونیک آن‌ها گرفته می‌شود:

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (5.2)$$

در این رابطه، دقت توکنی نسبت تعداد توکن‌های مشترک به تعداد توکن‌های پاسخ پیش‌بینی‌شده و بازخوانی نسبت همان اشتراک به تعداد توکن‌های پاسخ مرجع است. اگر مجموعه چندتایی توکن‌های پیش‌بینی و مرجع را به ترتیب P و G بنامیم، این دو کمیت به‌صورت زیر تعریف می‌شوند:

$$\text{Precision} = \frac{|P \cap G|}{|P|}, \quad \text{Recall} = \frac{|P \cap G|}{|G|}. \quad (6.2)$$

در پرسش‌های چندگزینه‌ای، دقت کل برابر تعداد پاسخ‌های صحیح تقسیم بر تعداد کل پرسش‌ها و روی مقیاس صفر تا صد درصد است. شباهت معنایی نیز کسینوس زاویه میان بردار بازنمایی پاسخ پیش‌بینی‌شده، u ، و پاسخ مرجع، v ، است:

$$\text{SemanticSimilarity} = \frac{u \cdot v}{\|u\| \|v\|}. \quad (7.2)$$

مقدار بزرگ‌تر برای دقت کل، تطابق دقیق، امتیاز افیک و شباهت معنایی بهتر است. تطابق دقیق و دقت کل در گزارش به‌صورت درصد و دو معیار دیگر به‌صورت نسبت صفر تا یک گزارش می‌شوند.

اگر مدل بخشی از پاسخ درست را همراه با عبارت اضافی تولید کند، تطابق دقیق صفر می‌شود، ولی امتیاز افیک میزان هم‌پوشانی باقی‌مانده را نشان می‌دهد. شباهت معنایی نیز بردارهای بازنمایی پاسخ و مرجع را مقایسه می‌کند و برای بازنویسی‌های درست مفید است. باین‌حال، چون شباهت بالا ممکن است تفاوت یک عدد یا نام را پنهان کند، نمونه‌های حساس باید همراه با معیار رشته‌ای و بررسی حفظ موجودیت تفسیر شوند.

۲-۵- تبدیل متن به گفتار و معیارهای آن

۲-۵-۱- مدل‌های مورد استفاده

سامانه تبدیل متن به گفتار متن نهایی را به صوت قابل پخش تبدیل می‌کند. پیش از تولید، نویسه‌ها و اعداد باید به صورتی نرمال شوند که مدل بتواند آن‌ها را تلفظ کند؛ برای مثال، باقی‌ماندن عدد لاتین یا یک نشانه ناشناخته ممکن است به سکوت یا تلفظ نادرست بینجامد.

دو مدل آزمایش‌شده بر معماری ویتس تکیه دارند. این معماری مدل‌سازی زبانی و تولید شکل موج را در یک چارچوب انتهابه‌انتها ترکیب می‌کند [۳]. مدل چندزبانه ام‌اس پوشش زبانی گسترده را هدف می‌گیرد [۱۹]. پایپر نیز برای استنتاج محلی و سبک طراحی شده و در نسخه نهایی پروژه به کار رفته است [۲۰]. تفاوت این مدل‌ها باید با ورودی متنی یکسان و هم‌زمان از نظر کیفیت، بازشناسی‌پذیری و سرعت سنجیده شود.

۲-۵-۲- معماری ویتس


در سامانه‌های کلاسیک تبدیل متن به گفتار، مدل آکوستیکی ابتدا متن را به ویژگی‌هایی مانند طیف‌نگاشت تبدیل می‌کند و یک واکدر جداگانه از آن ویژگی‌ها موج صوتی می‌سازد. ویتس این دو مرحله را در یک مدل احتمالی انتهابه‌انتها ترکیب می‌کند. رمزگذار متن از دنباله واج‌ها یک توزیع پیشین برای متغیر نهفته می‌سازد و رمزگذار پسین در زمان آموزش، نمایش نهفته متناظر را از صوت واقعی استخراج می‌کند [۳].

یک جریان نرمال‌ساز، توزیع پسین صوت را به توزیع پیش‌بینی‌شده از متن مرتبط می‌کند. در کنار آن، پیش‌بین مدت تعیین می‌کند هر واحد متنی چه مدت در خروجی ادامه داشته باشد و سازوکار هم‌ترازی، ترتیب یکنواخت متن و صوت را حفظ می‌کند. مولد عصبی در پایان مستقیماً موج صوتی را از نمایش نهفته می‌سازد و آموزش تخصصی به طبیعی‌تر شدن جزئیات صوت کمک می‌کند. به همین دلیل، کیفیت، آهنگ و مدت گفتار در ویتس به‌صورت جدا از یکدیگر قابل تفسیر کامل نیستند.

در زمان استنتاج، رمزگذار پسین که به صوت مرجع نیاز دارد کنار گذاشته می‌شود. متن و مدت‌های پیش‌بینی‌شده برای نمونه‌گیری نمایش نهفته و تولید موج صوتی به کار می‌روند. این مسیر نسبتاً یکپارچه اجرای محلی را ساده می‌کند، ولی خطای پردازش متن یا پیش‌بینی مدت می‌تواند به تلفظ نادرست، مکث غیرطبیعی یا

کشیدگی واژه منجر شود. مؤلفه‌های ناپیوستگی و رنگ‌شدگی در ارزیابی کیفیت برای آشکارکردن بخشی از همین مشکلات گزارش می‌شوند.

شکل ۲-۳ تفاوت دو مسیر را روشن می‌کند. در سمت چپ، مسیر آموزش از صوت مرجع و رمزگذار پسین برای یادگیری فضای نهفته و هم‌ترازی استفاده می‌کند؛ در سمت راست، مسیر استنتاج تنها با متن، پیش‌بینی مدت و نمونه‌گیری از توزیع پیشین، موج صوتی را تولید می‌کند.



شکل ۲-۳ مسیرهای آموزش و استنتاج معماری ویتس؛ برگرفته از [۳]

۲-۵-۳- تفاوت مدل‌های مورد ارزیابی

کامترا یک مدل فارسی مبتنی بر معماری ویتس است و نماینده یک سامانه تک‌زبانه در مقایسه پروژه محسوب می‌شود. تمرکز تک‌زبانه می‌تواند یادگیری الگوی تلفظ و آهنگ فارسی را آسان‌تر کند، ولی کیفیت عملی همچنان به داده گوینده، پوشش متنی و پیاده‌سازی استنتاج وابسته است.

مدل ویتس چندزبانه بخشی از طرح گفتاری ام‌ام‌اس است که پوشش تعداد زیادی زبان را هدف قرار می‌دهد [۱۹]. مزیت آن دسترسی به مدل آماده برای زبان‌های کم‌منبع و مسیر استنتاج یکنواخت است؛ در مقابل، پوشش گسترده زبانی به معنی بهترین کیفیت برای هر زبان خاص نیست. به همین دلیل، مدل فارسی آن با همان متن‌های ورودی دو سامانه دیگر ارزیابی شده است.

پایپر یک زنجیره سبک برای آوانویسی متن و اجرای محلی مدل صوتی فراهم می‌کند و مدل فارسی پروژه را در قالب قالب تبادل شبکه عصبی اجرا می‌کند [۲۰]. صدای fa_IR-gyro-medium تک‌گوینده است و خروجی آن با نرخ نمونه‌برداری ۲۲,۰۵۰ Hz تولید می‌شود. مزیت معماری اجرایی پایپر سادگی استقرار و امکان تولید قطعه‌ای است؛ با این حال، همانند دو مدل دیگر باید کیفیت ادراکی، حفظ محتوای متن و زمان تولید آن به‌طور مستقل

اندازه‌گیری شود.

۲-۵-۴- بازنمایی متن و تولید موج صوتی

تولید گفتار تنها نگاشت مستقیم نویسه به نمونه صوتی نیست. بخش پردازش متن، جمله را نرمال و به واحدهای قابل تلفظ تبدیل می‌کند؛ سپس مدل، بازنمایی زمانی یا آکوستیکی گفتار را می‌سازد و مولد موج صوتی آن را به سیگنال قابل پخش تبدیل می‌کند. در معماری‌های انتهابه‌انتها مانند ویتس، این اجزا در یک چارچوب مشترک آموزش می‌بینند [۳]، اما در زمان استفاده همچنان کیفیت پردازش متن بر خروجی اثر می‌گذارد. این موضوع برای فارسی در برخورد با عدد، تاریخ، مخفف و ترکیب متن فارسی و لاتین مهم است. شکل نوشتاری یک عدد همیشه نشان نمی‌دهد که باید چگونه خوانده شود و برخی نشانه‌ها ممکن است در داده آموزشی مدل حضور کافی نداشته باشند. در پروژه، نرمال‌ساز عدد و متن پیش از مدل قرار گرفته است تا ورودی قابل تلفظ تولید شود؛ با این حال، نرمال‌سازی معنایی محافظه‌کارانه انجام می‌شود تا مقدار یا نام موجود در پاسخ تغییر نکند. طول قطعه متنی نیز میان پیوستگی و تأخیر توازن ایجاد می‌کند. تولید کل پاسخ در یک مرحله معمولاً پیوستگی آوایی بیشتری دارد، ولی آغاز پخش را تا پایان تولید عقب می‌اندازد. قطعه‌های بسیار کوتاه زودتر پخش می‌شوند، اما ممکن است آهنگ جمله و مکث‌ها را نامنظم کنند. راهکار خط لوله، قطعه‌بندی بر مبنای پایان عبارت است تا تولید و پخش زود آغاز شوند و در عین حال مرزهای زبانی تا حد امکان حفظ گردند.

۲-۵-۵- کیفیت ادراکی و بازشناسی‌پذیری

میانگین امتیاز نظر کیفیت کلی گفتار را معمولاً روی مقیاس یک تا پنج بیان می‌کند. در این پروژه مقدار میانگین امتیاز نظر و مؤلفه‌هایی مانند نویز، ناپیوستگی، رنگ‌شدگی و بلندی با مدل ارزیابی بدون مرجع کیفیت گفتار برآورد شده‌اند. این مدل کیفیت ادراکی را از خود سیگنال تولیدشده پیش‌بینی می‌کند [۲۱]. این خروجی برای مقایسه کنترل‌شده مدل‌ها مفید است، اما جایگزین ارزیابی شنیداری انسان نیست. میانگین امتیاز نظر، برداشت عمومی از طبیعی‌بودن و خوشایندی صوت را خلاصه می‌کند، اما علت افت کیفیت را نشان نمی‌دهد. مؤلفه نویز وجود صداها را ناخواسته را بازتاب می‌دهد؛ ناپیوستگی به شکستگی، پرش یا مکث‌های غیرطبیعی حساس است؛ رنگ‌شدگی تغییر غیرطبیعی طیف و جنس صدا را نشان می‌دهد؛ و مؤلفه بلندی، مناسب‌بودن سطح شنیداری را برآورد می‌کند. گزارش هم‌زمان این مؤلفه‌ها مشخص می‌کند دو مدل با میانگین امتیاز نظر نزدیک ممکن است الگوهای خطای متفاوتی داشته باشند. انحراف معیار میانگین امتیاز نظر نیز در کنار میانگین اهمیت دارد. میانگین بالا با پراکندگی زیاد می‌تواند به این معنا باشد که مدل برای بخشی از جمله‌ها خوب و برای بخشی دیگر نامطمئن است. برای یک دستیار عمومی، پایداری کیفیت در متن‌های مختلف می‌تواند به‌اندازه بهترین خروجی‌های مدل مهم باشد. با این حال، چون ارزیابی

بدون مرجع کیفیت گفتار امتیاز را پیش‌بینی می‌کند، نتیجه آن شاهد نسبی برای مقایسه مدل‌ها است و نه نمره مستقیم گروهی از شنوندگان فارسی‌زبان.

کیفیت خوشایند لزوماً به معنی حفظ دقیق متن نیست. برای سنجش بازشناسی‌پذیری، صوت هر مدل دوباره با یک تشخیص گفتار ثابت به متن تبدیل و نرخ خطای واژه و نرخ خطای نویسه آن نسبت به متن ورودی محاسبه می‌شود. چون ارزیاب خود ممکن است خطا کند، این اعداد خطای مطلق شنونده انسانی نیستند؛ اعتبار آن‌ها در مقایسه نسبی مدل‌هایی است که با متن‌ها و ارزیاب یکسان آزمایش شده‌اند.

بازشناسی مجدد دو نوع خطا را با هم ترکیب می‌کند: خطای تلفظ یا وضوح مدل تبدیل متن به گفتار و خطای خود مدل ارزیاب تشخیص گفتار. ثابت نگه‌داشتن ارزیاب، متن‌ها و نرمال‌سازی باعث می‌شود سهم دوم برای همه سامانه‌ها تا حد امکان مشترک باشد. بنابراین کاهش نرخ خطای واژه و نرخ خطای نویسه در این آزمایش نشانه بازشناسی‌پذیرتر شدن نسبی گفتار تولیدی است، نه برآورد مستقیم درصد شنوندگانی که جمله را درست می‌فهمند.

۲-۵-۶- کارایی زمانی

برای تبدیل متن به گفتار نیز ضریب زمان واقعی از تقسیم زمان تولید بر مدت صوت خروجی به دست می‌آید. میانگین تأخیر سطح نمونه و ضریب زمان واقعی تجمیعی می‌توانند متفاوت باشند، زیرا نسبت تجمیعی به نمونه‌های بلندتر وزن بیشتری می‌دهد. در کاربرد مکالمه‌ای، علاوه بر این دو عدد، زمان رسیدن نخستین قطعه صوتی مهم است. تقسیم پاسخ به عبارت و تولید جریانی امکان هم‌پوشانی تولید متن، تولید صوت و پخش را فراهم می‌کند. برای رفع ابهام در تفسیر جدول‌ها، ضریب زمان واقعی نمونه i برابر t_i/d_i است که t_i زمان تولید و d_i مدت صوت خروجی است. میانگین نمونه‌ای، میانگین این نسبت‌ها و ضریب تجمیعی برابر رابطه زیر است:

$$\text{RTF}_{\text{aggregate}} = \frac{\sum_i t_i}{\sum_i d_i}. \quad (۸.۲)$$

تأخیر متوسط، میانگین زمان تولید یک نمونه است و با مدت صوت نرمال نمی‌شود. ضریب افزایش سرعت نیز معکوس ضریب زمان واقعی تجمیعی است؛ برای نمونه، ضریب افزایش سرعت پنج یعنی تولید کل صوت تقریباً پنج برابر سریع‌تر از پخش هم‌زمان آن انجام شده است. در همه این معیارهای زمانی، تأخیر و ضریب زمان واقعی کمتر و ضریب افزایش سرعت بیشتر مطلوب است.

۲-۶- تشخیص فعالیت صوتی و کنترل نوبت

تشخیص فعالیت صوتی یا تشخیص فعالیت صوتی احتمال وجود گفتار را در قطعه‌های صوتی برآورد می‌کند. کاربرد آن در این پروژه حذف همه سکوت‌ها نیست، بلکه تعیین خودکار مرز نوبت کاربر است. سه خطای عملی باید

کنترل شوند: شروع دیر هنگام که ابتدای واژه را حذف می‌کند، پایان زود هنگام که جمله را می‌برد و انتظار طولانی که پاسخ سامانه را کند می‌کند.

ساده‌ترین روش تشخیص گفتار، مقایسه انرژی قطعه با یک آستانه است. این روش در محیط آرام کم‌هزینه است، اما صدای پس‌زمینه، ضربه یا تغییر فاصله گوینده از میکروفن می‌تواند آن را گمراه کند. مدل عصبی تشخیص فعالیت صوتی علاوه بر دامنه، الگوهای طیفی و زمانی گفتار را در نظر می‌گیرد و برای هر قاب احتمال گفتار تولید می‌کند. در سامانه حاضر، این احتمال ورودی منطق کنترل نوبت است و خود مدل به‌تنهایی زمان آغاز یا پایان مکالمه را تعیین نمی‌کند.

خروجی تشخیص فعالیت صوتی برای هر قطعه معمولاً یک امتیاز پیوسته است، درحالی‌که کنترل نوبت به تصمیمی گسسته درباره شروع یا پایان گفتار نیاز دارد. اگر هر قطعه مستقل تصمیم‌گیری شود، نوسان امتیاز در مکث‌های کوتاه می‌تواند یک جمله را به چند نوبت بشکند. به همین دلیل، تصمیم پایدار به آستانه، تعداد قطعه‌های متوالی و وضعیت قبلی ضبط وابسته است. این منطق را می‌توان یک ماشین حالت کوچک دانست که میان انتظار، ضبط گفتار و انتظار برای سکوت پایانی جابه‌جا می‌شود.

برای ایجاد تعادل، سامانه مقداری صوت پیش از شروع تشخیص داده‌شده را نگه می‌دارد، پس از پایان نیز حاشیه کوتاهی حفظ می‌کند و تنها بعد از مدت معینی سکوت نوبت را خاتمه می‌دهد. آستانه احتمال و زمان‌های دقیق در فصل طراحی گزارش می‌شوند، زیرا مقادیر آن‌ها تصمیم پیاده‌سازی‌اند نه مفهوم عمومی.

نگهداری صوت پیش از شروع، از حذف واج ابتدایی در فاصله میان تشخیص و فعال‌شدن ضبط جلوگیری می‌کند. حاشیه انتهایی نیز احتمال حذف پایان واژه را کاهش می‌دهد. در مقابل، افزایش بیش از اندازه این دو حاشیه، سکوت اضافی را وارد تشخیص گفتار می‌کند و زمان پاسخ را بالا می‌برد. بنابراین تنظیم تشخیص فعالیت صوتی بخشی از عملکرد انتهابه‌انتها است و نباید مستقل از دقت بازشناسی و تأخیر سامانه ارزیابی شود.

کاهش نویز یا تقویت دامنه نیز باید انتخابی باشد. پردازشی که کیفیت شنیداری را بهتر می‌کند الزاماً ویژگی‌های مورد استفاده تشخیص گفتار را بهبود نمی‌دهد. به همین دلیل، پروژه تقویت را فقط برای صوت‌های بسیار کم‌دامنه فعال و اثر آن را با آزمایش زوجی اندازه‌گیری می‌کند.

۲-۷- انتشار خطا، رفع ابهام و حافظه

در معماری زنجیره‌ای، خروجی هر مرحله ورودی مرحله بعدی است. اگر تشخیص گفتار بخشی از پرسش را اشتباه بازشناسی کند، مدل زبانی معمولاً همان متن نادرست را به‌عنوان واقعیت می‌پذیرد. نرخ خطای کلی برای پیش‌بینی این شکست کافی نیست؛ اهمیت خطا به نقش معنایی واژه وابسته است. این مسئله انگیزه ارزیابی جداگانه حفظ عبارت پاسخ و طراحی کنترل ریسک است.

مسیر اطلاعات را می‌توان به صورت

$$x \longrightarrow \hat{y} \longrightarrow \hat{r} \longrightarrow \hat{s} \quad (9.2)$$

نمایش داد؛ در این رابطه x صوت کاربر، $\hat{y}$ متن بازشناسی شده، $\hat{r}$ پاسخ تولیدشده و $\hat{s}$ صوت خروجی است. خطای مرحله نخست می‌تواند محتوای تمام خروجی‌های بعدی را تغییر دهد، درحالی‌که خطای تبدیل متن به گفتار معمولاً متن پاسخ را تغییر نمی‌دهد و بیشتر بر قابل فهم بودن یا کیفیت شنیداری اثر می‌گذارد. این تفاوت سبب می‌شود معیارهای هر جزء همراه با جایگاه آن در زنجیره تفسیر شوند.

خطاهای تشخیص گفتار از نظر امکان بازیابی نیز یکسان نیستند. حذف کامل یک بخش از گفتار معمولاً اطلاعاتی برای اصلاح خودکار باقی نمی‌گذارد؛ اما اگر واژه درست در میان فرضیه‌های چندگانه باشد، می‌توان با استفاده از زمینه یا تأیید کاربر آن را بازیابی کرد. از سوی دیگر، انتخاب خودکار یک فرضیه جایگزین بدون شاهد کافی ممکن است متن درست را خراب کند. ارزیابی سیاست اصلاح باید در کنار تعداد موارد بازیابی شده، تغییرات زیان‌بار روی نمونه‌های از ابتدا درست را نیز گزارش کند.

رفع ابهام زمانی ارزش دارد که سؤال کوتاه و مشخص باشد. پرسیدن درباره هر اختلاف کوچک مکالمه را آزادکننده می‌کند، درحالی‌که نادیده گرفتن اختلاف نام، عدد یا نفی می‌تواند پاسخ نامعتبر بسازد. سیاست پروژه فقط از گزینه‌هایی استفاده می‌کند که واقعاً در فرضیه‌های تشخیص گفتار وجود دارند و اصلاح تأییدشده کاربر را همراه با زمینه آن ذخیره می‌کند.

تصمیم کنترل مکالمه سه هزینه متفاوت دارد. پاسخ مستقیم سریع‌ترین مسیر است، ولی در ورودی پرخطر می‌تواند پاسخ نامرتبب تولید کند. پرسش رفع ابهام احتمال خطای معنایی را کاهش می‌دهد، اما یک نوبت به مکالمه اضافه می‌کند. درخواست تکرار نیز زمانی مناسب است که صوت یا فرضیه‌ها اطلاعات کافی برای ساخت سؤال مشخص ندارند. سیاست مناسب باید این هزینه‌ها را متعادل کند؛ هدف آن بیشینه کردن تعداد پرسش‌های رفع ابهام نیست، بلکه پرسیدن فقط در مواردی است که ارزش مورد انتظار اصلاح از هزینه وقفه بیشتر باشد.

حافظه سامانه دو نقش متفاوت دارد. تاریخچه مکالمه برای فهم ارجاع‌ها و پرسش‌های ادامه‌دار به مدل زبانی داده می‌شود. حافظه اصلاحات برای بازرتبه‌بندی محدود فرضیه‌های بعدی استفاده می‌شود. جداکردن این دو نوع حافظه از تبدیل یک اصلاح موضعی به قاعده‌ای عمومی جلوگیری می‌کند.

۲-۷-۱- معیارهای ارزیابی انتشار خطا و عدم قطعیت

حفظ دقیق عبارت پاسخ، درصد نمونه‌هایی است که عبارت ضروری پاسخ پس از تشخیص گفتار بدون تغییر در رونویسی باقی می‌ماند. برای جداکردن خطای مدل زبانی از اثر تشخیص گفتار، ابتدا فقط نمونه‌هایی انتخاب می‌شوند که مدل زبانی با متن مرجع به آن‌ها پاسخ دقیق داده است. حفظ پاسخ صحیح، درصد همین نمونه‌ها است

که با رونویسی گفتاری نیز پاسخ دقیق می‌گیرند. شکست انتشار مکمل آن است و از رابطه زیر به دست می‌آید:

$$\text{PropagationFailure}(\%) = 100 - \text{CorrectAnswerRetention}(\%). \quad (۱۰.۲)$$

برای سنجش توان یک نشانگر خطر در جداسازی پاسخ‌های درست و نادرست، مساحت زیر منحنی مشخصه عملکرد گیرنده گزارش می‌شود. مقدار این مساحت بین صفر و یک است؛ مقدار نیم به معنای جداسازی تصادفی و مقدار نزدیک یک به معنای رتبه‌بندی بهتر نمونه‌های پرخطر پیش از نمونه‌های کم‌خطر است. در این پروژه این معیار یک‌بار با نرخ خطای واژه هر ضبط و یک‌بار با حذف کامل عبارت پاسخ محاسبه می‌شود. فاصله اطمینان نودوپنج درصدی، بازه عدم قطعیت برآورد را نشان می‌دهد و با بازنمونه‌گیری خوشه‌ای در سطح شناسه معنایی محاسبه می‌شود تا ضبط‌های تکراری یک پرسش مستقل فرض نشوند. همچنین خطای اوراکل چندفرضیه‌ای، کمترین خطای ممکن میان فرضیه‌های واقعی رمزگشا با استفاده از متن مرجع است؛ این عدد فقط کران بالای ظرفیت بازیابی را نشان می‌دهد و یک روش قابل استفاده در زمان اجرا نیست.

۸-۲- مرور پژوهش‌ها و کارهای مرتبط

این فصل پژوهش‌هایی را مرور می‌کند که مستقیماً بر انتخاب داده، مدل، معیار یا معماری پروژه اثر داشته‌اند. هدف، فهرست کردن تمام مطالعات پردازش گفتار و زبان فارسی نیست. برای هر حوزه ابتدا شواهد مرتبط بیان و سپس نتیجه‌ای که از آن برای پروژه حاضر گرفته شده مشخص می‌شود. ادبیات مورد نیاز در چهار گروه قرار می‌گیرد: تشخیص گفتار فارسی و چندزبانه، ارزیابی مدل‌های زبانی فارسی و اجرای محلی آن‌ها، تبدیل متن به گفتار فارسی و سامانه‌های گفت‌وگوی صوتی یکپارچه. این تقسیم‌بندی با معماری زنجیره‌ای پروژه سازگار است و امکان مقایسه روشن میان کارهای پیشین و سهم عملی این گزارش را فراهم می‌کند.

۹-۲- تشخیص گفتار فارسی

۹-۲-۱- داده‌ها و معیارهای فارسی

پایگاه دیپ‌ماین یکی از منابع بزرگ گفتار فارسی و انگلیسی است که برای وظایفی مانند تشخیص گفتار و گوینده طراحی شده و تنوع گویندگان را در نظر می‌گیرد [۲۲]. در مقابل، کامن‌ویس با گردآوری جمع‌سپاری‌شده، امکان ارزیابی عمومی و قابل‌بازتولید مدل‌ها روی زبان‌های متعدد را فراهم کرده است [۲۳]. بخش فارسی نسخه ۲۵ این مجموعه، مجموعه آزمون اصلی بنچمارک تشخیص گفتار و منبع متن ارزیابی تبدیل متن به گفتار در پروژه حاضر است.

مزیت مجموعه آزمون عمومی، ورودی یکسان برای مدل‌های مختلف است؛ اما هیچ مجموعه منفردی همه شرایط کاربرد را پوشش نمی‌دهد. معیار معیار پی‌اس‌آربی نیز با ارزیابی سامانه‌های فارسی در شرایط متنوع‌تر نشان می‌دهد که نتیجه مدل به دامنه، کیفیت ضبط و نوع گفتار وابسته است [۲۴]. به همین دلیل، این پروژه علاوه بر کامن‌ویس از فلورز و یک آزمایش پایین‌دستی پرسش و پاسخ استفاده می‌کند و نتایج هر دامنه را جدا گزارش می‌دهد.

پژوهش مربوط به گفتار کودکان فارسی نیز اهمیت تطبیق دامنه را نشان می‌دهد. در آن مطالعه، ویو ۲ و ۲ برای ویژگی‌های آکوستیکی کودکان سازگار شد و عملکرد مدل به داده و هدف تنظیم وابسته بود [۲۵]. این نتیجه مانع از آن می‌شود که رتبه یک مدل روی یک مجموعه، حکم برتری عمومی آن تلقی شود.

۲-۹-۲- مدل‌های چندزبانه و معماری‌های کارآمد

ایکس‌ال‌اس‌آر با پیش‌آموزش خودنظارتی چندزبانه، انتقال بازنمایی‌های گفتاری به زبان‌هایی با داده برچسب‌خورده کمتر را ممکن می‌کند [۵]. ویسپر رویکرد دیگری است که با داده نظارت‌شده چندزبانه و مقیاس بزرگ آموزش دیده و بدون ساخت مدل از ابتدا برای زبان‌های متعدد قابل استفاده است [۶]. با این حال، حضور فارسی در یک مدل چندزبانه تضمین نمی‌کند که آن مدل روی تمام دامنه‌های فارسی بهترین باشد.

مطالعات کم‌منبع نیز نشان می‌دهند که شباهت داده پیش‌آموزش با زبان هدف، وزن‌دهی داده‌ها و سازگار کردن مدل می‌تواند از افزایش صرف اندازه مدل مهم‌تر باشند [۲۶، ۲۷]. در پژوهشی روی زبان‌های دارای خط فارسی و عربی، استفاده از داده میان‌زبانی مرتبط برای ساخت مدل کارآمد بررسی شده است [۲۸]. پیام مشترک این مطالعات آن است که مدل باید روی داده هدف و تحت محدودیت اجرای واقعی سنجیده شود.

برای گفتار فارسی خودانگیخته، تنظیم ویسپر روی داده مرتبط با دامنه بررسی شده است [۲۹]. همچنین پژوهش مربوط به محتوای فارسی یوتیوب نشان می‌دهد راهبرد قطعه‌بندی صوت می‌تواند نتیجه همان مدل را تغییر دهد [۳۰]. این یافته برای دستیار صوتی مهم است، زیرا مرزبندی نوبت به کمک تشخیص فعالیت صوتی بخشی از ورودی واقعی تشخیص گفتار را تعیین می‌کند.

مدل بزرگ فست‌کانفورمر ترکیبی شرکت انویدیا یک مدل فارسی آماده با مسیرهای طبقه‌بندی زمانی پیوندگرا و ترنس‌دیوسر شبکه عصبی بازگشتی است که پس از مقداردهی اولیه از نقطه‌واری انگلیسی، روی بخش فارسی کامن‌ویس نسخه ۱۵ ریزتنظیم شده است [۱۰]. در پروژه حاضر این مدل همراه با ویسپر بزرگ نسخه ۳، ویو ۲ و ۲ فارسی و واسک فارسی نسخه ۴۲۰۰ روی خط لوله یکسان دوباره ارزیابی شده است. این ارزیابی مجدد ضروری است، زیرا اعداد کارت مدل یا مقاله با تقسیم داده، نرمال‌سازی و سخت‌افزار متفاوت مستقیماً قابل مقایسه نیستند.

۲-۹-۳- نتیجه برای پروژه

ادبیات تشخیص گفتار سه تصمیم پروژه را پشتیبانی می‌کند. نخست، همه مدل‌ها باید با صوت و نرمال‌سازی یکسان مقایسه شوند. دوم، نتیجه چند دامنه باید جدا بماند. سوم، دقت تنها معیار انتخاب عملیاتی نیست. برای نمونه، مدلی که کمترین نرخ خطای واژه را دارد ممکن است به حافظه بیشتر نیاز داشته باشد یا اطمینان واژه و فرضیه‌های چندگانه مورد نیاز کنترل ابهام را ارائه نکند. فصل نتایج نشان می‌دهد همین تفاوت باعث شده مدل ارزیاب برتر و مدل اجرایی نهایی یکسان نباشند.

۲-۱۰-۱- مدل‌های زبانی فارسی و اجرای محلی

۲-۱۰-۱-۱- ارزیابی زبان فارسی

مطالعات ارزیابی مدل‌های زبانی فارسی نشان داده‌اند که کیفیت مدل به نوع وظیفه وابسته است و عملکرد انگلیسی یا میانگین چندزبانه برای نتیجه‌گیری درباره فارسی کافی نیست [۳۱]. معیارهای جدیدتر فارسی دامنه‌هایی مانند دانش، استدلال، زبان و فرهنگ را با پوشش بیشتر بررسی کرده‌اند [۳۲]. همچنین فارسی‌اوال بر تنوع وظایف ارزیابی فارسی تأکید دارد [۳۳].

این مطالعات دو محدودیت مهم برای پروژه حاضر ایجاد می‌کنند. نخست، یک امتیاز کلی نمی‌تواند توان مدل در همه کاربردها را نشان دهد. دوم، داوری پاسخ آزاد دشوارتر از پرسش چندگزینه‌ای یا پاسخ کوتاه است. بنابراین در بنچمارک پروژه یک وظیفه دانش و استدلال کنترل‌شده با یک وظیفه درک مطلب فارسی ترکیب شده و تطابق دقیق، امتیاز افیک توکنی و شباهت معنایی هم‌زمان گزارش می‌شوند.

مدل درنا و نسخه‌های بعدی آن نمونه‌ای از تلاش برای تنظیم مدل روی داده و دستورهای فارسی است [۱۷]. در کنار آن، مدل‌های عمومی چندزبانه مانند گما ۲ و کوئن ۵.۲ نیز فارسی را پشتیبانی می‌کنند [۱۵، ۱۶]. ادبیات موجود برتری قطعی یک گروه را برای همه وظایف اثبات نمی‌کند؛ به همین علت، انتخاب مدل زبانی پروژه بر اجرای همان آزمون‌ها روی نسخه‌های قابل اجرای محلی استوار شده است.

۲-۱۰-۲- محدودیت اجرای محلی

کوانتیزه‌سازی پس از آموزش امکان کاهش حافظه مدل را بدون آموزش کامل مجدد فراهم می‌کند. کوانتیزه‌سازی پس‌آموزش وزن‌ها را با هدف محدود کردن خطای ناشی از فشرده‌سازی تنظیم می‌کند و کوانتیزه‌سازی آگاه از فعال‌سازی بر وزن‌های مهم تمرکز دارد [۳۴، ۳۵]. هدف این فصل مقایسه جزئی این الگوریتم‌ها نیست؛ نکته مرتبط آن است که کیفیت و سرعت باید روی همان نسخه کوانتیزه‌ای اندازه‌گیری شوند که در سامانه اجرا می‌شود. در کاربرد صوتی، تأخیر مدل زبانی مستقیماً به سکوت میان پایان گفتار کاربر و آغاز پاسخ تبدیل می‌شود.

بنابراین تعداد پارامتر، دقت آزمون، حافظه، زمان نخستین توکن و سرعت تولید باید با هم دیده شوند. پروژه حاضر با انتخاب نسخه چهاربیتی گما ۲ با ۹ میلیارد پارامتر این مصالحه را به صورت تجربی انجام می دهد و با تولید عبارت به عبارت، بخشی از تأخیر ادامه پاسخ را با تبدیل متن به گفتار هم پوشان می کند.

۳-۱۰-۲ نتیجه برای پروژه

کارهای پیشین ضرورت ارزیابی فارسی و وظیفه محور را روشن می کنند، اما اغلب کیفیت مدل را مستقل از خط لوله صوتی می سنجند. در پروژه حاضر، مدل زبانی ابتدا با متن مرجع رتبه بندی می شود و سپس حساسیت آن به متن خطا دار تشخیص گفتار جداگانه اندازه گیری می شود. این جداسازی مشخص می کند که شکست پاسخ ناشی از ضعف مدل زبانی است یا از حذف اطلاعات در مرحله بازشناسی گفتار سرچشمه می گیرد.

۲-۱۱-۲ تبدیل متن به گفتار فارسی

۲-۱۱-۲-۱ داده و مدل

کمبود داده عمومی با کیفیت یکی از محدودیت های توسعه تبدیل متن به گفتار فارسی بوده است. آرمان تی تی اس مجموعه ای تک گوینده برای تولید گفتار فارسی ارائه می کند [۳۶]. مجموعه دیپ ماین چندگوینده پوشش چندگوینده را هدف گرفته است [۳۷]. مانا تی تی اس نیز فرایندی برای ساخت داده فارسی در مقیاس بزرگ تر و کنترل کیفیت آن ارائه می دهد [۳۸]. این منابع نشان می دهند که تنوع گوینده، پاکی صوت و صحت متن هم تراز بر طبیعی بودن و تلفظ خروجی اثر دارند.

از نظر مدل، ویتس تولید صوت را در یک معماری انتها به انتها انجام می دهد [۳]. پروژه ام ام اس این رویکرد را در مقیاس چندزبانه گسترش می دهد و برای فارسی نیز مدل ارائه می کند [۱۹]. پایپر با هدف تولید محلی و سریع عرضه شده است [۲۰]. این سه مسیر مبنای مدل های مقایسه شده در گزارش هستند: دو نمونه ویتس فارسی یا چندزبانه و یک مدل مناسب اجرای محلی.

۲-۱۱-۲-۲ ارزیابی چندبعدی

پژوهش های تبدیل متن به گفتار معمولاً طبیعی بودن را با ارزیابی شنیداری و میانگین امتیاز نظر می سنجند، اما اجرای مطالعه انسانی بزرگ برای هر تکرار آزمایش هزینه بر است. ارزیابی بدون مرجع کیفیت گفتار امکان برآورد بدون مرجع کیفیت و چند بعد تخریب صوت را فراهم می کند [۲۱]. با این حال، امتیاز کیفی بالا تضمین نمی کند که همه واژه ها درست تلفظ شده باشند.

برای پوشش این فاصله، بازشناسی مجدد صوت با یک تشخیص گفتار ثابت می تواند به عنوان شاخص نسبی

حفظ محتوای متن به کار رود. همچنین ضریب زمان واقعی و تأخیر باید جدا از کیفیت گزارش شوند، زیرا مدل طبیعی‌تر ممکن است کندتر باشد. طراحی ارزیابی پروژه دقیقاً از این نتیجه پیروی می‌کند: متن‌های یکسان به همه مدل‌ها داده می‌شوند و ارزیابی بدون مرجع کیفیت گفتار، نرخ خطای واژه و نرخ خطای نویسه حاصل از بازشناسی مجدد و معیارهای زمان روی همان نمونه‌ها محاسبه می‌شوند.

۲-۱۱-۳ نتیجه برای پروژه

ادبیات نشان می‌دهد هیچ معیار منفردی برای انتخاب تبدیل متن به گفتار مکالمه‌ای کافی نیست. پروژه حاضر مدل نهایی را فقط بر اساس سریع‌ترین زمان انتخاب نمی‌کند؛ طبیعی بودن، یکنواختی کیفیت، حفظ متن و سریع‌تر بودن از زمان واقعی هم‌زمان در تصمیم دخیل‌اند. نتیجه این مقایسه در فصل چهارم توضیح می‌دهد چرا پایپر با وجود کندتر بودن از امام‌اس برای خط لوله نهایی انتخاب شده است.

۲-۱۲-۲ سامانه‌های گفت‌وگوی صوتی یکپارچه

پژوهش‌های جدید تلاش کرده‌اند دریافت و تولید صوت را مستقیماً در مدل زبانی ادغام کنند. اسپیک‌جی‌پی‌تی، آدیوپالم و سالمون نمونه‌هایی از مدل‌های گفتار و زبان هستند که قابلیت‌های صوتی و زبانی را در چارچوبی مشترک دنبال می‌کنند [۳۹، ۴۰، ۴۱]. مرورهای این حوزه مزیت تعامل مستقیم صوتی را در کنار هزینه آموزش، نیاز سخت‌افزاری و دشواری کنترل اجزا مطرح می‌کنند [۴۲].


در برابر این رویکرد، معماری زنجیره‌ای زنجیره تشخیص گفتار، مدل زبانی و تبدیل متن به گفتار اجازه می‌دهد هر مؤلفه مستقل انتخاب، اندازه‌گیری و جایگزین شود. عیب آن انتشار خطا میان مراحل و جمع‌شدن تأخیرها است. برای هدف این پروژه، یعنی اجرای محلی روی سخت‌افزار محدود و تحلیل شفاف خطا، قابلیت کنترل و مشاهده‌پذیری معماری زنجیره‌ای اهمیت بیشتری دارد. کنترل ابهام و پردازش جریانی نیز برای کاهش دو ضعف اصلی آن، یعنی انتشار خطا و تأخیر، افزوده شده‌اند.

۲-۱۲-۱ ارزیابی وظیفه‌محور تشخیص گفتار در کاربردهای مبتنی بر مدل زبانی

پولیکودان و همکاران نشان داده‌اند که نرخ خطای واژه، همه خطاها را با وزن یکسان می‌شمارد و به‌تنهایی مشخص نمی‌کند آیا متن بازشناسی شده هنوز اطلاعات لازم برای یک کاربرد مبتنی بر مدل زبانی را حفظ کرده است یا نه [۴]. آنان ابتدا توان مدل زبانی در اصلاح یک مرحله‌ای خروجی تشخیص گفتار را بررسی کردند، اما بخش مرتبط‌تر با پروژه حاضر چارچوب پرسش و پاسخ آنان است. در این چارچوب، مدل زبانی نخست پرسش‌های معنادار را از متن مرجع تولید می‌کند. سپس مدل زبانی هدف، هر پرسش را دو بار و به‌طور مستقل پاسخ می‌دهد: یک بار

با متن مرجع و بار دیگر با رونویسی تشخیص گفتار. در مرحله آخر، مدلی قوی‌تر به‌عنوان داور تعیین می‌کند که دو پاسخ از نظر معنایی معادل‌اند یا خیر.

جریان این ارزیابی در شکل ۲-۴ نشان داده شده است. نکته اصلی، ثابت‌بودن پرسش‌ها و مدل پاسخ‌گو میان دو مسیر است؛ در نتیجه تفاوت جفت‌پاسخ‌ها به تغییر بافت از متن مرجع به رونویسی تشخیص گفتار نسبت داده می‌شود.



شکل ۲-۴ چارچوب ارزیابی وظیفه‌محور تشخیص گفتار در کاربردهای مبتنی بر مدل زبانی؛ بازطراحی شده بر اساس [۴]

این پژوهش برای خلاصه‌کردن اختلاف دو مسیر، معیار نرخ خطای پاسخ نرخ خطای کاربرد را پیشنهاد می‌کند:

$$AER = \frac{N_{\text{different answers}}}{N_{\text{questions}}}. \quad (11.2)$$

مقدار صفر در رابطه ۱۱.۲ به معنی برابری معنایی همه جفت‌پاسخ‌ها و مقدار یک به معنی اختلاف همه آن‌هاست؛ بنابراین مقدار کمتر بهتر است و در صورت گزارش درصدی، نتیجه در صد ضرب می‌شود. مزیت این معیار آن است که حذف یا جانشینی یک واژه مهم را بر اساس پیامد معنایی آن می‌سنجد، نه صرفاً تعداد ویرایش‌های رونویسی. نتایج مقاله نیز نشان می‌دهند کاهش نرخ خطای واژه الزاماً با کاهش هم‌اندازه نرخ خطای کاربرد یا بهبود رتبه مدل در کاربرد پایین‌دستی همراه نیست [۴].

ارزیابی پروژه حاضر بازپیاپی‌سازی عین نرخ خطای کاربرد نیست، بلکه نسخه‌ای سازگار شده و قابل‌بازتولید از منطق مقایسه متن مرجع و متن تشخیص گفتار است. برای هر یک از ۳۲۴ شناسه معنایی فارسی فلورز یک نامزد

پرسش و پاسخ به صورت خودکار ساخته شد؛ همه نامزدهای قابل استفاده به صورت انسانی بازبینی، ویرایش یا رد شدند و ۲۸۶ مورد نهایی منجمد شدند. پاسخ طلایی هر مورد باید یک عبارت دقیق از متن مرجع می بود. سپس گما ۲ با ۹ میلیارد پارامتر با دستور و تنظیمات ثابت، جداگانه از متن مرجع و رونویسی تشخیص گفتار پاسخ تولید کرد. به جای داوری یک مدل سوم، هر دو پاسخ با پاسخ طلایی و معیارهای قطعی تطابق دقیق و امتیاز افیک سنجیده شدند؛ حفظ عبارت پاسخ در رونویسی نیز مستقیماً اندازه گیری شد. این انتخاب وابستگی نتیجه به مدل داور را حذف می کند، اما دامنه سنجش را به پرسش های دارای پاسخ کوتاه و مشخص محدود می سازد.

۱۳-۲ مقایسه کارهای مرتبط

جدول ۲-۲ جمع بندی فشرده ادبیات را از دید نیاز پروژه نشان می دهد. ستون آخر بیان می کند هر گروه از پژوهش ها به کدام تصمیم طراحی یا ارزیابی منجر شده است.

جدول ۲-۲ ارتباط گروه های پژوهشی با تصمیم های پروژه حاضر

حوزه	شاهد اصلی	محدودیت برای کاربرد حاضر	نتیجه در طراحی پروژه
داده و معیار تشخیص گفتار فارسی	تنوع دامنه و شرایط ضبط رتبه مدل را تغییر می دهد	یک مجموعه آزمون نماینده همه مکالمه های واقعی نیست	گزارش جداگانه کامن ویس و فلورز و آزمون پایین دستی
مدل های چندزبانه تشخیص گفتار	انتقال میان زبانی نیاز به آموزش از ابتدا را کاهش می دهد	اندازه یا چندزبانه بودن، برتری روی فارسی را تضمین نمی کند	بنچمارک یکسان ایکس ال اس آر، ویسپر، فست کانفورمر و واسک
ارزیابی مدل زبانی فارسی	کیفیت به وظیفه و معیار وابسته است	امتیاز متن مرجع اثر خطای گفتار را نشان نمی دهد	دو وظیفه کنترل شده و آزمایش جداگانه انتشار خطا
اجرای محلی مدل زبانی	کوانتیزه سازی حافظه را کاهش می دهد	کیفیت و سرعت نسخه فشرده ممکن است متفاوت باشد	سنجش همان نسخه چهاربیتی مورد استفاده در خط لوله
تبدیل متن به گفتار فارسی	کیفیت داده و مدل بر طبیعی بودن و تلفظ اثر دارد	میانگین امتیاز نظر یا سرعت به تنهایی برای انتخاب کافی نیست	ارزیابی مشترک کیفیت بدون مرجع، بازشناسی مجدد و زمان
مدل های گفتار و زبان	تعامل صوتی مستقیم را ممکن می کنند	هزینه و مشاهده پذیری محدود برای سخت افزار پروژه	معماری ماژولار زنجیره ای همراه با کنترل ابهام و اجرای جریان
انتشار خطای تشخیص گفتار و مدل زبانی	اختلاف پاسخ در بافت مرجع و رونویسی، زبان معنایی را آشکار می کند	نرخ خطای کاربرد به سه نقش مدل زبانی و کیفیت داور وابسته است	پرسش های فارسی بازبینی شده و سنجش قطعی تطابق دقیق، امتیاز افیک و حفظ عبارت پاسخ

۱۴-۲ شکاف پژوهشی و جایگاه پروژه حاضر

بخش بزرگی از کارهای پیشین یکی از مؤلفه های تشخیص گفتار، مدل زبانی یا تبدیل متن به گفتار را مستقل بررسی می کنند. این نتایج برای انتخاب اولیه مفیدند، اما پاسخ نمی دهند ترکیب مدل ها روی یک رایانه شخصی چه کیفیت و تأخیری خواهد داشت. همچنین نرخ خطای واژه پایین مشخص نمی کند که اطلاعات ضروری پرسش برای مدل زبانی حفظ شده است و میانگین امتیاز نظر نیز حفظ دقیق متن تولیدی را تضمین نمی کند.

پروژه حاضر این فاصله را در چهار محور هدف می‌گیرد:

- مقایسه چند خانواده مدل با پروتکل و داده یکسان، به‌جای کنار هم قراردادن اعداد منتشرشده در منابع متفاوت؛
- انتخاب اجزا با توجه هم‌زمان به کیفیت، تأخیر و منابع اجرای محلی؛
- اندازه‌گیری انتشار خطای تشخیص گفتار به پاسخ مدل زبانی و تمایز خطای کلی از حذف اطلاعات مهم برای وظیفه؛
- و پیاده‌سازی خط لوله‌ای قابل ردیابی با رفع ابهام، حافظه اصلاحات و تولید گفتار جریانی.

بنابراین سهم پروژه معرفی یک معماری بنیادی جدید برای هر مدل نیست؛ سهم آن ارزیابی سازگار، انتخاب مستدل و یکپارچه‌سازی اجزا در یک دستیار صوتی فارسی محلی است. این صورت‌بندی دامنه ادعا را روشن می‌کند و معیارهای فصل آزمایش‌ها را مستقیماً به شکاف شناسایی‌شده پیوند می‌دهد.

۲-۱۵- جمع‌بندی

پژوهش‌های مرتبط نشان دادند عملکرد گفتار فارسی به داده و دامنه وابسته است، مدل زبانی باید روی وظایف فارسی و در نسخه اجرایی خود سنجیده شود و انتخاب تبدیل متن به گفتار نیازمند مشاهده هم‌زمان کیفیت، حفظ متن و سرعت است. مدل‌های یکپارچه گفتار و زبان مسیر مهمی در پژوهش‌اند، اما معماری زنجیره‌ای برای هدف محلی این پروژه کنترل‌پذیرتر است. بر همین اساس، فصل بعد معماری ماژولار، کنترل ابهام، گردش کار یک نوبت و جزئیات پیاده‌سازی سامانه را تشریح می‌کند.

فصل ۳

شرح پروژه

۳-۱- مقدمه

سامانه نهایی پروژه یک دستیار صوتی فارسی کاملاً محلی است که دریافت گفتار، تشخیص پایان جمله، بازشناسی گفتار، کنترل ابهام، تولید پاسخ و پخش گفتار را در یک چرخه پیوسته انجام می‌دهد. معماری عملیاتی نسخه نهایی و شاخه‌های تصمیم آن در شکل ۳-۱ نمایش داده شده‌اند.

انتخاب مدل عملیاتی با رتبه‌بندی مستقل مدل‌ها یکسان نیست. برای مثال، مدل بزرگ فست کانفورمر ترکیبی نمو^۱ در آزمون کامن‌ویس نسخه ۲۵ کمترین خطا را داشت، اما واسک به دلیل اجرای کامل روی پردازنده مرکزی، عملکرد بهتر روی فلورز و دسترسی به اطمینان واژه و فرضیه‌های چندگانه در خط لوله تعاملی انتخاب شد. به همین ترتیب، گما^۲ با ۹ میلیارد پارامتر به دلیل برتری در دو وظیفه کنترل‌شده فارسی و امکان بارگذاری نسخه چهاربیتی روی سخت‌افزار پروژه، مدل زبانی نسخه نهایی است.

در این فصل نیازمندی‌ها، اجزای معماری، وضعیت‌های کنترل مکالمه و مسیر داده در یک نوبت کامل تشریح می‌شوند.

۳-۲- نیازمندی‌های سامانه

۳-۲-۱- نیازمندی‌های عملکردی

نسخه نهایی باید بتواند وظایف زیر را انجام دهد:

- انتظار خودکار برای شروع گفتار و تشخیص پایان آن؛

- نگهداری بخشی کوتاه از صوت قبل و بعد از گفتار برای جلوگیری از حذف ابتدا یا انتهای واژه‌ها؛

^۱ STT Fa FastConformer Hybrid Transducer-CTC Large

- تبدیل صوت ورودی به تک‌کانال ۱۶ kHz با قالب مدولاسیون کد پالس شانزده‌بیتی و تقویت انتخابی نمونه‌های بسیار کم‌دامنه؛
- تولید متن اصلی، اطمینان واژه‌ها و حداکثر سه فرضیه تشخیص گفتار؛
- نرمال‌سازی محافظه‌کارانه نویسه‌های فارسی بدون حدس‌زدن یا تصحیح خودکار واژه‌ها؛
- تشخیص اختلاف‌های مهم میان فرضیه‌ها و درخواست رفع ابهام هدفمند؛
- بازسازی پرسش اصلی از پاسخ‌هایی مانند «اولی»، «دومی» یا تکرار مستقیم واژه صحیح؛
- نگهداری تاریخچه محدود مکالمه و حافظه جداگانه اصلاحات تأییدشده؛
- تولید پاسخ کوتاه فارسی با مدل زبانی محلی؛
- شروع تولید و پخش گفتار پیش از پایان کامل تولید متن؛
- و ثبت جزئیات تصمیم‌ها، زمان‌ها و خطاها در خروجی و فایل گزارش اجرا.

۲-۲-۳- نیازمندی‌های غیرعملکردی

نیازمندی‌های غیرعملکردی شامل اجرای بدون سرویس ابری، مصرف کنترل‌شده حافظه، تأخیر قابل‌قبول، قابلیت جایگزینی مؤلفه‌ها، قابلیت بازتولید آزمایش‌ها و حفظ قابلیت ردیابی خطا است. داده مکالمه تنها در حافظه نشست و فایل گزارش محلی نگهداری می‌شود. چون گزارش اجرا شامل متن تشخیص‌داده‌شده و پاسخ است، این فایل بخشی از داده خصوصی کاربر محسوب می‌شود و باید متناسب با نیاز حریم خصوصی مدیریت شود.

۳-۳- معماری ماژولار


معماری نرم‌افزار به پنج لایه تقسیم شده است:

۱. لایه صوت برای دریافت میکروفون، تشخیص فعالیت صوتی و پخش؛
۲. لایه تشخیص گفتار برای آماده‌سازی صوت، رمزگشایی و نمایش ساخت‌یافته فرضیه‌ها؛
۳. لایه کنترل مکالمه برای ارزیابی ریسک، رفع ابهام و حافظه؛
۴. لایه تولید شامل مدل زبانی و تبدیل متن به گفتار؛

۵. و لایه هماهنگ‌کننده برای اتصال مراحل، ثبت معیارها و مدیریت خطا.

قرارداد میان لایه‌ها بر داده‌های مشخص استوار است. خروجی تشخیص گفتار صرفاً یک رشته نیست و شامل متن اصلی، واژه‌ها همراه با اطمینان و فرضیه‌های جایگزین همراه با امتیاز رمزگشا است. تصمیم کنترل مکالمه نیز یکی از سه حالت «پاسخ»، «رفع ابهام» یا «درخواست تکرار» را تولید می‌کند. به این ترتیب، مدل زبانی فقط هنگامی فراخوانی می‌شود که پرسش خالی نباشد و ابهام مهم حل شده باشد.

شکل ۳-۱ علاوه بر مسیر اصلی داده، نقش حافظه نشست و ثبت معیارها را نیز نشان می‌دهد. پیکان‌های پیوسته مسیر اجرای نوبت و پیکان‌های خط‌چین وابستگی‌های کمکی را نمایش می‌دهند. شاخه «پاسخ» به تولید متن پاسخ می‌رسد، درحالی‌که دو شاخه دیگر بدون ارسال متن نامطمئن به مدل زبانی، پیام کوتاه رفع ابهام یا درخواست تکرار را پخش می‌کنند.



شکل ۳-۱ گردش کار و جریان تصمیم یک نوبت در چت‌بات فارسی

۴-۳- دریافت صوت و تشخیص انتهای گفتار

جریان میکروفون با نرخ ۱۶ kHz، تک‌کاناله و قالب اعشاری عدد اعشاری ۳۲ بیتی در قطعه‌های ۵۱۲ نمونه‌ای خوانده می‌شود. مدل سیلرو برای تشخیص فعالیت صوتی در قالب قالب تبادل شبکه عصبی روی پردازنده مرکزی اجرا و برای هر قطعه احتمال وجود گفتار را محاسبه می‌کند. آشکارساز انتهای جمله از چهار نوع محدودیت زمانی استفاده می‌کند:

- حداقل ۱۵۰ ms گفتار برای آغاز ضبط؛

- ۳۰۰ ms پیش‌نگهدار برای حفظ ابتدای جمله؛

- ۹۰۰ ms سکوت برای اعلام پایان؛

• و ۲۰۰ ms پس‌نگهدار برای حفظ انتهای جمله.

حداکثر طول هر نوبت ۳۰ ثانیه و آستانه پیش‌فرض تشخیص فعالیت صوتی برابر ۰.۵ است. این طراحی جایگزین ضبط دستی زمان ثابت شده و پس از پایان پخش پاسخ، سامانه دوباره به حالت انتظار برای گفتار بازمی‌گردد.

۳-۵- آماده‌سازی صوت و تشخیص گفتار

صوت ذخیره‌شده پیش از رمزگشایی به تک‌کانال و نرخ نمونه‌برداری هدف تبدیل می‌شود. برای نمونه‌های کم‌دامنه یک پروفایل محدود تقویت صوت تعریف شده است. در تنظیم عملیاتی فعلی، اگر ریشه میانگین مربعات کمتر از منفی ۴۵ dBFS باشد، دامنه به سوی منفی ۲۴ dBFS تقویت می‌شود؛ با این حال افزایش بهره از ۴۰ dB بیشتر نیست و ۱ dB فضای خالی قله حفظ می‌شود. این قاعده تنها برای صوت‌های بسیار ضعیف فعال است تا روی نمونه‌های عادی پردازش غیرضروری اعمال نشود.

مدل فارسی واسک نسخه ۴۲۰۰ صوت را روی پردازنده مرکزی رمزگشایی می‌کند. واسک اطمینان واژه را در حالت عادی و امتیاز فرضیه‌های جایگزین را در حالت چندفرضیه‌ای از دو مسیر متفاوت ارائه می‌کند. بنابراین، وقتی بیش از یک فرضیه درخواست شده باشد، صوت دو بار با یک مدل آکوستیکی کش‌شده رمزگشایی و سپس نتایج ادغام می‌شوند. متن و اطمینان واژه از گذر اصلی و حداکثر سه فرضیه از گذر دوم نگهداری می‌شود. کاربر می‌تواند برای کاهش تأخیر تعداد فرضیه‌ها را به یک کاهش دهد.

۳-۶- کنترل ریسک و رفع ابهام

انتخاب کورکورانه فرضیه دارای بالاترین امتیاز رمزگشا در آزمایش‌ها باعث افزایش خطا شد. از این‌رو، سیاست سامانه محافظه‌کارانه است: متن اصلی حفظ می‌شود مگر آنکه حافظه اصلاح صریح کاربر از یک فرضیه واقعی واسک پشتیبانی کند.

در حالت عادی، واژه‌های با اطمینان کمتر از آستانه با اختلاف فرضیه‌ها مقایسه می‌شوند. اگر اختلاف در یک بخش معنادار باشد، سامانه به جای ارسال متن مشکوک به مدل زبانی، پرسش کوتاهی مانند زیر می‌سازد:

«منظورتان «شریعت» یا «شریف» است؟»

فقط اتکا به اطمینان واژه برای نام‌ها، اعداد و نفی کافی نیست؛ زیرا ممکن است خطای مهم با اطمینان بالا رخ دهد. به همین دلیل، اختلاف فرضیه‌ها پس از نشانه‌هایی مانند «دانشگاه»، «شهر»، «شرکت»، «دکتر»، «مدل» و «شماره»، و نیز اختلاف عدد یا نفی، حتی در اطمینان بالا نیز می‌تواند رفع ابهام را فعال کند. در مقابل، اختلاف‌های سبکی شناخته‌شده مانند «لطفاً» و «خواهشاً» نادیده گرفته می‌شوند.

پاسخ رفع ابهام ممکن است خود از نظر تشخیص گفتار دشوار باشد. سامانه متن اصلی و فرضیه‌های مجاز پاسخ را بررسی می‌کند و پاسخ مستقیم، عبارت‌هایی مانند «منظورم ... بود» و گزینه‌های ترتیبی «اولی»، «دومی» و «سومی» را می‌پذیرد. پس از حل ابهام، پرسش نخست با گزینه تأییدشده بازسازی و برای مدل زبانی ارسال می‌شود.

۳-۷- تاریخچه و حافظه نشست

دو نوع حافظه مستقل نگهداری می‌شود. تاریخچه عمومی شامل حداکثر شش نوبت کامل کاربر و دستیار است. این تاریخچه برای ارجاع‌ها و پرسش‌های ادامه‌دار به مدل زبانی داده می‌شود. اگر ورودی از حد ۲۰۴۸ توکن بیشتر شود، قدیمی‌ترین جفت کامل کاربر و دستیار حذف می‌شود تا ترتیب نقش‌ها در قالب گفت‌وگوی گما حفظ شود. نوع دوم، حافظه ساخت‌یافته و محدود به حداکثر دوازده مورد است. اصلاح صریح کاربر همراه با متن زمینه در این حافظه ذخیره می‌شود و حتی پس از خروج نوبت اصلی از تاریخچه شش‌نوبتی باقی می‌ماند. استفاده از اصلاح به همان زمینه محدود است تا یک جایگزینی موضعی به قاعده عمومی و نادرست تبدیل نشود. این حافظه همچنین می‌تواند در نوبت‌های بعدی یکی از فرضیه‌های واقعی رمزگشا را، در صورت تطابق واژه و زمینه، انتخاب کند.

۳-۸- تولید پاسخ و گفتار جریانی

مدل دستورمحور گما ۲ با ۹ میلیارد پارامتر و وزن‌های چهاربیتی محلی اجرا می‌شود. دستور سامانه پاسخ فارسی، کوتاه و مناسب گفتار را الزام می‌کند و از تولید حروف لاتین در خروجی صوتی می‌کاهد. نمونه‌گیری تصادفی غیرفعال است و خروجی حداکثر ۱۵۰ توکن دارد.

برای کاهش زمان انتظار، متن کامل پیش از آغاز تبدیل متن به گفتار منتظر نمی‌ماند. توکن‌های تولیدشده در یک بافر عبارت جمع می‌شوند. نقطه، علامت سؤال و مرزهای سخت، عبارت را فوراً می‌بندند؛ ویرگول پس از حداقل ۳۰ نویسه و نبود مرز پس از حداکثر ۶۰ نویسه موجب تقسیم می‌شود. عبارت‌های آماده به نخ تولید پایپر فرستاده و قطعه‌های مدولاسیون کد پالس به‌ترتیب در نخ پخش مصرف می‌شوند. هم‌زمان یک فایل موجی کامل نیز نوشته می‌شود. بدین ترتیب، تولید متن، تولید صوت و پخش بخشی از زمان خود را هم‌پوشان می‌کنند.

پیش از تبدیل متن به گفتار، اعداد لاتین، فارسی و عربی به واژه‌های فارسی تبدیل، نویسه‌ها یکسان و نمادهای نامناسب حذف می‌شوند. اعداد صحیح، علامت منفی، جداکننده هزار و اعشار تا شش رقم به‌صورت گفتاری پشتیبانی می‌شوند.

۳-۹- جریان یک نوبت مکالمه

جریان تصمیم در هر نوبت به‌صورت زیر است:

۱. تشخیص فعالیت صوتی شروع و پایان گفتار را تعیین و صوت را ذخیره می‌کند؛

۲. صوت آماده‌سازی و توسط واسک رمزگشایی می‌شود؛

۳. متن، اطمینان‌ها و فرضیه‌ها نرمال‌سازی می‌شوند؛

۴. حافظه اصلاح برای بازرتبه‌بندی محدود بررسی می‌شود؛

۵. کنترل ریسک یکی از سه عمل پاسخ، رفع ابهام یا تکرار را انتخاب می‌کند؛

۶. در مسیر پاسخ، تاریخچه و حافظه به گما افزوده می‌شوند؛

۷. خروجی مدل زبانی به عبارت‌های قابل گفتار تقسیم می‌شود؛

۸. پایپر عبارت‌ها را تولید و پخش می‌کند؛

۹. و معیارها و رخدادها در گزارش چرخشی ذخیره می‌شوند.

۳-۱۰- ثبت معیارها و حریم خصوصی

برای هر نوبت زمان تشخیص گفتار، میانگین اطمینان واژه، تعداد فرضیه‌ها، فعال‌شدن رفع ابهام، زمان کل تولید مدل زبانی، زمان نخستین توکن، زمان نخستین عبارت، زمان نخستین صوت، تعداد عبارت‌ها و زمان کل تبدیل متن به گفتار ثبت می‌شود. گزارش‌ها در فایل یونی‌کد هشت‌بیتی چرخشی با اندازه پیش‌فرض ۵ MB و سه نسخه پشتیبان نگهداری می‌شوند.

این اطلاعات برای یافتن گلوگاه و بازتولید خطا ضروری است، اما به دلیل وجود متن مکالمه نباید بدون کنترل در محیط اشتراکی منتشر شود.

۳-۱۱- پیاده‌سازی سامانه

۳-۱۱-۱- نمای کلی پیاده‌سازی

پیاده‌سازی سامانه با زبان پایتون و به‌صورت مجموعه‌ای از ماژول‌های مستقل انجام شده است. نقطه ورود اصلی برنامه تنها حلقه مکالمه را آغاز می‌کند و جزئیات مدل‌ها در زیرسامانه‌های صوت، تشخیص گفتار، کنترل مکالمه، مدل زبانی و تبدیل متن به گفتار جدا شده‌اند. وزن مدل‌ها و داده‌های تولیدی محلی هستند و اجرای عادی به فراخوانی رابط برنامه‌نویسی ابری نیاز ندارد.

۱۲-۳- تنظیمات و قابلیت بازپیکربندی

مسیر مدل‌های تشخیص گفتار، مدل زبانی بزرگ، تبدیل متن به گفتار و تشخیص فعالیت صوتی، دستگاه میکروفون، فرمان پخش صوت، حدود زمانی تشخیص فعالیت صوتی، تعداد فرضیه‌های تشخیص گفتار، آستانه‌های رفع ابهام، طول ورودی و خروجی مدل زبانی، طول عبارت‌های تبدیل متن به گفتار و تنظیمات گزارش‌گیری همگی با متغیر محیطی قابل تغییر هستند. این روش از قراردادن مسیرهای وابسته به یک رایانه در منطق برنامه‌جولوگیری می‌کند.

مقادیر اصلی نسخه ارزیابی شده در جدول ۱-۳ آمده است.

جدول ۱-۳ تنظیمات پیش‌فرض خط لوله اجرایی

پارامتر	مقدار
نرخ نمونه‌برداری	۱۶ kHz
آستانه تشخیص فعالیت صوتی	۰.۵
کمینه مدت گفتار	۱۵۰ ms
سکوت انتهای نوبت	۹۰۰ ms
مدت پیش‌نگهدار	۳۰۰ ms
مدت پس‌نگهدار	۲۰۰ ms
بیشینه مدت نوبت	۳۰ s
تعداد فرضیه‌های تشخیص گفتار	۳
آستانه اطمینان واژه	۰.۶۵
شکاف امتیاز رمزگشا	۱.۰
بیشینه توکن ورودی مدل زبانی	۲۰۴۸
بیشینه توکن خروجی مدل زبانی	۱۵۰
کمینه نرم طول عبارت تبدیل متن به گفتار	۳۰ نویسه
بیشینه طول عبارت تبدیل متن به گفتار	۶۰ نویسه

آزمایش انتخاب پارامتر در فصل چهارم، آستانه اطمینان واژه ۰.۴۵ و شکاف امتیاز رمزگشا ۰.۵ را روی بخش توسعه انتخاب کرد، اما نرخ رفع ابهام آن روی داده نگه‌داشته‌شده از قید عملیاتی عبور کرد. از این‌رو تنظیم اجرایی محافظه‌کارانه با آستانه اطمینان ۰.۶۵ و شکاف امتیاز ۱.۰ در کد حفظ شده و نتیجه شبکه پارامتر به‌عنوان شواهد تحقیقاتی، نه جایگزینی قطعی تنظیم، گزارش می‌شود.

۱۳-۳- پیاده‌سازی دریافت صوت و تشخیص فعالیت صوتی

کلاس تشخیص فعالیت صوتی سیلرو یک نشست اجرایی روی پردازنده مرکزی می‌سازد و حالت بازگشتی مدل و ۶۴ نمونه زمینه را میان قطعه‌ها نگه می‌دارد. کلاس آشکارساز مرز نوبت احتمال‌های قاب‌به‌قاب را به رخدادهای «آغاز» و «پایان» تبدیل می‌کند.

بافر حلقوی پیش‌نگهدار تضمین می‌کند قاب‌هایی که پیش از قطعی‌شدن تشخیص آغاز دریافت شده‌اند از بین نروند. پس از آغاز، تمام قاب‌ها تا سکوت پایانی یا رسیدن به حداکثر طول نوبت جمع می‌شوند. سکوت اضافی حذف و مقدار پس‌نگهدار حفظ می‌شود. فایل حاصل با زیرنوع مدولاسیون کد پالس شانزده‌بیتی نوشته می‌شود. اگر دستگاه میکروفون پیکربندی شده باز نشود، برنامه فهرست دستگاه‌های ورودی را نمایش می‌دهد و یک بار با دستگاه پیش‌فرض تلاش می‌کند. مسیر فشردن کلید برای شروع و پایان ضبط نیز به‌عنوان ابزار تشخیصی جداگانه حفظ شده است.

۱۴-۳- پیاده‌سازی آماده‌سازی و تشخیص گفتار

تابع آماده‌سازی، فایل را با کتابخانه فایل صوت می‌خواند، کانال‌ها را میانگین می‌گیرد و در صورت نیاز با `resample_poly` به ۱۶ kHz تبدیل می‌کند. مقادیر نامعتبر عددی حذف و پس از تقویت انتخابی، سیگنال به بازه مجاز بریده و به بایت‌های مدولاسیون کد پالس شانزده‌بیتی با ترتیب کم‌ارزش تبدیل می‌شود. خروجی علاوه بر صوت، مدت، نرخ‌های نمونه‌برداری، ریشه میانگین مربعات ورودی و خروجی و بهره اعمال شده را نگه می‌دارد. مدل واسک در نخستین درخواست بارگذاری و با حافظه نهان `lru_cache` برای نوبت‌های بعدی استفاده می‌شود. صوت در قطعه‌های ۸۰۰۰ بیتی به رمزگشا داده می‌شود و نتایج میانی و نهایی به یک ساختار واحد ادغام می‌شوند. سه کلاس داده برای خروجی تعریف شده‌اند:

- ساختار واژه‌بازشناسی‌شده: متن، اطمینان و زمان آغاز و پایان واژه؛

- ساختار فرضیه جایگزین: متن فرضیه، واژه‌ها و امتیاز رمزگشا؛

- ساختار نتیجه‌بازشناسی: متن اصلی، واژه‌ها و مجموعه فرضیه‌ها.

در حالت چندفرضیه‌ای، یک گذر عادی برای حفظ متن کمینه‌سازی خطر بیز و اطمینان واژه و یک گذر چندفرضیه‌ای برای امتیاز فرضیه‌ها اجرا می‌شود. ادغام دو گذر متن اصلی را تغییر نمی‌دهد و فرضیه‌های تکراری را حذف می‌کند.

۱۵-۳ - نرمال سازی محافظه کارانه فارسی

پس پردازش تشخیص گفتار فقط تفاوت های نمایشی امن را یکسان می کند: نرمال سازی سازگاری یونی کد، تبدیل یای عربی و الف مقصوره به یای فارسی، تبدیل کاف عربی به کاف فارسی، تبدیل رقم های فارسی و عربی به رقم لاتین داخلی، حذف علائم جهت نمای نامرئی و ادغام فاصله های پیاپی. نیم فاصله و علائم نگارشی حفظ می شوند. همین تبدیل روی متن اصلی، واژه ها و تمام فرضیه ها اعمال می شود تا شاخص واژه و شواهد اطمینان هم راستا بمانند.

این ماژول عمداً تصحیح واژگانی انجام نمی دهد. تغییر حدسی واژه ممکن است یک نام، عدد یا نفی صحیح را خراب کند و منشأ خطا را از دید ارزیابی پنهان سازد.

۱۶-۳ - پیاده سازی ارزیابی ریسک تشخیص گفتار

کنترل ریسک از هم ترازی دنباله ای متن اصلی و فرضیه های داخل شکاف امتیاز استفاده می کند. در مسیر نخست، تنها اختلاف هایی بررسی می شوند که با واژه کم اطمینان هم پوشانی دارند. در مسیر دوم، اختلاف در عدد، نفی یا جایگاه نام بعد از یک نشانه معنایی می تواند بدون شرط اطمینان رفع ابهام را فعال کند. برای کاهش پرسش های غیر ضروری، سه قاعده اعمال می شود: شکل های املائی هم ارز یکسان تلقی می شوند، اختلاف واژه های صرفاً مؤدبانه حذف می شود و تکرار یک اسم در همان جمله می تواند از یک اختلاف غیر حیاتی پشتیبانی کند. سیاست هرگز متن تازه ای اختراع نمی کند و گزینه ها حتماً از فرضیه های واقعی رمزگشا می آیند. هنگام وجود ابهام، یک شیء تصمیم با دلیل، واژه های کم اطمینان، گزینه ها و پرسش فارسی تولید می شود. پاسخ نوبت بعد با گزینه ها و کلمات ترتیبی بررسی می شود. اگر دقیقاً یک گزینه از متن اصلی یا فرضیه مجاز پاسخ پشتیبانی شود، پرسش اولیه بازسازی می شود؛ در غیر این صورت رفع ابهام ناموفق تلقی و متن جدید به عنوان نوبت مستقل پردازش می شود.

۱۷-۳ - بازرتبه بندی محدود با حافظه اصلاح

ماژول بازرتبه بندی فقط وقتی یک فرضیه جایگزین را انتخاب می کند که تمام شروط زیر برقرار باشند:

۱. مورد حافظه از رفع ابهام صریح کاربر به دست آمده باشد؛
۲. واژه قبلی در متن اصلی حاضر باشد؛
۳. واژه تأیید شده در یک فرضیه واقعی و داخل شکاف امتیاز باشد؛

۴. و زمینه پرسش با زمینه ذخیره شده اشتراک واژگانی داشته باشد.

پس از انتخاب، فرضیه تأیید شده تنها فرضیه خروجی قرار می‌گیرد تا سامانه در همان اختلاف دوباره پرسش رفع ابهام نسازد. این راهبرد تفاوت مهمی با تصحیح خودکار آزاد دارد: هر تغییر به شواهد رمزگشا و تأیید قبلی کاربر وابسته است.

۳-۱۸- پیاده‌سازی نشست و کنترل مکالمه

کلاس نشست گفتگو تاریخچه را در یک صف دوسویه شش‌نوبتی و حافظه ساخت‌یافته را در یک صف دوسویه دوازده‌موردی نگه می‌دارد. وضعیت رفع ابهام در انتظار، متن و گزینه‌های پرسش حل‌نشده را فقط برای نوبت بعد حفظ می‌کند. ثبت یک اصلاح با کلید و زمینه یکسان، مقدار قدیمی را جایگزین می‌کند تا حافظه متناقض انباشته نشود.

تابع کنترل مکالمه پس از نرمال‌سازی و بازرتبه‌بندی، وضعیت را تعیین می‌کند. متن خالی به درخواست تکرار، ابهام معتبر به رفع ابهام و متن مطمئن یا رفع ابهام حل‌شده به تولید پاسخ هدایت می‌شود. این تابع متنی و مستقل از مدل‌های سنگین است؛ بنابراین همان منطق در اجرای واقعی و مجموعه آزمون چندنوبتی استفاده می‌شود.

۳-۱۹- پیاده‌سازی مدل زبانی

توکن‌ساز و مدل گما ۲ با ۹ میلیارد پارامتر از مسیر محلی بارگذاری می‌شوند. دستگاه در صورت دسترسی کودا و در غیر این صورت پردازنده مرکزی است؛ نوع محاسبه نیز به ترتیب عدد اعشاری ۱۶ بیتی یا عدد اعشاری ۳۲ بیتی انتخاب می‌شود. نسخه وزن عملیاتی از قبل چهاربیتی شده است.

قالب استاندارد مدل گما نقش مستقل «دستور سامانه» را در این پیکربندی نمی‌پذیرد؛ بنابراین دستورهای سامانه بدون تغییر نسخه ذخیره‌شده تاریخچه به ابتدای نخستین پیام کاربر افزوده می‌شوند. حافظه تأیید شده علاوه بر ابتدای متن، نزدیک پرسش فعلی نیز تکرار می‌شود تا در تاریخچه طولانی نادیده گرفته نشود. اگر نوبت از رفع ابهام بازسازی شده باشد، مدل دستور کوتاهی برای تکرار صریح واژه، عدد یا نفی تأیید شده دریافت می‌کند.

دو رابط تولید وجود دارد: رابط کامل برای آزمون‌ها و پیام‌های ساده، و رابط جریانی کتابخانه ترنسفورمرها. تولید در یک نخ جدا انجام می‌شود و قطعه‌های متن به محض رمزگشایی به مصرف‌کننده داده می‌شوند. پاسخ نهایی از خط نخست گرفته، نشانه‌های قالب‌بندی حذف و فاصله‌ها یکسان می‌شوند.

۳-۲۰- پیاده‌سازی تبدیل متن به گفتار جریانی

مدل فارسی پایپر از فایل‌های قالب تبادل شبکه عصبی محلی بارگذاری می‌شود. پیش‌پردازش شامل نوشتاری کردن اعداد، نرمال‌سازی هضم، یکسان‌سازی نویسه‌ها، حذف نمادهای ناسازگار و ادغام فاصله است. کلاس بافر عبارت، قطعه‌های نامنظم خروجی مدل زبانی را به عبارت‌های قابل‌گفتار تبدیل می‌کند. کلاس خروجی گفتار جریانی دو صف و دو نخ دارد: نخ نخست عبارت‌ها را با پایپر به قطعه‌های مدولاسیون کد پالس تبدیل می‌کند و نخ دوم همان قطعه‌ها را به‌ترتیب در جریان خام خروجی پخش و در فایل خروجی ذخیره می‌کند. ناسازگاری نرخ نمونه‌برداری، پهنای نمونه یا تعداد کانال‌ها در میانه جریان به‌عنوان خطا ثبت می‌شود. پرسش رفع ابهام و پیام تکرار به دلیل کوتاه‌بودن از مسیر تک‌فایلی ساده عبور می‌کنند؛ پاسخ معمولی از مسیر جریانی استفاده می‌کند.

۳-۲۱- هماهنگ‌سازی، معیارها و مدیریت خطا

تابع اصلی هماهنگ‌کننده کل نوبت را مدیریت می‌کند. خروجی آن شامل پرسش خام، جزئیات کامل تشخیص گفتار، تصمیم کنترل، پرسش بازسازی‌شده، تصویر حافظه، پاسخ، مسیر صوت و معیارهای زمان است. زمان نخستین توکن، نخستین عبارت و نخستین صوت جدا از زمان کل ثبت می‌شوند؛ زیرا در سامانه جریانی، تجربه انتظار کاربر با زمان کل تولید یکسان نیست. ورودی خالی موجب پیام تکرار می‌شود و مدل زبانی فراخوانی نمی‌شود. ابهام مهم نیز به مسیر رفع ابهام کوتاه هدایت می‌شود. خطاهای سطح حلقه ثبت و بدون بسته‌شدن دائمی برنامه به کاربر اعلام می‌شوند. گزارش چرخشی یونی‌کد هشت‌بیتی هم در کنسول و هم در فایل نوشته می‌شود.

۳-۲۲- آزمون‌پذیری و جداسازی پژوهش از اجرا

آزمون‌های واحد، آماده‌سازی صوت، نرمال‌سازی متن، انتخاب پارامتر، بازرتبه‌بندی، ارزیابی ریسک، تشخیص فعالیت صوتی، تبدیل عدد و قطعه‌بندی متن تبدیل متن به گفتار را بدون اجرای کامل مدل‌های سنگین بررسی می‌کنند. مجموعه چندنوبتی نیز از همان تابع کنترل متنی نسخه اجرا استفاده می‌کند. اسکرپت‌های ارزیابی پژوهشی خروجی‌های نسخه‌بندی‌شده، نقاط واریسی افزایشی، فراداده، بخش‌های جداگانه توسعه و نگه‌داشته‌شده و خلاصه‌های ماشینی تولید می‌کنند. فایل‌های نتیجه قبلی بازنویسی نمی‌شوند و برای مراحل مهم هش یکپارچگی نگهداری شده است. این طراحی امکان ردیابی دقیق هر عدد گزارش‌شده در فصل بعد را فراهم می‌کند.

۳-۲۳- جمع‌بندی

پیاده‌سازی نهایی شامل ضبط خودکار، مدل سیلرو برای تشخیص فعالیت صوتی، آماده‌سازی محدود صوت، رمزگشایی دوگذر واسک، کنترل ریسک، حافظه اصلاح، Gemma 2 9B و پایپر جریانی است. خط لوله علاوه بر تولید پاسخ، شواهد تصمیم و زمان‌های مرحله‌ای را نیز برمی‌گرداند. در فصل بعد، نتایج مستقل مدل‌ها و آزمایش‌های انتها به انتهای انتشار خطا و بهبودهای پیاده‌سازی در فصل بعد ارائه می‌شوند.

فصل ۴

نتایج

۴-۱- مقدمه

ارزیابی پروژه در دو سطح انجام شده است. در سطح نخست، مدل‌های تشخیص گفتار، مدل زبانی بزرگ و تبدیل متن به گفتار مستقل از یکدیگر مقایسه شدند. در سطح دوم، انتشار خطای تشخیص گفتار به پاسخ مدل زبانی، اثر پیش‌پردازش صوت، ظرفیت فرضیه‌های چندگانه، بازیابی مبتنی بر اصلاح کاربر و رفتار چندنوبتی سامانه بررسی شد.

برای جلوگیری از آمیختن نتیجه‌ها، هر جدول مجموعه داده و دامنه خود را دارد. برتری یک مدل روی کامن‌ویس به معنی برتری آن روی فلورز یا در خط لوله تعاملی نیست. همچنین مقدارهای کران بالای اوراکل فقط ظرفیت شواهد موجود را نشان می‌دهند و سیاست قابل استفاده در زمان اجرا محسوب نمی‌شوند.

۴-۲- کنترل نشت داده میان آموزش و آزمون

منظور از نشت داده در این فصل، ورود مستقیم یا غیرمستقیم نمونه‌های آزمون به فرایند آموزش، ریزتنظیم یا انتخاب ابرپارامترهای مدل است؛ رخدادی که می‌تواند نتیجه را خوش‌بینانه‌تر از عملکرد واقعی نشان دهد. در سطح این پروژه، همه نقاط واریسی پیش از اجرای بنچمارک ثابت شدند و هیچ‌یک با نمونه‌های کامن‌ویس نسخه ۲۵ یا فلورز آموزش یا ریزتنظیم نشدند. برای تشخیص گفتار از بخش‌های آزمون رسمی و برای تبدیل متن به گفتار از یک زیرمجموعه ثابت ۱۰۵۲ متنی استفاده شد. این کنترل از ایجاد نشت در کد و آزمایش‌های خود پروژه جلوگیری می‌کند؛ با این حال، برای نقاط واریسی منتشرشده باید شفافیت داده آموزشی سازنده نیز جداگانه بررسی شود.

۴-۲-۱- مدل‌های تشخیص گفتار

برای مدل نمو، مستند سازنده ریزتنظیم روی بخش فارسی کامن‌ویس نسخه ۱۵ با یک تقسیم‌بندی سفارشی را اعلام می‌کند [۱۰]. چون فهرست شناسه‌های آن تقسیم‌بندی منتشر نشده و نسخه‌های بعدی کامن‌ویس ممکن است بخشی از ضبط‌های پیشین را حفظ کنند، تفاوت شماره نسخه به‌تنهایی جدایی نمونه‌ها را ثابت نمی‌کند. ازاین‌رو نتیجه این مدل روی کامن‌ویس نسخه ۲۵ به‌عنوان ارزیابی درون‌دامنه گزارش شده و نتیجه آن روی بخش آزمون رسمی فلورز، که پیکره‌ای مستقل است، شاهد اصلی تغییر دامنه محسوب می‌شود [۴۳]. برای مدل ویو۲وک ۲ فارسی نیز وضعیت مشابه است: ریزتنظیم روی کامن‌ویس نسخه ۱۰۶ اعلام شده است [۱۱]، بنابراین عدم هم‌پوشانی تاریخی آن با نسخه ۲۵ بدون دسترسی به فهرست آموزش قابل اثبات نیست و نتیجه فلورز برای آن شاهد مستقل‌تری فراهم می‌کند.

برای ویسپر، جزئیات نمونه‌به‌نمونه مجموعه بزرگ آموزش عمومی نشده است [۱۲]؛ برای واسک فارسی نسخه ۴۲۰ نیز فهرست کامل داده آموزش در مستند رسمی وجود ندارد [۱۳]. در نتیجه، برای این دو مدل نیز ادعای حذف قطعی هم‌پوشانی بالادستی مطرح نمی‌شود. کنترل قابل انجام در پروژه شامل استفاده بدون ریزتنظیم، ثابت نگه‌داشتن وزن‌ها و گزارش نتیجه روی دو پیکره آزمون مستقل بود. بنابراین برای هر چهار مدل تشخیص گفتار، نشأت محلی رخ نداده است، ولی نبود نشأت در آموزش اولیه فقط در حد اطلاعات منتشرشده سازندگان قابل بررسی است.

۴-۲-۲- مدل‌های تبدیل متن به گفتار

در ارزیابی تبدیل متن به گفتار، نقاط واری کامترا، ام‌ام‌اس و پایپر بدون آموزش مجدد استفاده شدند. زیرمجموعه ۱۰۵۲ تایی یک بار از بخش آزمون کامن‌ویس نسخه ۲۵ انتخاب و عیناً برای هر سه مدل تکرار شد. تنها متن مرجع به مدل‌ها داده شد و صوت اصلی کامن‌ویس هیچ‌گاه ورودی آموزش یا تولید این مدل‌ها در پروژه نبود؛ همه فایل‌های ارزیابی، خروجی تازه همان نقاط واری ثابت بودند. مدل ام‌ام‌اس طبق گزارش سازنده با داده گفتاری حاصل از خوانش متون عمومی مذهبی توسعه یافته و کامن‌ویس به‌عنوان داده آموزش مدل تبدیل متن به گفتار فارسی آن اعلام نشده است [۱۹، ۴۴]. بنابراین برای ام‌ام‌اس هم‌پوشانی شناخته‌شده‌ای در سطح پیکره وجود ندارد. در مقابل، صفحه مدل کامترا فقط برچسب مجموعه فارسی تبدیل متن به گفتار را ارائه می‌کند و فهرست نمونه‌های آموزش را منتشر نمی‌کند [۴۵]. صفحه صدای پایپر نیز اعلام می‌کند که صدای فارسی جیرو از یک مدل ویتس فارسی ریزتنظیم شده است، اما فهرست کامل جمله‌ها و فایل‌های آموزش را در اختیار نمی‌گذارد [۴۶]. ازاین‌رو برای کامترا و پایپر امکان تطبیق شناسه‌به‌شناسه با ۱۰۵۲ متن آزمون وجود نداشت و حذف مطلق هم‌پوشانی بالادستی قابل تضمین نیست.

بازشناسی مجدد صوت‌های مصنوعی با مدل نمو نیز باید با همین احتیاط تفسیر شود، زیرا این ارزیاب روی نسخه‌ای قدیمی‌تر از خانواده کامن‌ویس ریزتنظیم شده است. استفاده از یک ارزیاب و متن‌های یکسان، مقایسه نسبی سه مدل تبدیل متن به گفتار را منصفانه نگه می‌دارد، اما نرخ خطای واژه و نویسه حاصل یک آزمون نهایی کاملاً مستقل از دامنه آموزش نیست. همچنین چون همین بنچمارک در انتخاب مدل عملیاتی استفاده شده است، ارزیابی نهایی آینده باید روی گفتار و متن فارسی تازه و کنار گذاشته‌شده، ترجیحاً همراه با داوری انسانی، تکرار شود.

۳-۴ ارزیابی مستقل تشخیص گفتار

۳-۴-۱ مجموعه کامن‌ویس نسخه ۲۵

بخش آزمون فارسی کامن‌ویس نسخه ۲۵ شامل ۱۰۵۱۹ نمونه با مجموع ۵۲,۰۴۷.۲۸ ثانیه، معادل حدود ۱۴.۴۶ ساعت گفتار بود. چهار مدل با معیارهای نرخ خطای واژه، نرخ خطای نویسه، ضریب زمان واقعی، تأخیر متوسط، حافظه پردازنده گرافیکی و زمان کل استنتاج مقایسه شدند. نتایج این مقایسه در جدول ۴-۱ آمده است.

جدول ۴-۱ نتایج تشخیص گفتار روی مجموعه فارسی کامن‌ویس نسخه ۲۵

مدل	نرخ خطای واژه (درصد)	نرخ خطای نویسه (درصد)	ضریب زمان واقعی	تأخیر (ثانیه)	حافظه گرافیکی (گیگابایت)	زمان کل (ثانیه)
NeMo STT Fa FastConformer Hybrid Transducer-CTC Large	12.33%	3.79%	0.0275	0.1359	0.88	1429.43
Vosk fa-0.42	22.34%	5.93%	0.3051	1.5098	0.00	15881.76
Wav2Vec2 XLSR Persian v3	26.15%	12.05%	0.0150	0.0744	1.64	782.60
Whisper large-v3	36.77%	10.64%	0.2944	1.4568	6.70	15324.19

در جدول ۴-۱ مقدار کمتر در همه ستون‌های عددی مطلوب است. نرخ خطای واژه و نویسه دقت محتوایی را می‌سنجند، درحالی‌که ضریب زمان واقعی، تأخیر و زمان کل هزینه زمانی اجرا را نشان می‌دهند. مقدار صفر برای حافظه گرافیکی واسک به معنی اجرای آن روی پردازنده مرکزی است، نه مصرف‌کردن حافظه اصلی سامانه؛ بنابراین جدول باید به صورت یک مصالحه میان دقت، سرعت و هزینه استقرار خوانده شود.

مدل بزرگ فست کانفورمر ترکیبی نمو دقیق‌ترین مدل این مجموعه و مدل ویو۲وک ۲ سریع‌ترین مدل بود. واسک با وجود تأخیر بیشتر، بدون حافظه پردازنده گرافیکی اجرا شد و از نظر استقرار هم‌زمان با مدل زبانی مزیت داشت.

۳-۴-۲ مجموعه بخش فارسی فلورز

برای سنجش وابستگی نتیجه به دامنه، پنج پیکربندی روی تمام ۸۷۱ ضبط بخش آزمون رسمی بخش فارسی مجموعه فلورز با مجموع ۱۳,۳۲۱.۸۶ ثانیه ارزیابی شدند. خروجی مدل بزرگ فست کانفورمر ترکیبی نمو در دو روش رمزگشایی طبقه‌بندی زمانی پیوندگرا و ترنس‌دیوسر شبکه عصبی بازگشتی جداگانه اندازه‌گیری شد. اندازه حافظه

پردازنده گرافیکی در خروجی منجمد این آزمایش ذخیره نشده و بنابراین گزارش نمی‌شود. نتایج پنج پیکربندی در جدول ۴-۲ ارائه شده‌اند.

جدول ۴-۲ نتایج تشخیص گفتار روی بخش فارسی مجموعه فلورز

مدل	نرخ خطای واژه (درصد)	نرخ خطای نویسه (درصد)	ضریب زمان واقعی	تأخیر (ثانیه)	زمان کل (ثانیه)
Vosk fa-0.42	16.75%	6.28%	0.2820	4.3131	3756.71
Wav2Vec2 XLSR Persian v3	29.56%	9.04%	0.0165	0.2523	219.77
NeMo STT Fa FastConformer Hybrid Transducer-CTC Large (CTC)	29.72%	10.58%	0.0076	0.1163	101.29
Whisper large-v3	31.30%	9.13%	0.2545	3.8923	3390.19
NeMo STT Fa FastConformer Hybrid Transducer-CTC Large (Transducer)	43.32%	27.77%	0.0102	0.1555	135.48

در این مجموعه، واسک برخلاف کامن‌ویس کمترین نرخ خطای واژه و نرخ خطای نویسه را داشت. سر طبقه‌بندی زمانی پیوندگرا مدل بزرگ فست کانفورمر ترکیبی نمو سریع‌ترین اجرا بود، اما نرخ خطای واژه آن به ۲۹.۷۲٪ رسید. جابه‌جایی رتبه‌ها نشان می‌دهد که دامنه داده و روش رمزگشایی بخش تعیین‌کننده انتخاب مدل هستند.

۴-۴- ارزیابی مستقل مدل‌های زبانی

پنج مدل قابل اجرای محلی روی دو وظیفه کنترل‌شده فارسی ارزیابی شدند. همه پیکربندی‌ها از نسخه‌های چهاربیتی استفاده کردند، اما ارقام سرعت و حافظه فقط در دامنه و تنظیم همان خروجی منجمد قابل مقایسه‌اند.

۴-۴-۱ پرسش‌های چندگزینه‌ای پارسی‌ان‌ال‌یو

مجموعه شامل ۱۰۵۰ پرسش، یعنی ۳۵۰ نمونه در هر یک از سه دسته دانش عمومی، ادبیات و ریاضی و منطق بود. دقت هر مدل در جدول ۴-۳ گزارش شده است.

جدول ۴-۳ دقت مدل‌های زبانی در وظیفه چندگزینه‌ای پارسی‌ان‌ال‌یو

مدل	دانش عمومی	ادبیات	ریاضی و منطق	کل
گما ۲ با ۹ میلیارد پارامتر	56.57%	47.71%	36.29%	46.86%
کوئن ۵.۲ با ۷ میلیارد پارامتر	45.14%	33.43%	42.57%	40.38%
درنا ۲ با ۸ میلیارد پارامتر	40.86%	37.43%	32.57%	36.95%
کوئن ۵.۲ با ۳ میلیارد پارامتر	33.71%	26.86%	28.00%	29.52%
گما ۲ با ۲ میلیارد پارامتر	34.29%	25.43%	17.43%	25.71%

گما ۲ با ۹ میلیارد پارامتر با ۴۶.۸۶٪ بهترین دقت کل را به دست آورد و در دو دسته نخست نیز برتر بود. کوئن

۵.۲ با ۷ میلیارد پارامتر در ریاضی و منطق به ۴۲.۵۷٪ رسید و نشان داد بهترین مدل به نوع وظیفه وابسته است.

۲-۴-۴- درک مطلب فارسی

هر مدل روی ۶۰۰ پرسش درک مطلب ارزیابی و تطابق دقیق، امتیاز افیک توکنی و شباهت معنایی اندازه‌گیری شد. نتایج این ارزیابی در جدول ۴-۴ آمده است.

جدول ۴-۴ نتایج درک مطلب فارسی

مدل	تطابق دقیق	میانگین امتیاز افیک	شباهت معنایی
گما ۲ با ۹ میلیارد پارامتر	25.17%	0.5811	0.7839
گما ۲ با ۲ میلیارد پارامتر	15.17%	0.4805	0.7123
کوئن ۵.۲ با ۷ میلیارد پارامتر	13.50%	0.4409	0.7160
درنا ۲ با ۸ میلیارد پارامتر	9.67%	0.3928	0.6636
کوئن ۵.۲ با ۳ میلیارد پارامتر	6.33%	0.3650	0.6647


گما ۲ با ۹ میلیارد پارامتر در هر سه معیار رتبه نخست را کسب کرد. نتیجه دو وظیفه کنترل‌شده، انتخاب آن را برای خط لوله نهایی توجیه می‌کند.

۵-۴- ارزیابی مستقل تبدیل متن به گفتار

برای ساخت مجموعه آزمون، ۱۰ درصد از بخش فارسی کامن‌ویس نسخه ۲۵ به صورت تصادفی انتخاب شد؛ حاصل این نمونه‌گیری ۱۰۵۲ متن مرجع بود [۲۳]. متن مرجع هر نمونه، نه صوت اصلی آن، به هر یک از سه مدل تبدیل متن به گفتار داده شد تا برای همه مدل‌ها گفتار متناظر با ورودی یکسان تولید شود. سپس صوت‌های تولیدشده با مدل فارسی `nvidia/stt_fa_fastconformer_hybrid_large` بازشناسی شدند [۱۰]. این مدل در آزمایش کامن‌ویس نسخه ۲۵ همین پروژه کمترین نرخ خطای واژه و نرخ خطای نویسه را داشت؛ بنابراین به عنوان ارزیاب ثابت بازشناسی مجدد انتخاب شد. در پایان، متن پیش‌بینی‌شده با همان متن مرجعی مقایسه شد که ورودی تولید گفتار بود.

مراحل نمونه‌گیری، تولید صوت و سه شاخه ارزیابی در شکل ۴-۱ خلاصه شده‌اند. اتصال خط‌چین متن مرجع به محاسبه خطا تأکید می‌کند که نرخ خطای واژه و نرخ خطای نویسه از مقایسه متن بازشناسی‌شده با ورودی اصلی تبدیل متن به گفتار به دست آمده‌اند، نه از مقایسه دو فایل صوتی.

این قرارداد دو جنبه متفاوت را می‌سنجد: ارزیاب بدون مرجع، کیفیت ادراکی پیش‌بینی‌شده را بدون سیگنال مرجع برآورد می‌کند [۲۱]، درحالی‌که نرخ خطای واژه و نرخ خطای نویسه میزان قابل‌بازشناسی بودن محتوای زبانی



شکل ۴-۱ روش ارزیابی کیفیت، بازشناسی پذیری و کارایی مدلهای تبدیل متن به گفتار

گفتار مصنوعی را می‌سازند. همه مدل‌ها روی همان ۱۰۵۲ متن و با یک مدل بازشناسی ارزیابی شدند؛ از این رو این خطاها برای مقایسه نسبی مدلهای تبدیل متن به گفتار معتبرند، اما نباید خطای مطلق شنونده انسانی تفسیر شوند. جدول ۴-۵ کیفیت ادراکی، جدول ۴-۶ دقت بازشناسی مجدد و جدول ۴-۷ کارایی زمانی را نشان می‌دهند.

جدول ۴-۵ نتایج کیفیت ادراکی مدلهای تبدیل متن به گفتار

مدل	تعداد	میانگین امتیاز نظر	انحراف معیار امتیاز نظر	نویز	ناپیوستگی	رنگ‌شدگی	بلندی
Kamtera VITS	۱۰۵۲	3.380	0.611	3.632	4.077	3.814	4.098
MMS VITS	۱۰۵۲	3.913	0.683	4.011	4.048	3.633	3.887
پایپر	۱۰۵۲	4.534	0.362	4.070	4.656	4.168	4.282

در تمام ابعاد جدول ۴-۵ مقدار بزرگ‌تر بهتر است، به جز انحراف معیار میانگین امتیاز نظر که مقدار کمتر آن یکنواختی بیشتر کیفیت میان نمونه‌ها را نشان می‌دهد. پایپر نه تنها بیشترین میانگین امتیاز نظر را دارد، بلکه با انحراف معیار ۰.۳۶۲ پایدارترین کیفیت را نیز نشان می‌دهد. میانگین امتیاز نظر آن نسبت به امام‌اس به اندازه ۰.۶۲۱ امتیاز و نسبت به کامترا به اندازه ۱.۱۵۴ امتیاز بیشتر است. برتری هم‌زمان در نویز، ناپیوستگی، رنگ‌شدگی و بلندی صدا نشان می‌دهد این افزایش تنها حاصل یک بعد کیفیت نیست. با این حال، این اعداد خروجی مدل ارزیابی بدون مرجع کیفیت گفتار هستند و جایگزین آزمون شنیداری انسانی محسوب نمی‌شوند.

جدول ۴-۶ بازشناسی مجدد و زمان نمونه‌ای مدل‌های تبدیل متن به گفتار

مدل	تعداد	نرخ خطای واژه (درصد)	نرخ خطای نویسه (درصد)	ضریب زمان واقعی گزارش شده	میانگین تأخیر (ثانیه)
Kamtera VITS	۱۰۵۲	۱۴.۴٪	۶.۸٪	۰.۰۴۴	۰.۱۷۵
MMS VITS	۱۰۵۲	۲۵.۳٪	۱۱.۴٪	۰.۰۳۲	۰.۰۸۷
پایپر	۱۰۵۲	۱۰.۷٪	۴.۵٪	۰.۱۹۲	۰.۴۳۴

مقادیر نرخ خطای واژه و نرخ خطای نویسه در این گزارش روی مقیاس صفر تا صد درصد نمایش داده می‌شوند؛ برای مثال نرخ خطای واژه برابر ۱۰.۷٪ یعنی تقریباً ۱۰.۷ عملیات خطا به ازای هر صد واژه مرجع. نسبت به کامترا، مدل پایپر خطای واژه را ۳.۷ واحد درصد کاهش می‌دهد که معادل ۲۵.۷٪ کاهش نسبی است. در مقایسه با امام‌اس، کاهش مطلق نرخ خطای واژه برابر ۱۴.۶ واحد درصد و کاهش نسبی آن ۵۷.۷٪ است. برای نرخ خطای نویسه نیز کاهش نسبی پایپر در برابر کامترا و امام‌اس به ترتیب ۳۳.۸٪ و ۶۰.۵٪ است. بنابراین مزیت کیفی پایپر با حفظ بهتر واژه‌ها و نویسه‌های متن ورودی همراه است، نه فقط با صدای مطلوب‌تر از دید ارزیابی بدون مرجع کیفیت گفتار.


جدول ۴-۷ کارایی زمانی تجمیعی مدل‌های تبدیل متن به گفتار

مدل	تعداد	ضریب زمان واقعی تجمیعی	میانگین تأخیر (ثانیه)	ضریب زمان واقعی بازشناسی	سرعت نسبت به زمان واقعی
Kamtera VITS	۱۰۵۲	۰.۰۴۳	۰.۱۷۵	۰.۰۳۴	۲۳.۲۷x
MMS VITS	۱۰۵۲	۰.۰۲۶	۰.۰۸۷	۰.۰۲۶	۳۹.۰۳x
پایپر	۱۰۵۲	۰.۱۹۲	۰.۴۳۴	۰.۰۵۹	۵.۲۰x

برای جلوگیری از مقایسه مستقیم معیارهایی با مقیاس و جهت متفاوت، شکل ۴-۲ آن‌ها را در سه نمودار مستقل نشان می‌دهد. طول میله‌ها فقط درون هر نمودار قابل مقایسه است: برای میانگین امتیاز نظر و ضریب سرعت مقدار بیشتر و برای نرخ خطای واژه و نرخ خطای نویسه مقدار کمتر بهتر است.

خروجی جدول دقت برای امام‌اس مقدار ضریب زمان واقعی برابر ۰.۰۳۲ و خروجی اختصاصی کارایی تجمیعی مقدار ۰.۰۲۶ را گزارش کرده است. اگر مقدار نخست میانگین نسبت‌های سطح نمونه باشد، اختلاف آن با نسبت مجموع زمان تولید به مجموع مدت صوت طبیعی است؛ زیرا تعریف دوم به نمونه‌های بلندتر وزن بیشتری می‌دهد. با این حال، خلاصه کلی اولیه نیز مقدار ۰.۰۳۲ را با برچسب تجمیعی آورده بود و در نتیجه برچسب دو خروجی کاملاً سازگار نیست. هر دو مقدار بدون ادغام حفظ شده‌اند و محاسبه سرعت ۳۹.۰۳ برابر بر پایه خروجی اختصاصی کارایی تجمیعی انجام شده است. ضرایب سرعت از مقادیر گردنشده ضریب زمان واقعی محاسبه شده‌اند؛ از این رو ممکن است معکوس دقیق عدد سه‌رقمی نمایش داده شده نباشند.

امام‌اس از نظر کارایی سریع‌ترین مدل است. تأخیر متوسط پایپر حدود پنج برابر امام‌اس و ضریب زمان واقعی تجمیعی آن حدود ۷.۳۸ برابر بزرگ‌تر است. با وجود این، ضریب زمان واقعی برابر ۰.۱۹۲ همچنان به معنی تولید



شکل ۲-۴ خلاصه مقایسه مدل‌های تبدیل متن به گفتار از نظر کیفیت، بازشناسی مجدد و سرعت

حدود ۵.۲۰ برابر سریع‌تر از زمان واقعی است؛ یعنی تولید یک ثانیه صوت به‌طور متوسط کمتر از یک ثانیه زمان می‌برد. در نسخه اجرایی، این هزینه زمانی به‌عنوان مصالحه‌ای در برابر بهترین کیفیت ادراکی، کمترین نرخ خطای واژه و نرخ خطای نویسه و یکنواختی بیشتر پذیرفته شد. تأخیرهای جدول فقط زمان تولید تبدیل متن به گفتار هستند و نباید با تأخیر کامل مکالمه از میکروفن تا آغاز پخش یکسان فرض شوند.


۴-۶ انتشار خطا از تشخیص گفتار به مدل زبانی

طرح این آزمایش با الهام از چارچوب پرسش و پاسخ و معیار نرخ خطای کاربرد پولیکودان و همکاران برای ارزیابی تشخیص گفتار در کاربردهای مبتنی بر مدل زبانی طراحی شده است [۴]. در مقاله، یک مدل پرسش‌ها را از متن مرجع می‌سازد، مدل هدف آن‌ها را جداگانه با بافت مرجع و بافت تشخیص گفتار پاسخ می‌دهد و مدل سوم معادل بودن معنایی دو پاسخ را داوری می‌کند. در نسخه فارسی حاضر، منطق دو مسیر حفظ شده است، اما برای کاهش وابستگی به داور زبانی، خروجی هر مسیر مستقیماً با پاسخ طلایی بازبینی شده سنجیده می‌شود. از این‌رو معیار اصلی پروژه نرخ خطای کاربرد مقاله نیست؛ تطابق دقیق، امتیاز افیک، حفظ عبارت پاسخ و شکست انتشار گزارش می‌شوند.

در مسیر مرجع، متن صحیح به مدل زبانی گما داده می‌شود و در مسیر خطادار، فقط همان متن با رونویسی تشخیص گفتار جایگزین می‌شود. پرسش، الگوی دستور، نسخه مدل و تنظیمات تولید در دو مسیر ثابت‌اند. شکست انتشار نیز فقط در نمونه‌هایی تعریف می‌شود که پاسخ مسیر مرجع تطابق دقیق دارد؛ هرگاه همان نمونه پس از

جایگزینی با رونویسی تشخیص گفتار دیگر تطابق دقیق نداشته باشد، یک شکست پایین‌دستی ثبت می‌شود. این شرط، خطای ناشی از بازشناسی گفتار را از ناتوانی پایه مدل زبانی در پاسخ به پرسش جدا می‌کند. آزمایش انتشار خطا بر مجموعه فلورز و یک مجموعه پرسش و پاسخ منجمد انجام شد. از ۸۷۱ ضبط، ۷۶۹ ضبط متعلق به ۲۸۶ شناسه معنایی با پرسش‌ها تطبیق داشتند. برای تعریف گروه اصلی، تنها مواردی نگه داشته شدند که گما ۲ با ۹ میلیارد پارامتر با متن مرجع پاسخ دقیق داده بود؛ این گروه ۴۷۰ ضبط از ۱۷۴ شناسه معنایی داشت.

ساختار کامل این ارزیابی در شکل ۳-۴ نشان داده شده است. دو شرط شامل خروجی منجمد نمو و خروجی واسک بودند. منظور از نمو در این بخش مدل مدل بزرگ فست کانفورمر ترکیبی نمو است که خروجی شاخه ترنسدیوسر آن در آزمایش فلورز استفاده شد. در هر دو شرط، صوت، نگاشت پرسش و پاسخ، دستور مدل زبانی و تنظیمات گما ۲ با ۹ میلیارد پارامتر ثابت نگه داشته شدند؛ بنابراین متغیر اصلی فقط متن تولیدشده توسط تشخیص گفتار بود. معیارهای تشخیص روی همه ۸۷۱ ضبط، معیارهای پاسخ روی ۷۶۹ ضبط تطبیق‌یافته و نرخ شکست انتشار روی گروه اصلی ۴۷۰ ضبط محاسبه شدند.



Only the ASR transcript changes between paired conditions; all downstream settings remain frozen.

شکل ۳-۴ ساختار ارزیابی انتشار خطا از تشخیص گفتار به پاسخ مدل زبانی

جدول ۸-۴ نتیجه دو شرط را نشان می‌دهد.

جدول ۴-۸ اثر کیفیت تشخیص گفتار بر پاسخ گما ۲ با ۹ میلیارد پارامتر

واسک	NeMo STT Fa FastConformer Hybrid Transducer-CTC Large	معیار
16.75%	43.32%	نرخ خطای واژه کل ۸۷۱ ضبط
6.28%	27.77%	نرخ خطای نویسه کل ۸۷۱ ضبط
65.93%	15.34%	حفظ دقیق عبارت پاسخ در ۷۶۹ ضبط
39.53%	9.62%	تطابق دقیق پاسخ در کل ۷۶۹ ضبط
0.6952	0.3402	میانگین امتیاز افیک پاسخ در کل ۷۶۹ ضبط
62.98%	14.68%	حفظ پاسخ صحیح در گروه اصلی
37.02%	85.32%	شکست انتشار در گروه اصلی

فاصله اطمینان ۹۵٪ خوشه‌بندی شده بر اساس شناسه معنایی برای حفظ پاسخ صحیح، در شرط نمو برابر ۱۰.۱۹ تا ۱۹.۴۸٪ و در شرط واسک برابر ۵۶.۷۳ تا ۶۹.۱۸٪ بود. این آزمایش نشان می‌دهد کاهش خطای تشخیص گفتار به بهبود بزرگ در پاسخ پایین‌دستی منجر می‌شود، اما حتی در واسک بیش از یک‌سوم پاسخ‌های صحیح مرجع در اثر متن گفتاری از دست می‌روند.

۴-۶-۱- نرخ خطای واژه در برابر حفظ عبارت پاسخ

برای پیش‌بینی شکست پایین‌دستی، مساحت زیر منحنی مشخصه عملکرد گیرنده برای نرخ خطای واژه ضبط و برای حذف کامل عبارت پاسخ مقایسه شد. مقادیر دو پیش‌بینی‌کننده در جدول ۴-۹ آمده‌اند.

جدول ۴-۹ مقایسه پیش‌بینی‌کننده‌های شکست پایین‌دستی

شرط	AUC(WER)	AUC(span loss)	تفاضل	فاصله اطمینان 95%
نمو	0.7711	0.8943	0.1233	0.0416-0.2112
واسک	0.7620	0.9422	0.1802	0.1219-0.2411

هر دو فاصله اطمینان صفر را کنار می‌گذارند. بنابراین حذف اطلاعات مرتبط با وظیفه، نسبت به نرخ خطای کلی واژه شاخص بهتری برای خطر پاسخ نادرست است. همین نتیجه مبنای طراحی رفع ابهام بر نام، عدد، نفی و اختلاف معنادار شد.

۷-۴- آزمایش تقویت صوت‌های کم‌دامنه

در خط پایه واسک، ۲۰۶ ضبط از ۷۶۹ نمونه دارای سطح غیرعادی پایین بودند. پروفایل محدود با آستانه منفی dBFS ۴۵، هدف منفی dBFS ۲۴، سقف dB ۴۰ و فضای خالی dB ۱ فقط روی این موارد اعمال شد. متن سایر ضبط‌ها بدون رمزگشایی دوباره از خط پایه منجمد استفاده کرد. نتیجه آزمایش زوجی در جدول ۴-۱۰ گزارش شده است.

جدول ۴-۱۰ آزمایش زوجی تقویت صوت کم‌دامنه

معیار	پایه	تقویت‌شده	تغییر
نرخ خطای واژه پیکره	12.740%	12.472%	-0.268 واحد درصد
میانگین نرخ خطای واژه ضبط	12.880%	12.614%	-0.266 واحد درصد
حفظ عبارت پاسخ	65.930%	66.320%	+0.390 واحد درصد
تطابق دقیق گما	39.532%	39.922%	+0.390 واحد درصد
میانگین امتیاز افیک گما	0.6952	0.7040	+0.0088

در سطح ضبط، ۶۳ مورد بهتر، ۳۱ مورد بدتر و ۶۷۵ مورد بدون تغییر بودند. فاصله اطمینان خوشه‌ای تغییر نرخ خطای واژه برابر منفی ۰.۴۴۵ تا منفی ۰.۱۰۰ واحد درصد و احتمال بوت‌استرپ بهبود ۹۹.۹٪ بود. تغییر حفظ عبارت پاسخ فاصله‌ای شامل صفر داشت.

بازاجرای کامل گما روی هر ۷۶۹ متن نیز بدون شکست انجام شد. تنها ۱۱۷ زمینه تشخیص گفتار و ۳۳ پاسخ مدل زبانی تغییر کردند. فاصله اطمینان تغییر تطابق دقیق صفر را قطع می‌کرد، اما برای افزایش میانگین امتیاز افیک برابر مثبت ۰.۰۰۲۶ تا مثبت ۰.۰۱۶۲ و احتمال بهبود ۹۹.۷۲٪ بود. بنابراین بهبود امتیاز افیک و نرخ خطای واژه قابل انکاتر از افزایش کوچک تطابق دقیق است.

۸-۴- شواهد فرضیه‌های چندگانه و بازیابی زمینه‌ای

سه فرضیه واسک برای تمام ۷۶۹ ضبط تقویت‌شده منجمد شد. تقسیم داده با شناسه معنایی و پیش از ارزیابی سیاست انجام گرفت: ۱۹۲ شناسه و ۵۱۷ ضبط برای توسعه، و ۹۴ شناسه و ۲۵۲ ضبط برای بخش نگه‌داشته‌شده. ظرفیت اوراکل و خطر انتخاب خام فرضیه‌ها در جدول ۴-۱۱ مقایسه شده‌اند.

جدول ۴-۱۱ ظرفیت و خطر انتخاب فرضیه‌های چندگانه

معیار	توسعه	نگه‌داشته‌شده	کل
میانگین نرخ خطای واژه متن اصلی	12.77%	12.29%	12.61%
میانگین نرخ خطای واژه اوراکل فرضیه‌های چندگانه	11.24%	11.00%	11.16%
میانگین نرخ خطای واژه بیشترین امتیاز رمزگشا	14.98%	14.04%	14.67%
حفظ عبارت پاسخ در متن اصلی	67.70%	63.49%	66.32%
حفظ عبارت پاسخ اوراکل	74.08%	69.84%	72.69%
عبارت‌های قابل بازیابی	33	16	49

اوراکل در ۲۰۷ ضبط فرضیه‌ای بهتر از متن اصلی پیدا کرد، اما انتخاب صرفاً بر پایه امتیاز رمزگشا فقط در ۵ مورد بهتر و در ۳۴۲ مورد بدتر بود. بنابراین ظرفیت فرضیه‌های چندگانه واقعی است، ولی استفاده ایمن از آن به شواهد خارجی مانند اصلاح صریح کاربر نیاز دارد.

۴-۸-۱- بازیابی با اصلاح صریح

برای ارزیابی منطق پیاده‌سازی شده، از صوت و فرضیه واقعی همراه با یک اصلاح زمینه‌ای نیمه‌مصنوعی استفاده شد. برچسب مرجع فقط در مرحله آفلاین برای ساخت موارد مثبت به کار رفت. زمان اجرا فقط فرضیه‌ها و اصلاح قبلی را دریافت کرد. برای هر مورد، کنترل بدون حافظه و حافظه نامرتب نیز اجرا شد. نتایج بازیابی و کنترل‌ها در جدول ۴-۱۲ ارائه شده‌اند.

جدول ۴-۱۲ نتایج بازیابی زمینه‌ای فرضیه‌های چندگانه

معیار	توسعه	نگه‌داشته‌شده	کل
تعداد موارد مثبت	51	27	78
نرخ بازیابی هدف	72.55%	81.48%	75.64%
نرخ خطای واژه شرطی پیش از بازیابی	15.92%	13.01%	14.91%
نرخ خطای واژه شرطی پس از بازیابی	11.88%	8.39%	10.67%
حفظ عبارت پیش از بازیابی	54.90%	62.96%	57.69%
حفظ عبارت پس از بازیابی	68.63%	77.78%	71.79%
انتخاب فرضیه نادرست	0	0	0
تغییر در کنترل بدون/با حافظه نامرتب	0	0	0

فقط ۵۹ متن بازیابی شده تغییر داده شد و ۷۱۰ پیش‌بینی گما از آزمایش تقویت صوت عیناً بازاستفاده شد. اثر این تغییرها بر پاسخ مدل زبانی در جدول ۴-۱۳ آمده است.

جدول ۱۳-۴ اثر پایین دستی بازیابی زمینه‌ای

دامنه و معیار	پایه صوتی	بازیابی	تغییر
تطابق دقیق، کل ۷۶۹	39.92%	41.09%	+1.17 واحد درصد
میانگین امتیاز افیک، کل ۷۶۹	0.7040	0.7075	+0.0035
تطابق دقیق، ۲۵۲ نگه‌داشته‌شده	36.90%	38.49%	+1.59 واحد درصد
میانگین امتیاز افیک، ۲۵۲ نگه‌داشته‌شده	0.6860	0.6922	+0.0062
تطابق دقیق، ۵۹ متن تغییر کرده	38.98%	54.24%	+15.25 واحد درصد
میانگین امتیاز افیک، ۵۹ متن تغییر کرده	0.7607	0.8058	+0.0451

در کل مجموعه، نه پاسخ دقیق به دست آمد و هیچ پاسخ دقیقی از دست نرفت. فاصله اطمینان خوشه‌ای برای تغییر تطابق دقیق مثبت ۰.۴۰ تا مثبت ۲.۰۸ واحد درصد و برای امتیاز افیک برابر مثبت ۰.۰۰۰۶ تا مثبت ۰.۰۰۷۱ بود. نتیجه بخش نگه‌داشته‌شده به دلیل فقط ۲۲ زمینه تغییر کرده عدم قطعیت بیشتری دارد. این آزمایش کارایی منطق اصلاح صریح را نشان می‌دهد، اما جایگزین مکالمات صوتی طبیعی چندنوبتی نیست.

۹-۴ انتخاب پارامتر بدون نشت داده

شبکه پارامتر صوت شامل پنج آستانه سطح پایین از منفی ۵۵ تا منفی ۳۵ dBFS و پنج هدف ریشه میانگین مربعات از منفی ۳۰ dBFS تا منفی ۱۸ dBFS بود. انتخاب فقط روی بخش توسعه انجام و سپس یک بار روی بخش نگه‌داشته‌شده اجرا شد. ترکیب انتخاب‌شده شامل آستانه منفی ۴۰ dBFS و هدف منفی ۱۸ dBFS بود. نتیجه توسعه و ارزیابی نگه‌داشته‌شده در جدول ۱۴-۴ گزارش شده است.

جدول ۱۴-۴ نتیجه انتخاب پارامتر تقویت صوت

بخش	نرخ خطای واژه پایه	نرخ خطای واژه منتخب	حفظ عبارت پایه	حفظ عبارت منتخب
توسعه	12.868%	12.585%	67.70%	68.28%
نگه‌داشته‌شده	12.482%	11.992%	62.30%	63.49%

کاهش نرخ خطای واژه نگه‌داشته‌شده ۰.۴۹۰ و افزایش حفظ عبارت ۱.۱۹ واحد درصد بود. این پروفایل منتخب جدید هنوز جایگزین پروفایل محافظه‌کارانه منفی ۴۵/منفی ۲۴ در نسخه عملیاتی نشده و باید با هزینه تأخیر و داده صوتی طبیعی نیز بررسی شود.

شبکه عدم قطعیت شامل آستانه‌های اطمینان ۰.۴۵ تا ۰.۸۵ و شکاف‌های امتیاز ۰.۲۵ تا ۳.۰ بود. قید توسعه، نرخ رفع ابهام حداکثر ۱۰٪ و رفع ابهام غیرضروری حداکثر ۵٪ بود. از ۷۶۹ ضبط، ۷۵۳ مورد با گذر تازه دقیقاً

با متن منجمد هم‌راستا بودند و ۱۶ مورد برای جلوگیری از خطای هم‌ترازی کنار گذاشته شدند. خلاصه انتخاب آستانه‌ها در جدول ۴-۱۵ ارائه شده است.

جدول ۴-۱۵ انتخاب آستانه اطمینان و شکاف فرضیه

تنظیم/بخش	نرخ خطای واژه اولیه	نرخ خطای واژه با کمک اوراکل	حفظ عبارت پس از پرسش	رفع ابهام	رفع ابهام غیرضروری
توسعه 0.65/1.0	12.511%	12.092%	70.69%	29.31%	18.61%
توسعه 0.45/0.5	12.511%	12.414%	68.51%	7.13%	4.75%
نگه‌داشته‌شده 0.45/0.5	12.003%	11.858%	64.52%	11.69%	8.47%

تنظیم ۰.۴۵/۰.۵ قانون انتخاب روی توسعه را برآورده کرد، اما روی بخش نگه‌داشته‌شده هر دو نرخ رفع ابهام از قید عبور کردند. افزون بر این، ستون‌های بهبود با فرض انتخاب صحیح کاربر محاسبه شده‌اند و کران بالای سیاست تعاملی هستند، نه تصحیح خودکار. بنابراین این تنظیم نباید به‌عنوان نقطه عملیاتی قطعی معرفی شود.

۴-۱۰- ارزیابی چندنوبتی کنترل مکالمه

مجموعه رگرسیون کوچک شامل خطای نام، عدد، نفی، پاسخ مستقیم و ترتیبی به رفع ابهام، حفظ اصلاح پس از خروج از تاریخچه، ارجاع ضمیری، تغییر موضوع، تفاوت املایی بی‌ضرر و خطای پراطمینان بود. این مجموعه از همان ماشین حالت متنی خط لوله اجرا استفاده کرد.

نسخه نخست هر ۱۲ نوبت اصلی را در دقت تصمیم، دقت و یادآوری رفع ابهام، صحت بازسازی پرسش و صحت حافظه با ۱۰۰٪ گذراند. اجرای گما ۲ با ۹ میلیارد پارامتر نیز هر هفت بررسی مفهوم پاسخ را گذراند. دو نمونه چالشی آشکار کردند که اختلاف «لطفاً/خواهشاً» رفع ابهام غیرضروری ایجاد می‌کند و اختلاف نام «شریعت/شریف» پس از «دانشگاه» در اطمینان بالا نادیده گرفته می‌شود.

پس از افزودن تشخیص اهمیت معنایی و اختلاف جایگاه بحرانی، دقت تصمیم چالشی از ۰٪ به ۱۰۰٪ رسید و هیچ مورد اصلی پسرفت نکرد. اجرای محلی مدل زبانی نیز هفت بررسی اصلی و پاسخ چالش مسیره‌دهی شده را با ۱۰۰٪ پوشش واژه‌های کلیدی گذراند. این مجموعه تشخیصی و دست‌نویس است و برآورد جمعیتی کیفیت مکالمه واقعی محسوب نمی‌شود.

۴-۱۱- بحث و تحلیل نتایج

۴-۱۱-۱- مقدمه تحلیل

نتایج این پروژه نشان می‌دهند که انتخاب اجزای یک دستیار صوتی را نمی‌توان با یک جدول رتبه‌بندی مستقل انجام داد. عملکرد مدل با دامنه داده، روش رمزگشایی، منابع هم‌زمان، اطلاعات مورد نیاز کنترل مکالمه و اثر خطا

بر وظیفه پایین‌دستی تغییر می‌کند. در این فصل پیامدهای این نتایج برای طراحی نسخه نهایی تحلیل می‌شوند.

۴-۱۲- وابستگی انتخاب تشخیص گفتار به دامنه

روی کامن‌ویس نسخه ۲۵، مدل مدل بزرگ فست کانفورمر ترکیبی نمو با نرخ خطای واژه برابر ۱۲.۳۳٪ دقیق‌ترین مدل بود؛ اما روی بخش فارسی مجموعه فلورز، واسک با نرخ خطای واژه برابر ۱۶.۷۵٪ رتبه نخست را کسب کرد و سر طبقه‌بندی زمانی پیوندگرا همان مدل به ۲۹.۷۲٪ رسید. بنابراین ادعای «بهترین مدل تشخیص گفتار فارسی» بدون نام مجموعه و قرارداد نرمال‌سازی معتبر نیست.

این جابه‌جایی ممکن است از تفاوت گویندگان، شیوه ضبط، دامنه متنی، طول جمله و سازگاری داده آموزشی مدل با آزمون ناشی شود. همچنین تفاوت زیاد طبقه‌بندی زمانی پیوندگرا و ترنس‌دیوسر شبکه عصبی بازگشتی یک مدل واحد روی فلورز نشان می‌دهد که انتخاب رمزگشا به اندازه انتخاب رمزگذار اهمیت دارد.

سر طبقه‌بندی زمانی پیوندگرا مدل نمو از نظر سرعت با ضریب زمان واقعی برابر ۰.۰۰۷۶ برتری زیادی داشت؛ اما نسخه نهایی برای سرعت مستقل تشخیص گفتار بهینه نشده است. واسک روی پردازنده مرکزی اجرا می‌شود، حافظه پردازنده گرافیکی را برای گما ۲ با ۹ میلیارد پارامتر آزاد می‌گذارد و اطمینان واژه و فرضیه‌های جایگزین را در اختیار کنترل مکالمه قرار می‌دهد. این ویژگی‌ها همراه با دقت بهتر روی داده آزمایش انتها‌به‌انتها، انتخاب آن را برای استقرار توجیه می‌کنند.

۴-۱۳- کیفیت مدل زبانی و هزینه استقرار

گما ۲ با ۹ میلیارد پارامتر در پرسش چندگزینه‌ای با ۴۶.۸۶٪ و در درک مطلب با تطابق دقیق ۲۵.۱۷٪ امتیاز افیک برابر ۰.۵۸۱۱ و شباهت معنایی ۰.۷۸۳۹ رتبه نخست را گرفت. برتری هم‌زمان در دو وظیفه کنترل‌شده قوی‌تر از نتیجه یک نمونه تصادفی ناهمگن است و دلیل جایگزینی گما ۲ با ۲ میلیارد پارامتر در نسخه اجرایی محسوب می‌شود.

با این حال، کوئن ۵.۲ با ۷ میلیارد پارامتر در ریاضی و منطق بهتر بود. اگر دامنه کاربرد دستیار به حل مسئله منطقی محدود شود، ارزیابی تخصصی می‌تواند انتخاب دیگری ایجاد کند. در کاربرد عمومی فعلی، عملکرد کلی و درک مطلب اولویت دارد.

وزن چهاربیتی امکان بارگذاری گما ۲ با ۹ میلیارد پارامتر روی پردازنده گرافیکی لپ‌تاپ را فراهم کرد، اما مصرف حافظه فقط وزن مدل نیست و به فعال‌سازی، حافظه نهان کلید و مقدار، طول ورودی و پیاده‌سازی کتابخانه نیز وابسته است. انتقال تشخیص گفتار و تشخیص فعالیت صوتی به پردازنده مرکزی رقابت حافظه را کاهش می‌دهد. بنابراین انتخاب مدل‌های خط لوله یک مسئله تخصیص منابع میان اجزا است، نه سه تصمیم مستقل.

۱۴-۴ - معنای نتایج انتشار خطا

جایگزینی مسیر نمو با واسک، حفظ پاسخ صحیح گروه اصلی را از ۱۴.۶۸٪ به ۶۲.۹۸٪ رساند. این افزایش نشان می‌دهد که بهبود مدل زبانی بدون تثبیت ورودی گفتاری نمی‌تواند کیفیت کل سامانه را تضمین کند. در عین حال، شکست ۳۷.۰۲٪ در شرط بهتر نیز نشان می‌دهد نرخ خطای واژه پایین به معنی حفظ قطعی اطلاعات لازم برای پاسخ نیست.

نتیجه مساحت زیر منحنی این موضوع را دقیق‌تر بیان می‌کند. حذف کامل عبارت پاسخ، شکست پایین‌دستی را بهتر از نرخ خطای واژه کلی جدا کرد و فاصله اطمینان تفاضل در هر دو شرط صفر را کنار گذاشت. یک جمله می‌تواند چند خطای کم‌اهمیت داشته باشد و هنوز پاسخ‌پذیر بماند؛ برعکس، تغییر تنها یک نام، عدد یا نفی می‌تواند با نرخ خطای واژه کم معنای پرسش را عوض کند.

از این رو سیاست رفع ابهام نسخه نهایی به اهمیت اختلاف حساس است. این سیاست برای اختلاف سبکی پرسش نمی‌سازد، ولی اختلاف نام، عدد و نفی را حتی در اطمینان بالا جدی می‌گیرد. بهبود دو مورد چالشی بدون پسرقت در موارد اصلی، شواهد رگرسیونی اولیه‌ای برای این تصمیم فراهم می‌کند.

۱۵-۴ - تفسیر پیش‌پردازش صوت

تقویت فقط ۲۰۶ صوت کم‌دامنه، نرخ خطای واژه پیکره را ۰.۲۶۸ واحد درصد کاهش داد. اندازه اثر کوچک است، اما فاصله اطمینان خوشه‌ای کاملاً منفی و احتمال بوت‌استرپ بهبود ۹۹.۹٪ بود. بازاجرای مدل زبانی نیز افزایش ۰.۰۰۸۸ در میانگین امتیاز افیک با فاصله اطمینان مثبت نشان داد.

در مقابل، تغییر تطابق دقیق و حفظ عبارت پاسخ از نظر آماری قطعی نبود. این تفاوت یادآور می‌شود که یک پیش‌پردازش نباید فقط با چند نمونه شنیداری یا یک معیار پذیرفته شود. پذیرش پروفایل محافظه‌کارانه بر ترکیب شواهد نرخ خطای واژه و امتیاز افیک استوار است و ادعای بهبود تمام معیارها نمی‌شود.

شبکه توسعه آستانه منفی ۴۰ dBFS و هدف منفی ۱۸ dBFS را انتخاب و روی داده نگه‌داشته‌شده کاهش ۰.۴۹۰ واحد درصد نرخ خطای واژه نشان داد. با این حال، این نتیجه جدید هنوز به معنی جایگزینی خودکار تنظیم عملیاتی نیست؛ هزینه آن روی صوت زنده، پایداری در نویز و اثر پایین‌دستی کامل باید بررسی شود. جداسازی انتخاب و ارزیابی نهایی از خوش‌بینی ناشی از تنظیم روی کل داده جلوگیری می‌کند.

۱۶-۴ - چرا فرضیه‌های چندگانه نباید کورکورانه انتخاب شوند

اوراکل فرضیه‌های چندگانه روی بخش نگه‌داشته‌شده نرخ خطای واژه میانگین را از ۱۲.۲۹٪ به ۱۱.۰۰٪ کاهش داد و ۱۶ عبارت پاسخ از دست‌رفته را قابل بازیابی کرد. این اعداد نشان می‌دهند پاسخ بهتر اغلب در میان سه فرضیه وجود دارد. با این حال انتخاب بیشترین امتیاز رمزگشا نرخ خطای واژه را به ۱۴.۰۴٪ بدتر کرد. امتیاز آکوستیکی لزوماً با درستی واژه‌های مرتبط با وظیفه هم‌راستا نیست.

سیاست اجرا فقط با اصلاح صریح و هم‌زمینه کاربر فرضیه را عوض می‌کند. در آزمایش نیمه‌مصنوعی، نرخ بازیابی بخش نگه‌داشته‌شده ۸۱.۴۸٪ بود و هیچ تغییر در کنترل بدون حافظه یا حافظه نامرتبط رخ نداد. نتیجه پایین‌دستی نیز نه تطابق دقیق به دست آورد و موردی از دست نداد.

این نتیجه اثبات نمی‌کند که همان نرخ در مکالمه طبیعی تکرار خواهد شد؛ زیرا اصلاح پیشین به‌صورت آفلاین ساخته شده بود. ارزش اصلی آزمایش در اعتبارسنجی سازوکار است: یک اصلاح محدود به زمینه می‌تواند ظرفیت فرضیه‌های چندگانه را بدون تبدیل سامانه به تصحیح‌کننده حدسی به کار گیرد.

۱۷-۴ - توازن رفع ابهام و تجربه کاربر

رفع ابهام می‌تواند پاسخ نادرست را متوقف کند، اما پرسش زیاد مکالمه را کند و آزاردهنده می‌کند. تنظیم پیشین ۰.۶۵/۱.۰ در تحلیل توسعه با کمک اوراکل ظرفیت بهبود بیشتری داشت، ولی ۲۹.۳۱٪ نوبت‌ها را به رفع ابهام می‌فرستاد و ۱۸.۶۱٪ پرسش‌ها غیرضروری بودند. نقطه ۰.۴۵/۰.۵ روی توسعه این نرخ‌ها را به ۷.۱۳٪ و ۴.۷۵٪ کاهش داد.

با وجود این، نرخ‌های نگه‌داشته‌شده ۱۱.۶۹٪ و ۸.۴۷٪ از قید عبور کردند. این شکست تعمیم نشان می‌دهد آستانه ثابت به تنهایی برای همه گویندگان و شرایط کافی نیست. قواعد اهمیت معنایی، کالبراسیون اطمینان و داده واقعی بیشتری لازم است. همچنین اعداد کمک اوراکل فرض می‌کنند کاربر همیشه گزینه درست را انتخاب می‌کند و باید کران بالای تعامل تفسیر شوند.

۱۸-۴ - کاهش تأخیر ادراکی با جریان‌سازی

در پیاده‌سازی قبلی، مدل زبانی باید پاسخ را کامل می‌کرد و سپس کل متن به تبدیل متن به گفتار داده می‌شد. نسخه نهایی سه مرحله تولید توکن، تولید عبارت صوتی و پخش را هم‌پوشان می‌کند. از این‌رو معیار مهم تجربه کاربر فقط زمان کل نیست، بلکه زمان نخستین توکن، نخستین عبارت و نخستین صوت است.

این معماری حتی بدون تغییر سرعت خام مدل‌ها می‌تواند شروع پاسخ را جلو بیندازد. تقسیم بسیار کوتاه

عبارت‌ها سربار فراخوانی تبدیل متن به گفتار و گسست آهنگ را افزایش می‌دهد و عبارت‌های بسیار بلند زمان انتظار را بیشتر می‌کنند. حدود ۳۰/۶۰ نویسه یک انتخاب مهندسی فعلی هستند و هنوز به ارزیابی شنیداری و تأخیر روی مجموعه مکالمه واقعی نیاز دارند.

۱۹-۴ انتخاب ترکیب نهایی

ترکیب عملیاتی پروژه عبارت است از:

Silero VAD → Vosk fa-0.42 → Gemma 2 9B 4-bit → Piper fa_IR-gyro-medium

دلایل این انتخاب عبارت‌اند از:

- واسک بهترین دقت فلورز، اجرای پردازنده مرکزی و شواهد اطمینان و فرضیه‌های چندگانه مورد نیاز کنترل مکالمه را فراهم می‌کند؛
 - گما ۲ با ۹ میلیارد پارامتر در هر دو وظیفه کنترل‌شده مدل زبانی رتبه نخست را دارد و نسخه چهاربیتی آن روی سخت‌افزار پروژه اجرا می‌شود؛
 - پایپر بهترین کیفیت ادراکی و قابل‌فهم‌بودن را دارد؛ نرخ خطای واژه آن نسبت به کامترا و ام‌ام‌اس به ترتیب ۲۵.۷٪ و ۵۷.۷٪ کاهش نسبی دارد و با وجود سرعت کمتر از ام‌ام‌اس، همچنان حدود ۵.۲۰ برابر سریع‌تر از زمان واقعی تولید می‌کند؛
 - و مدل سیلرو برای تشخیص فعالیت صوتی، کنترل ریسک و جریان‌سازی، شکاف میان مدل‌های مستقل و تجربه مکالمه را پوشش می‌دهند.
- این انتخاب ادعا نمی‌کند هر جزء در تمام معیارها بهترین است. فست کانفورمر برای کاربرد کامن‌ویس-مانند یا نیاز به سرعت خام و کوئن ۵.۲ با ۷ میلیارد پارامتر برای وظیفه ریاضی می‌توانند گزینه بهتری باشند. ترکیب نهایی برای محدودیت و شواهد کاربرد حاضر انتخاب شده است.

۲۰-۴ جمع‌بندی

مهم‌ترین نتیجه تحلیلی آن است که خطای مرتبط با وظیفه از خطای کلی واژه مهم‌تر است. بهبود صوت و تشخیص گفتار کیفیت پایین‌دستی را افزایش دادند، ولی بهره‌برداری از فرضیه‌های چندگانه فقط با شواهد زمینه‌ای ایمن بود. کنترل ریسک، حافظه اصلاح و تولید جریانی به همان اندازه انتخاب مدل‌ها در نسخه کاربردی نقش دارند. فصل بعد نتیجه‌گیری نهایی و مسیرهای توسعه مبتنی بر محدودیت‌های باقی‌مانده را ارائه می‌کند.

فصل ۵

نتیجه‌گیری و پیشنهادات

۵-۱- نتیجه‌گیری

هدف پروژه، ساخت یک دستیار صوتی فارسی محلی و بررسی علمی مؤلفه‌های آن بود. این هدف با پیاده‌سازی زنجیره زیر محقق شد:



سامانه نهایی فقط سه مدل را به هم متصل نمی‌کند. تشخیص خودکار شروع و پایان گفتار، تقویت محدود صوت ضعیف، نمایش ساخت‌یافته اطمینان و فرضیه‌ها، رفع ابهام هدفمند، حافظه اصلاح محدود به زمینه، تاریخچه شش‌نوبتی، نرمال‌سازی عدد و تولید و پخش جریانی نیز پیاده‌سازی شده‌اند. زمان‌های نخستین توکن، عبارت و صوت همراه با رخدادهای تصمیم در گزارش چرخشی ذخیره می‌شوند.

مقایسه مستقل تشخیص گفتار نشان داد مدل بزرگ فست کانفورمر ترکیبی نمو روی کامن‌ویس نسخه ۲۵ با نرخ خطای واژه برابر ۱۲.۳۳٪ دقیق‌ترین مدل بود، اما واسک روی بخش فارسی مجموعه فلورز با نرخ خطای واژه برابر ۱۶.۷۵٪ رتبه نخست را گرفت. این تفاوت، وابستگی شدید رتبه‌بندی به دامنه را آشکار کرد. واسک به دلیل نتیجه فلورز، اجرای پردازنده مرکزی و ارائه اطمینان واژه و فرضیه‌های چندگانه در نسخه عملیاتی انتخاب شد.

در مدل زبانی، گما ۲ با ۹ میلیارد پارامتر در پرسش چندگزینه‌ای با دقت ۴۶.۸۶٪ و در درک مطلب با تطابق دقیق ۲۵.۱۷٪، امتیاز افیک برابر ۵۸۱۱.۰ و شباهت معنایی ۷۸۳۹.۰ بهترین نتیجه کلی را داشت. نسخه چهاربیتی آن امکان اجرای محلی را فراهم کرد. در تبدیل متن به گفتار نیز پایپر با میانگین امتیاز نظر پیش‌بینی‌شده برابر ۴.۵۳۴ و کمترین خطای بازشناسی مجدد انتخاب شد.

آزمایش انتشار خطا نتیجه‌ای فراتر از رتبه‌بندی مستقل ارائه کرد. جایگزینی مسیر نمو با واسک، حفظ پاسخ صحیح را از ۱۴.۶۸٪ به ۶۲.۹۸٪ و تطابق دقیق کل را از ۹.۶۲٪ به ۳۹.۵۳٪ رساند. حذف عبارت مرتبط با پاسخ نسبت به نرخ خطای واژه کلی پیش‌بینی‌کننده قوی‌تری برای شکست مدل زبانی بود. این یافته طراحی کنترل ریسک مبتنی بر نام، عدد، نفی و اختلاف معنادار را توجیه کرد.

تقویت محدود صوت کم‌دامنه نرخ خطای واژه را ۰.۲۶۸ واحد درصد کاهش و میانگین امتیاز افیک پایین‌دستی را ۰.۰۰۸۸ افزایش داد؛ هر دو تغییر دارای فاصله اطمینان پشتیبان بودند. فرضیه‌های چندگانه نیز ظرفیت بهبود داشتند، اما انتخاب بیشترین امتیاز رمزگشا خطا را افزایش داد. بازیابی فقط با اصلاح صریح و هم‌زمینه کاربر، تطابق دقیق کل را ۱.۱۷ واحد درصد افزایش داد و نه پاسخ دقیق به دست آورد، بدون آنکه پاسخ دقیقی از دست برود. در نتیجه، پاسخ پرسش اصلی پروژه این است که یک چت‌بات صوتی فارسی محلی قابل پیاده‌سازی است، اما کیفیت آن فقط به بزرگ‌ترین یا دقیق‌ترین مدل مستقل وابسته نیست. انتخاب مدل متناسب با دامنه، تخصیص منابع، کنترل خطای مرتبط با وظیفه، حافظه محدود و کاهش تأخیر ادراکی همگی در عملکرد نهایی نقش دارند.

۵-۲- پیشنهادها برای توسعه آینده

پیشنهادهای زیر می‌توانند ارزیابی خودکار فعلی را با شواهد انسانی تکمیل کنند و سامانه را به شرایط کاربرد واقعی نزدیک‌تر سازند:

۱. ساخت یک مجموعه داده فارسی ویژه تبدیل متن به گفتار با ضبط‌های استودیویی، متن بازبینی‌شده، تنوع گوینده، لهجه و ساختار آوایی و تقسیم مستقل آموزش، توسعه و آزمون. مجوز انتشار، رضایت گویندگان و فراداده کیفیت ضبط نیز باید از آغاز طراحی مجموعه مشخص شوند؛

۲. انجام ارزیابی انسانی کور برای مدل‌های تبدیل متن به گفتار بر پایه طبیعی بودن صوت، فهم‌پذیری، صحت تلفظ، پیوستگی آهنگ و یکنواختی کیفیت. این ارزیابی امکان مقایسه امتیاز انسانی با ارزیابی بدون مرجع کیفیت گفتار و خطای بازشناسی مجدد را فراهم می‌کند و نشان می‌دهد معیارهای خودکار تا چه اندازه با تجربه شنونده هم‌راستا هستند؛

۳. اجرای ارزیابی انسانی گسترده روی کل سامانه با کاربران دارای سن، جنسیت، لهجه و تجربه فنی متفاوت. در این مطالعه، درستی و مرتبط بودن پاسخ، موفقیت وظیفه، طبیعی بودن صدای خروجی، رضایت کلی و مفید بودن یا مزاحمت پرسش رفع ابهام باید جداگانه امتیازدهی شوند؛

۴. اجرای یک پروتکل نهایی روی مجموعه‌ای مهروموم شده از مکالمات صوتی طبیعی چندنوبتی. این پروتکل باید موفقیت وظیفه، پاسخ نادرست، دقت و یادآوری رفع ابهام، قطع زودهنگام یا دیرهنگام تشخیص فعالیت

صوتی، میانه و صدک‌های ۹۰ و ۹۵ زمان پایان گفتار تا نخستین صوت و ارزیابی انسانی را به صورت هم‌زمان گزارش کند؛

۵. افزودن خلاصه‌سازی کنترل‌شده برای مکالمه‌های طولانی‌تر از تاریخچه شش‌نوبتی. خلاصه باید نام‌ها، عددها، نفی‌ها، ترجیح‌های کاربر و اصلاح‌های صریح را بدون افزودن اطلاعات تازه حفظ کند و با آزمون‌های رگرسیون چندنوبتی ارزیابی شود؛

۶. کالیبره کردن سیاست رفع ابهام با بازخورد کاربران واقعی تا میان جلوگیری از پاسخ پرخطر و کاهش پرسش‌های غیرضروری توازن برقرار شود. مقایسه سیاست ثابت با سیاست سازگار شونده می‌تواند اثر این تغییر را بر موفقیت وظیفه و رضایت کاربر مشخص کند.

منابع

- [1] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, “wav2vec 2.0: A framework for self-supervised learning of speech representations,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 12449–12460, 2020.
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [3] J. Kim, J. Kong, and J. Son, “Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech,” in *Proceedings of the 38th International Conference on Machine Learning*, 2021.
- [4] S. Pulikodan, S. K. P. K. Ghosh, V. Sanka, and N. Desai, “An approach to measuring the performance of automatic speech recognition (asr) models in the context of large language model (llm) powered applications,” in *Proceedings of Interspeech 2025*, pp. 5718–5722, 2025.
- [5] A. Conneau, A. Baevski, R. Collobert, A. Mohamed, and M. Auli, “Unsupervised cross-lingual representation learning for speech recognition,” *arXiv preprint arXiv:2006.13979*, 2020.
- [6] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” *arXiv preprint arXiv:2212.04356*, 2022.
- [7] A. Gulati, J. Qin, C.-C. Chiu, *et al.*, “Conformer: Convolution-augmented transformer for speech recognition,” in *Proceedings of Interspeech*, 2020.

-
- [8] D. Rekesh, N. R. Koluguri, S. Krizan, S. Majumdar, V. Noroozi, H. Huang, O. Hrinchuk, K. Puvvada, A. Kumar, J. Balam, and B. Ginsburg, “Fast conformer with linearly scalable attention for efficient speech recognition,” *arXiv preprint arXiv:2305.05084*, 2023.
- [9] D. Povey, A. Ghoshal, G. Boulianne, L. Burget, O. Glembek, N. Goel, M. Hannemann, P. Motlicek, Y. Qian, P. Schwarz, J. Silovsky, G. Stemmer, and K. Vesely, “The kaldi speech recognition toolkit,” in *IEEE 2011 Workshop on Automatic Speech Recognition and Understanding*, 2011.
- [10] NVIDIA, “Stt fa fastconformer hybrid transducer-ctc large.” Hugging Face Model Card. Accessed: 2026-09-05.
- [11] M. Farahani, “Wav2vec2-large-xlsr-53-persian v3 model card.” Hugging Face Model Card. Accessed: 2026-09-05.
- [12] OpenAI, “Whisper model card.” Official model card, 2023. Accessed: 2026-09-05.
- [13] Alpha Cephei, “Vosk models: Persian vosk-model-fa-0.42.” Official Vosk model catalogue. Accessed: 2026-09-05.
- [14] A. Graves, “Sequence transduction with recurrent neural networks,” *arXiv preprint arXiv:1211.3711*, 2012.
- [15] Gemma Team, M. Riviere, S. Pathak, P. G. Sessa, *et al.*, “Gemma 2: Improving open language models at a practical size,” *arXiv preprint arXiv:2408.00118*, 2024.
- [16] A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, *et al.*, “Qwen2.5 technical report,” *arXiv preprint arXiv:2412.15115*, 2024.
- [17] Part AI, “Dorna2-llama3.1-8b-instruct model card.” Hugging Face model documentation, 2025.
- [18] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, “Qlora: Efficient finetuning of quantized llms,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023.

-
- [19] V. Pratap, A. Tjandra, B. Shi, P. Tomasello, A. Babu, S. Kundu, A. Elkahky, Z. Ni, A. Vyas, A. Baevski, *et al.*, “Scaling speech technology to 1,000+ languages,” *arXiv preprint arXiv:2305.13516*, 2023.
- [20] Rhasspy, “Piper: A fast, local neural text to speech system.” Software documentation, 2023.
- [21] G. Mittag, B. Naderi, A. Chehadi, and S. Moller, “Nisqa: A deep cnn-self-attention model for multidimensional speech quality prediction with crowdsourced datasets,” in *Proceedings of Interspeech*, 2021.
- [22] H. Zeinali, L. Burget, and J. Cernocky, “A multi purpose and large scale speech corpus in persian and english for speaker and speech recognition: The deepmine database,” *arXiv preprint arXiv:1912.03627*, 2019.
- [23] R. Ardila, M. Branson, K. Davis, M. Kohler, J. Meyer, M. Henretty, R. Morais, L. Saunders, F. Tyers, and G. Weber, “Common voice: A massively-multilingual speech corpus,” in *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pp. 4218–4222, 2020.
- [24] N. Sedghiye, S. Sadeghi, R. Khodadadi, F. Kashani, O. Aghdaei, S. Rahimi, and M. S. Safari, “Psr: A comprehensive benchmark for evaluating persian asr systems,” *arXiv preprint arXiv:2505.21230*, 2025.
- [25] A. Abaskohi, F. Mortazavi, and H. Moradi, “Automatic speech recognition for speech assessment of persian preschool children,” *arXiv preprint arXiv:2203.12886*, 2022.
- [26] N. San, G. Paraskevopoulos, A. Arora, X. He, P. Kaur, O. Adams, and D. Jurafsky, “Predicting positive transfer for improved low-resource speech recognition using acoustic pseudo-tokens,” in *Proceedings of the Sixth Workshop on Research in Computational Linguistic Typology and Multilingual NLP*, 2024.
- [27] A. Pineiro-Martin, C. Garcia-Mateo, L. Docio-Fernandez, M. d. C. Lopez-Perez, and G. Rehm, “Weighted cross-entropy for low-resource languages in multilingual speech recognition,” *arXiv preprint arXiv:2409.16954*, 2024.

-
- [28] S. Bandrupalli, B. Akkiraju, S. C. Devarakonda, V. R. S. Narasinga, and A. Vuppala, “Efficient asr for low-resource languages: Leveraging cross-lingual unlabeled data,” in *Findings of the Association for Computational Linguistics: IJCNLP-AACL 2025*, pp. 1611–1617, 2025.
- [29] B. Namdarzadeh and N. Ballier, “Fine-tuning whisper with spontaneous persian speech (sps),” in *Proceedings of the SIGUL 2026 Joint Workshop with ELE, EURALI, and DCLRL*, pp. 263–269, 2026.
- [30] R. Iranmanesh, R. Ziaei, and J. Garman, “Segmentation strategy matters: Benchmarking whisper on persian youtube content,” in *Proceedings of the First Workshop on NLP and LLMs for the Iranian Language Family*, 2026.
- [31] A. Abaskohi, S. Baruni, M. Masoudi, N. Abbasi, M. H. Babalou, A. Edalat, S. Kamahi, S. Mahdizadeh Sani, N. Naghavian, D. Namazifard, P. Sadeghi, and Y. Yaghoobzadeh, “Benchmarking large language models for persian: A preliminary study focusing on chatgpt,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*, pp. 2189–2203, 2024.
- [32] S. B. Hosseinbeigi, B. Rohani, M. Masoudi, M. Shamsfard, Z. Saaberi, M. Karimi Manesh, and M. A. Abbasi, “Advancing persian llm evaluation,” in *Findings of the Association for Computational Linguistics: NAACL 2025*, 2025.
- [33] M. Shamsfard, Z. Saaberi, M. Karimi Manesh, S. M. H. Hashemi, *et al.*, “Farseval-pkbets: A new diverse benchmark for evaluating persian large language models,” *arXiv preprint arXiv:2504.14690*, 2025.
- [34] E. Frantar, S. Ashkboos, T. Hoefler, and D. Alistarh, “Gptq: Accurate post-training quantization for generative pre-trained transformers,” *arXiv preprint arXiv:2210.17323*, 2022.
- [35] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan, and S. Han, “Awq: Activation-aware weight quantization for llm compression and acceleration,” *arXiv preprint arXiv:2306.00978*, 2023.

-
- [36] M. H. Shamgholi, V. Saeedi, J. Peymanfard, L. Alhabib, and H. Zeinali, “Armantts single-speaker persian dataset,” *arXiv preprint arXiv:2304.03585*, 2023.
- [37] M. Adibian, H. Zeinali, and S. Barmaki, “Deepmine-multi-tts: A persian speech corpus for multi-speaker text-to-speech,” *SSRN Electronic Journal*, 2023.
- [38] M. F. Qharabagh, Z. Dehghanian, and H. R. Rabiee, “Manatts persian: A recipe for creating tts datasets for lower resource languages,” in *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 9177–9206, 2025.
- [39] D. Zhang, S. Li, X. Zhang, J. Zhan, P. Wang, Y. Zhou, and X. Qiu, “Speechgpt: Empowering large language models with intrinsic cross-modal conversational abilities,” *arXiv preprint arXiv:2305.11000*, 2023.
- [40] P. K. Rubenstein, C. Asawaroengchai, D. D. Nguyen, A. Bapna, *et al.*, “Audiopalm: A large language model that can speak and listen,” *arXiv preprint arXiv:2306.12925*, 2023.
- [41] C. Tang, W. Yu, G. Sun, X. Chen, T. Tan, *et al.*, “Salmonn: Towards generic hearing abilities for large language models,” *arXiv preprint arXiv:2310.13289*, 2023.
- [42] W. Cui, D. Yu, X. Jiao, Z. Meng, G. Zhang, *et al.*, “Recent advances in speech language models: A survey,” *arXiv preprint arXiv:2410.03751*, 2024.
- [43] A. Conneau, M. Ma, S. Khanuja, Y. Zhang, V. Axelrod, S. Dalmia, J. Riesa, C. Rivera, and A. Bapna, “Fleurs: Few-shot learning evaluation of universal representations of speech,” in *Proceedings of the 2022 IEEE Spoken Language Technology Workshop*, 2022.
- [44] Meta AI, “Massively multilingual speech: Persian text-to-speech model card.” Hugging Face model documentation. Accessed: 2026-09-10.
- [45] Kamtera, “Persian tts female vits model card.” Hugging Face model documentation. Accessed: 2026-09-10.

[46] Rhasspy, “Piper fa-ir gyro medium voice model card.” Hugging Face model documentation.

Accessed: 2026-09-10.

پیوست ۱

فهرست برنامه‌ها و جزئیات بازتولید

۱-۱- مشخصات محیط توسعه و اجرای نهایی

مشخصات رایانه‌ای که نسخه نهایی کد روی آن بررسی شد در جدول ۱-۱ آمده است. برخی ارزیابی‌های منجمد مدل‌ها در نشست‌های جداگانه انجام شده‌اند؛ از این رو عدددهای زمان و حافظه هر جدول فقط درون همان پروتکل مقایسه می‌شوند و به محیط زیر تعمیم داده نمی‌شوند.


جدول ۱-۱ مشخصات محیط توسعه و اجرای محلی

مشخصات	مؤلفه
Intel Core i7-13700H, 20 logical CPUs	CPU
NVIDIA GeForce RTX 4070 Laptop GPU	GPU
8188 MiB	GPU Memory
15.7 GB	Host RAM
7.62 GiB	RAM available to WSL2
UMIS NVMe SSD	Storage
Microsoft Windows 11 Pro	Host OS
WSL2, x86_64 Linux	Runtime layer
610.62	GPU Driver

شکل ۱-۱ نمای فشرده‌ای از مصرف منابع کل مسیر اجرایی و تأخیر مؤلفه‌ها را نشان می‌دهد. مقادیر زمانی از دو اجرای شروع سرد به دست آمده‌اند؛ خط‌های روی ستون‌ها بازه مشاهده‌شده و خود ستون‌ها میانگین دو اجرا را نمایش می‌دهند. مصرف حافظه GPU پس از کسر خط پایه سیستم گزارش شده است، در حالی که مصرف RAM مستقیماً به فرایندهای چت‌بات نسبت داده می‌شود.

End-to-end Persian chatbot resource profile

Vosk → Gemma 2.9B (4-bit) → Piper | RTX 4070 Laptop, 8 GiB VRAM | two cold runs



Bars show the two-run mean; whiskers show the observed range. GPU allocation is baseline-subtracted; RAM is the direct process peak.

شکل ۱-۱ نمایه مصرف منابع و تأخیر مسیر انتهابه‌انتهای چت‌بات فارسی

۲-۱- محیط نرم‌افزاری ثبت‌شده

نسخه‌های زیر از محیط persian_assistant در زمان نهایی‌سازی گزارش استخراج شدند و در جدول ۱-۲

آمده‌اند:

جدول ۱-۲ نسخه کتابخانه‌های محیط اجرای محلی

نسخه	بسته	نسخه	بسته
2.12.0+cu130	PyTorch	3.12.13	Python
1.14.0	Accelerate	4.57.6	Transformers
0.3.45	Vosk	0.49.2	BitsAndBytes
1.4.2	Piper TTS	1.26.0	ONNX Runtime
0.11.0	Librosa	0.12.1	Hazm
1.17.1	SciPy	2.4.6	NumPy
0.14.0	SoundFile	0.5.5	SoundDevice

این جدول تصویر محیط موجود است. برای نصب تازه باید نسخه‌های فایل وابستگی پروژه و سازگاری

PyTorch/CUDA بررسی شوند؛ زیرا نسخه درایور و بسته‌های شتاب‌دهی با سخت‌افزار وابستگی دارند.

۳-۱- مدل‌های عملیاتی

ترکیب مدل‌های نسخه اجرایی و محل اجرای هر مرحله در جدول ۱-۳ خلاصه شده است.

جدول ۱-۳ مدل‌های خط لوله نهایی

مرحله	مدل	محل اجرا
VAD	Silero VAD ONNX	CPU
ASR	vosk-model-fa-0.42	CPU
LLM	Gemma 2 9B Instruct, 4-bit	CUDA GPU
TTS	Piper fa_IR-gyro-medium ONNX	CPU

مدل‌های بزرگ در مخزن کد نسخه‌بندی نمی‌شوند و باید در مسیرهای تعریف‌شده قرار گیرند یا مسیر آن‌ها با متغیر محیطی تغییر کند.

۴-۱- تنظیمات ارزیابی ASR

آزمون Common Voice 25 برای هر مدل شامل ۱۰۵۱۹ نمونه و ۵۲,۰۴۷.۲۸ ثانیه صوت بود. آزمون FLEURS fa_ir برای هر پیکربندی شامل تمام ۸۷۱ ضبط و ۱۳,۳۲۱.۸۶ ثانیه صوت بود. معیارها از روابط زیر محاسبه شدند:

$$WER(\%) = 100 \times \frac{S + D + I}{N} \quad (1.1)$$

$$RTF = \frac{T_{inference}}{T_{audio}} \quad (2.1)$$

که در آن S ، D و I تعداد جایگزینی، حذف و درج و N تعداد واژه مرجع است. CER رابطه مشابهی در سطح نویسه دارد. فایل‌های محاسباتی ممکن است نرخ خام را در بازه صفر تا یک ذخیره کنند، اما همه مقدارهای WER/CER در متن و جدول‌های گزارش در عدد صد ضرب شده و با علامت درصد نمایش داده می‌شوند.

۵-۱- تنظیمات انتشار خطا

مجموعه پرسش و پاسخ منجمد شامل ۷۶۹ ضبط از ۲۸۶ شناسه معنایی بود. نمونه‌های تکراری یک جمله در بوت‌استرپ به‌عنوان یک خوشه در نظر گرفته شدند. گروه اصلی انتشار خطا شامل ۴۷۰ ضبط از ۱۷۴ شناسه‌ای بود

که مدل زبانی در شرط متن مرجع پاسخ دقیق داده بود. برای مقایسه شرایط، پیش‌بینی‌های خام و ورودی‌ها منجمد نگه داشته شدند. فاصله‌های اطمینان با باز نمونه‌گیری در سطح شناسه معنایی محاسبه شدند تا تکرار ضبط یک جمله به‌عنوان مشاهده مستقل تلقی نشود.

۶-۱- تنظیمات آزمایش پیش‌پردازش صوت

در آزمایش زوجی نخست، پروفایل زیر استفاده شد:

- آستانه اعمال: منفی dBFS ۴۵؛

- هدف RMS: منفی dBFS ۲۴؛

- بیشینه بهره: dB ۴۰؛

- فضای خالی قله: منفی dBFS ۱.

پیش‌پردازش روی ۲۰۶ مورد از ۷۶۹ ضبط فعال شد. شبکه انتخاب پارامتر شامل ۲۵ ترکیب توسعه بود و تنها ترکیب منتخب آستانه منفی dBFS ۴۰ و هدف منفی dBFS ۱۸ روی بخش نگه‌داشته‌شده رمزگشایی شد.

۷-۱- تنظیمات N-best و عدم قطعیت

سه فرضیه برای هر ۷۶۹ ضبط تولید شد. تقسیم ۷۰/۳۰ در سطح شناسه معنایی انجام شد و به ۵۱۷ ضبط توسعه و ۲۵۲ ضبط نگه‌داشته‌شده انجامید. معیار اوراکل بهترین فرضیه را با استفاده از مرجع انتخاب می‌کند و فقط کران بالای تشخیصی است.

شبکه عدم قطعیت شامل آستانه‌های اطمینان ۰.۴۵، ۰.۵۵، ۰.۶۵، ۰.۷۵ و ۰.۸۵ و شکاف‌های امتیاز ۰.۲۵، ۰.۵، ۱.۰، ۲.۰ و ۳.۰ بود. انتخاب روی توسعه باید نرخ رفع ابهام حداکثر ۱۰٪ و نرخ رفع ابهام غیر ضروری حداکثر ۵٪ را رعایت می‌کرد.

۸-۱- تنظیمات ارزیابی مدل زبانی و TTS

ارزیابی چندگزینه‌ای مدل زبانی ۱۰۵۰ پرسش در سه دسته برابر و ارزیابی درک مطلب ۶۰۰ پرسش داشت. معیارهای درک مطلب تطابق دقیق، F1 توکنی و شباهت معنایی بودند.

برای آزمایش TTS، ۱۰ درصد از بخش فارسی Common Voice 25 به‌صورت تصادفی انتخاب شد که شامل ۱۰۵۲ نمونه بود. متن مرجع هر نمونه به سه مدل تولید گفتار داده شد و صوت حاصل با مدل ثابت STT Fa

FastConformer Hybrid Transducer-CTC Large بازنشاسی شد. WER/CER از مقایسه متن بازنشاسی شده با متن ورودی محاسبه شدند. NISQA برای کیفیت ادراکی پیش‌بینی شده و RTF و تأخیر برای سرعت استفاده شدند. WER/CER روی مقیاس صفر تا صد درصد گزارش شده‌اند؛ در مقابل، RTF یک نسبت بدون واحد است و روی مقیاس خام باقی می‌ماند. ضریب افزایش سرعت برابر است با:

$$Speedup = \frac{1}{RTF} \quad (3.1)$$

میانگین RTF نمونه‌ای، میانگین نسبت زمان تولید به مدت صوت هر نمونه است. RTF تجمیعی از تقسیم مجموع زمان تولید همه نمونه‌ها بر مجموع مدت صوت آن‌ها محاسبه می‌شود؛ بنابراین این دو مقدار لزوماً برابر نیستند. در خروجی‌های موجود، مقدارهای ۰.۰۳۲ و ۰.۰۲۶ مدل MMS به ترتیب در جدول دقت و جدول اختصاصی کارایی تجمیعی آمده‌اند، اما خلاصه کلی برچسب ناسازگاری برای مقدار نخست دارد؛ از این رو هر دو مقدار در گزارش حفظ شده‌اند. برای بازتولید دقیق نمونه‌گیری تصادفی نیز باید همان فهرست شناسه‌های ۱۰۵۲ نمونه یا بذر تصادفی ذخیره شده استفاده شود.

۹-۱- فرمان‌های اصلی بازتولید

کد منبع و فایل‌های لازم برای اجرای سامانه در مخزن عمومی پروژه در GitHub: Aliakbawr/e2e_system در دسترس هستند. نمونه فرمان‌های دریافت مخزن و اجرای بخش‌های قابل اجرای محلی در شبه‌کد ۱ آمده است:

شبه‌کد ۱: فرمان‌های بازتولید ارزیابی‌های اصلی

- 1 git clone https://github.com/Aliakbawr/e2e_system.git
- 2 cd e2e_system
- 3 python main.py
- 4 python -m benchmark.chatbot_multiturn.run_evaluation --strict
- 5 python -m benchmark.asr_audio_preprocessing.run_ablation
- 6 python -m benchmark.asr_parameter_selection.run_audio_sweep
- 7 python -m benchmark.asr_parameter_selection.run_uncertainty_sweep
- 8 python -m benchmark.asr_nbest.build_evidence
- 9 python -m benchmark.asr_nbest.evaluate_contextual_recovery

نقاط واریسی آزمایش‌ها افزایشی و قابل ادامه هستند. خروجی‌های خلاصه، فراداده و فایل‌های نتیجه نسخه‌بندی

شده‌اند و برای نتایج منجمد، فایل هش یکپارچگی نیز نگهداری می‌شود.

۱۰-۱ جریان اجرا و شبه‌کد سامانه

۱۱-۱ جریان اصلی برنامه

پس از آغاز برنامه، مدل زبانی و TTS بارگذاری و یک نشست خالی ساخته می‌شود. حلقه اصلی منتظر گفتار می‌ماند و پس از پایان پخش پاسخ دوباره به حالت شنیدن بازمی‌گردد. مدل Vosk در نخستین نوبت به‌صورت تنبل بارگذاری و برای نوبت‌های بعدی کش می‌شود. جریان اصلی در شبه‌کد ۲ نمایش داده شده است.

شبه‌کد ۲: حلقه اصلی مکالمه

```
1 session = ChatSession(max_turns=6, max_memory_items=12)
2
3 while running:
4     audio_path = record_utterance_with_vad()
5     result = chat(audio_path, session)
6     print(result.question, result.answer, result.metrics)
```

۱-۱۲ - شبه‌کد یک نوبت کامل

ترتیب اجرای یک نوبت کامل در شبه‌کد ۳ ارائه شده است.

شبه‌کد ۳: پردازش یک نوبت کامل مکالمه

```
1 raw = transcribe_audio_detailed(audio_path)
2 transcript = preprocess_transcription(raw)
3 decision = interpret_transcription(transcript, session)
4
5 if decision.action == "retry":
6     speak("Please repeat")
7     return
8
9 if decision.action == "clarify":
10    session.set_pending_clarification(
11        decision.raw_question,
12        decision.risk.options,
13    )
14    speak(decision.risk.clarification)
15    return
16
17 stream = gemma.generate_stream(
18     question=decision.effective_question,
19     history=session.messages(),
20     memory=session.memory_prompt(),
21 )
22
23 for fragment in stream:
24     for phrase in phrase_buffer.feed(fragment):
25         streaming_piper.submit(phrase)
26
27 streaming_piper.finish()
28 session.add_turn(decision.effective_question, final_answer)
```

۱-۱۳ - شبه‌کد کنترل ابهام

منطق تصمیم‌گیری برای رفع ابهام در شبه‌کد ۴ آمده است.

شبه‌کد ۴: منطق کنترل ابهام

```
1 transcript = rerank_with_explicit_memory(transcript, session)
2 risk = assess_asr_risk(transcript)
3
4 if pending_clarification:
5     resolution = resolve_from_primary_and_nbest(reply)
6     if resolution.is_unique:
7         remember_contextual_correction(resolution)
8         question = reconstruct_original_question(resolution)
9         return ANSWER(question)
10
11 if transcript.is_empty:
12     return RETRY
13
14 if risk.has_low_confidence_disagreement:
15     return CLARIFY(risk.options)
16
17 if risk.has_critical_name_number_or_negation_disagreement:
18     return CLARIFY(risk.options)
19
20 return ANSWER(transcript.primary_text)
```

۱-۱۴ - نمونه مکالمه رفع ابهام

در مثال زیر، دو فرضیه واقعی رمزگشا در یک نام مهم اختلاف دارند:

کاربر: درباره دانشگاه شریف توضیح بده.

متن اصلی ASR: درباره دانشگاه شریعت توضیح بده.

فرضیه جایگزین: درباره دانشگاه شریف توضیح بده.

سامانه: منظورتان «شریعت» یا «شریف» است؟

کاربر: دومی.

پرسش بازسازی شده: درباره دانشگاه شریف توضیح بده.

اصلاح «شریعت → شریف» همراه با زمینه همین پرسش در حافظه نشست ذخیره می شود. این اصلاح فقط در پرسش هم زمینه آینده می تواند یک فرضیه N-best را پشتیبانی کند و به جایگزینی عمومی همه رخدادهای «شریعت» تبدیل نمی شود.

۱-۱۵ - ساختار خروجی و معیارها

خروجی برنامه برای هر نوبت ساختاری مشابه شبه کد ۵ دارد:

شبه کد ۵: ساختار خروجی ثبت شده برای هر نوبت مکالمه

```
1  {
2    "question": "...",
3    "decision": "answer | clarify | retry",
4    "resolved_question": "...",
5    "asr": {
6      "text": "...",
7      "mean_word_confidence": 0.0,
8      "alternatives": [],
9      "risk": {},
10     "reranking": {}
11   },
12   "memory": [],
13   "answer": "...",
14   "audio": "data/audio_out/response.wav",
15   "metrics": {
16     "asr_time": 0.0,
17     "llm_time": 0.0,
18     "llm_time_to_first_token": 0.0,
19     "llm_time_to_first_phrase": 0.0,
20     "time_to_first_audio": 0.0,
21     "tts_time": 0.0,
22     "tts_phrase_count": 0
23   }
24 }
```

این ساختار اجازه می دهد خطای هر نوبت به صوت، ASR، تصمیم کنترل، مدل زبانی یا TTS نسبت داده شود و معیارهای تجربه کاربر از زمان کل تولید جدا بمانند.

Abstract

This project designs, implements, and evaluates a fully local Persian voice assistant. The operational pipeline uses Silero VAD to determine utterance boundaries, Vosk Persian ASR to produce the primary transcript, word-level confidence values, and alternative hypotheses, a four-bit Gemma 2 9B model to generate Persian responses, and Piper to synthesize and stream the final speech. In addition to connecting these models, the implementation includes selective amplification for very low-level recordings, conservative Persian text normalization, task-aware ambiguity detection, context-limited memory of confirmed corrections, multi-turn dialogue history, and stage-level runtime logging.

Candidate ASR, language, and TTS models were evaluated under controlled protocols that considered quality, accuracy, runtime, and resource use. The experiments show that ASR rankings depend on the evaluation domain and that a low overall word error rate does not necessarily preserve the names, numbers, or negations required for a correct downstream answer. The final dialogue controller therefore asks a focused clarification question when the available ASR evidence exposes a consequential ambiguity instead of silently forwarding uncertain text to the language model.

For TTS evaluation, 1,052 reference texts were selected as a random ten percent sample of Persian Common Voice 25. Each TTS model generated speech from the same texts. NISQA estimated perceptual quality, while a fixed NeMo Persian FastConformer model retranscribed the generated audio so that WER and CER could measure relative intelligibility. Piper achieved the strongest quality and retranscription accuracy, whereas MMS VITS was the fastest. Piper was selected because it remained faster than real time while offering the best overall output quality. Finally, phrase-level streaming overlaps language generation, speech synthesis, and playback, reducing perceived waiting time. The resulting system provides a reproducible and modular framework for studying local Persian voice assistants and the propagation of errors across their components.

Keywords: Persian voice chatbot, automatic speech recognition, large language model, text-to-speech, ambiguity resolution, streaming inference



University of Isfahan

Faculty of Computer Engineering

Department of Artificial Intelligence

B.Sc. Project

Project Title:

**Persian Voice Chatbot via Integration of Automatic Speech
Recognition, Large Language Model and Text-to-Speech**

Supervisor:

Dr. Hamidreza Baradaran Kashani

By:

Ali Akbar Ahrari

September 2026