



دانشگاه اصفهان | دانشکده مهندسی کامپیوتر | گروه هوش مصنوعی

سمینار دفاع از پروژه کارشناسی

چتبات فارسی مبتنی بر یکپارچه سازی تشخیص گفتار، مدل زبانی بزرگ و تبدیل متن به گفتار

ارائه دهنده: علی اکبر احراری
استاد راهنما: دکتر حمیدرضا برادران کاشانی
داور: دکتر شفیع زادگان
شهریور ۱۴۰۵



سرفصل مطالب

۰۱ مسئله و اهداف

۰۴ نتایج اجرا

۰۲ معماری سامانه

۰۵ انتشار خطا و کنترل ریسک

۰۳ روش ارزیابی

۰۶ جمع بندی



یک دستیار صوتی خوب فقط اتصال سه مدل نیست؛ کیفیت نهایی حاصل تعامل دقت، منابع و کنترل خطاست.

انتشار خطا

WER پایین به تنهایی تضمین نمی‌کند
اطلاعات لازم برای پاسخ مدل زبانی
حفظ شده باشد.

اجرای محلی

مدل‌ها باید هم‌زمان روی رایانه
شخصی اجرا شوند؛ بنابراین حافظه،
تأخیر و رقابت CPU/GPU بخشی از
مسئله‌اند.

دقت فارسی

رتبه مدل ASR با دامنه داده تغییر
می‌کند و یک خطای کوچک در نام،
عدد یا نفی می‌تواند معنای پرسش را
عوض کند.

پرسش محوری: کدام ترکیب، بهترین رفتار انتهابه‌انتها را در محدودیت سخت‌افزار محلی فراهم می‌کند؟



اهداف و پرسش‌های پژوهش

۰۱

RQ3 – تولید گفتار

کیفیت ادراکی، بازشناسی پذیری و
سرعت

RQ2 – مدل زبانی

کیفیت پاسخ فارسی در کنار امکان
اجرای محلی

RQ1 – تشخیص گفتار

توازن دقت، سرعت و مصرف منابع
برای فارسی


RQ4 – سامانه یکپارچه

خطای ASR چگونه به پاسخ LLM منتقل می‌شود و چگونه می‌توان خطر آن را کنترل کرد؟

دامنه پروژه: ارزیابی، انتخاب و یکپارچه‌سازی مدل‌های موجود؛ نه آموزش مدل پایه از ابتدا



مسیر اصلی داده، کنترل ریسک، حافظه نشست و ثبت معیارها





کنترل مکالمه

answer / clarify / retry

حساس به نام، عدد و نفی

Vosk fa-0.42

متن، اطمینان واژه و سه فرضیه N-
best

Silero VAD

تشخیص آغاز و پایان نوبت
۱۶ کیلوهرتز، CPU

گزارش‌گیری

زمان نخستین توکن، عبارت و
صوت

Piper

تولید عبارت‌محور و پخش جریانی

Gemma2 9B

نسخه چهاربیتی
تاریخچه شش‌نوبتی

همه مولفه‌ها محلی و قابل جایگزینی‌اند؛ مدل زبانی فقط پس از حل ابهام فراخوانی می‌شود.



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

طرح کلی ارزیابی

۰۳

TTS

نمونه تصادفی ۱۰٪ CV25
۱۰۰۵۲ متن برای هر مدل
NISQA + بازشناسی مجدد

LLM

۱۰۰۵۰ — ParsiNLU
پرسش
درک مطلب — ۶۰۰ پرسش
۵ مدل چهاربیتی

ASR

CV25
۱۰۰۵۱۹ نمونه — ۱۴/۴۶
ساعت
۸۷۱ — FLEURS fa_ir
نمونه

ارزیابی پایین دستی





دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

پیش‌آموزش و ریزتنظیم مدل‌های ASR

۰۳

مدل	سازگارسازی فارسی	داده اعلام‌شده
NeMo FastConformer Hybrid	ریز تنظیم فارسی از مدل انگلیسی	Common Voice 15.0
Wav2Vec2 XLSR Persian v3	ریز تنظیم فارسی از مدل پایه XLSR با ۵۳ زبان	Common Voice 6.1
Whisper large-v3	چندزبانه؛ بدون ریز تنظیم فارسی	زیر مجموعه فارسی اعلام نشده
Vosk fa-0.42	مدل اختصاصی فارسی	داده آموزش اعلام نشده

نکته: Common Voice و FLEURS گزارش‌شده در صفحه Vosk، مجموعه ارزیابی‌اند و نباید داده آموزش تلقی شوند.



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

نتایج ASR – Common Voice 25

۰۴

کمتر بهتر است

۱۲,۳۳%

NeMo FastConformer

۲۲,۳۴%

Vosk fa-0.42

۲۶,۱۵%

Wav2Vec2 XLSR

۳۶,۷۷%

Whisper large-v3

۱۲,۳۳%

NeMo –WER کمترین

۰/۰۱۵

Wav2Vec2 –RTF سریعترین

CPU

Vosk –GPU اجرای بدون



رتبه مدل‌ها با تغییر دامنه جابه‌جا شد؛ بهترین نتیجه این مجموعه متعلق به Vosk است.



چرا Vosk در سامانه نهایی انتخاب شد؟

۰۴

Vosk fa-0.42

CV25 WER: 22.34%
FLEURS WER: 16.75%
CPU + confidence + N-best

NeMo FastConformer

CV25 WER: 12.33%
FLEURS Transducer WER: 43.32%
نیازمند GPU در ارزیابی

انتخاب عملیاتی ≠ کمترین WER در یک مجموعه

Vosk حافظه GPU را برای Gemma آزاد می‌کند و شواهد لازم برای رفع ابهام را ارائه می‌دهد.



درک مطلب فارسی

۲۵/۱۷%

تطابق دقیق

۰/۵۸۱۱

۱۴ توکنی

۰/۷۸۳۹

شباهت معنایی

دقت کل ParsiNLU

۴۶/۸۶%



Gemma2 9B

بیشتر بهتر است

۴۰/۳۸%



Qwen2.5 7B

۳۶/۹۵%



Dorna2 8B

۲۹/۵۲%



Qwen2.5 3B

۲۵/۷۱%




Gemma2 2B

Gemma2 9B در هر دو وظیفه بهترین نتیجه کلی را داشت.



روش ارزیابی تبدیلی متن به گفتار

۰۴





نتایج TTS و انتخاب Piper

۰۴

×۵/۲۰

سریع‌تر از زمان واقعی

۱۰/۷%

WER بازشناسی مجدد
کمتر بهتر است

۴/۵۳۴

NISQA MOS
بیشتر بهتر است

مدل	MOS	WER	CER	RTF تجمیعی
Kamtera VITS	۳/۳۸۰	۱۴/۴%	۶/۸%	۰/۰۴۳
MMS VITS	۳/۹۱۳	۲۵/۳%	۱۱/۴%	۰/۰۲۶
Piper	۴/۵۳۴	۱۰/۷%	۴/۵%	۰/۱۹۲

Piper سریع‌ترین مدل نیست، اما بهترین کیفیت ادراکی و بیشترین حفظ محتوای زبانی را دارد.



روش ارزیابی انتشار خطا از تشخیص گفتار به مدل زبانی

۵۰



مسیر خطا دار

رونویسی ASR → همان پرسش، دستور و مدل زبانی

مسیر مرجع

متن مرجع → Gemma
تنها نمونه‌های با پاسخ دقیق نگه داشته می شوند.

گروه اصلی: ۴۷۰ ضبط از ۱۷۴ شناسه معنایی

متغیر اصلی فقط متن تولیدشده توسط ASR است.



Vosk fa-0.42

WER: 16.75%

حفظ پاسخ صحیح: ۶۲/۹۸٪

شکست انتشار: ۳۷/۰۲٪

NeMo –Transducer

WER: 43.32%

حفظ پاسخ صحیح: ۱۴/۶۸٪

شکست انتشار: ۸۵/۳۲٪

۱۶/۴۸٪ → ۶۳/۹۸٪

افزایش حفظ پاسخ صحیح با جایگزینی مسیر ASR



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه هوش مصنوعی

خطای مرتبط با وظیفه مهم‌تر از WER کلی است

۵۰

AUC پیش‌بینی شکست پایین‌دستی

WER 0.7711

NeMo

حذف عبارت پاسخ ۰/۸۹۴۳

WER 0.7620

Vosk

حذف عبارت پاسخ ۰/۹۴۲۲

حذف نام، عدد، نفی یا عبارت پاسخ، خطر واقعی را بهتر از میانگین خطای واژه نشان می‌دهد.



تقویت انتخابی صوت‌های کم‌دامنه

۰۵

فقط ۲۰۶ ضبط کم‌دامنه تقویت شدند؛ سایر نمونه‌ها بدون تغییر باقی ماندند.

۹۹/۹%

احتمال بوت‌استرپ بهبود WER

۰/۰۰۸۸+

میانگین ۱۴ پاسخ

۰/۲۶۸-

واحد درصد WER پیکره

تفسیر

اثر کوچک است، اما جهت بهبود WER و F1 قابل اتکاتر از تغییر تطابق دقیق بود؛ بنابراین پیش‌پردازش محافظه‌کارانه حفظ شد.



N-best: ظرفیت واقعی، انتخاب کور زبان بار

۵۰

اصلاح صریح کاربر

نرخ بازیابی هدف: ۸۱/۴۸٪
افزایش EM نگه داشته شده: ۱/۵۹
واحد درصد
انتخاب نادرست: صفر

بیشترین امتیاز رمزگشا

WER نگه داشته شده
۱۲/۲۹٪ ← ۱۴/۰۴٪
انتخاب خام نتیجه را بدتر کرد

اوراکل N-best

WER نگه داشته شده
۱۲/۲۹٪ ← ۱۱/۰۰٪
۱۶ عبارت پاسخ قابل بازیابی

سیاست نهایی فقط با شاهد زمینه‌ای و اصلاح صریح کاربر فرضیه را تغییر می‌دهد.

نتیجه: N-best منبع شواهد است، نه مجوز تصحیح خودکار.



کنترل ابهام، حافظه و جریان سازی




دو نوع حافظه

تاریخچه شش نوبتی برای LLM
حافظه ۱۲ اصلاح تایید شده و محدود به زمینه

نمونه رفع ابهام

«منظورتان شریعت یا شریف است؟»
اختلاف نام، عدد و نفی حتی با اطمینان بالا بررسی می شود.




همپوشانی تولید متن، صوت و پخش برای کاهش تأخیر ادراکی




پرو فایل منابع و تأخیر سامانه

۵۰



| اجرای سرد دو نوبت ۸ GiB VRAM – RTX 4070 Laptop



- Vosk: اجرای CPU، دقت بهتر روی FLEURS و ارائه confidence و N-best
- Gemma2 9B: رتبه نخست در دو وظیفه کنترل شده فارسی
- Piper: بهترین کیفیت ادراکی و کمترین WER/CER بازشناسی مجدد
- کنترل ریسک و جریان سازی: اتصال میان مدل های مستقل و تجربه مکالمه

github.com/Aliakbawr/e2e_system



پیشنهادهای آینده

- ارزیابی انسانی پاسخ و طبیعی بودن صوت
- ساخت مجموعه TTS فارسی و آزمون شنیداری
- ارزیابی گسترده سامانه روی مکالمه طبیعی
- کالیبراسیون رفع ابهام و خلاصه‌سازی تاریخچه بلند

نتیجه‌های اصلی

- رتبه ASR به دامنه وابسته است.
- حفظ اطلاعات پاسخ از WER مهم‌تر است.
- N-best فقط با شاهد زمینه‌ای ایمن است.
- انتخاب نهایی یک مسئله انتها به انتهاست.



با تشکر از توجه شما

پاسخ به پرسش‌ها



github.com/Aliakbawr/e2e_system